

CONTENTS

Prácticos 8 y 9 (LGN / Estimación Puntual) — Probabilidad y Estadística

 FING UdelaR · Resolución completa y verificada

PRÁCTICO 8 — Convergencia Casi Segura y Ley de los Grandes Números

 Ejercicio 1 — Desigualdad de Chebyshev: tamaño de muestra para encuesta

 Ejercicio 2 — Álgebra de límites casi seguros

 Ejercicio 3 — Método de Montecarlo

 Ejercicio 4 — Promedios móviles de a pares

 Ejercicio 5 — Suma diverge a $+\infty$

 Ejercicio 6 — Límites c.s. con exponenciales

PRÁCTICO 9 — Estimación Puntual

 Ejercicio 1 — Consistencia de $\overline{X}_n$, σ_n^2 , s_n^2

 Ejercicio 2 — Estimadores por el método de los momentos

 Ejercicio 3 — Vida útil de una pieza (Exponencial $\rightarrow$ Geométrica)

 Ejercicio 4 — Estimador por momentos con $E(X_1)=0$

 Ejercicio 5 — Estimadores de máxima verosimilitud

 Ejercicio 6 — Sesgo de $\overline{X}_n$, σ_n^2 , s_n^2

 Ejercicio 7 — Estimador lineal insesgado de varianza mínima

 Ejercicio 8 — Estimadores para $\mathcal{P}(\lambda)$

 Ejercicio 9 — $\mathcal{U}[0, \theta]$: MoM vs. MLE

Resumen de técnicas usadas en estos prácticos

.....

Script de verificación

.....

Prácticos 8 y 9 (LGN / Estimación Puntual) — Probabilidad y Estadística

FING UDELAR · RESOLUCIÓN COMPLETA Y VERIFICADA

⚠ **Nota sobre las fuentes:** este práctico fue rehecho porque el archivo de salida original fue sobrescrito por error. Se cotejaron los enunciados contra **ambas variantes** disponibles en PyE/ (`Práctico 8/9 - PyE.pdf` y `Práctico 8/9 L - PyE.pdf` , ediciones 2022 y 2023 — idénticas salvo el nombre “Chevishoff/Chevishoff”, sin efecto en el contenido). La carpeta `Solucion Practicos PYE/` **no contiene una solución oficial real de estos dos prácticos:** `8. Ley de los Grandes Numeros.pdf` es solo el enunciado (no trae resolución), y `Practico9_Solucion.pdf` corresponde a un práctico **completamente distinto** (IMERL 2019-S2, “Estadística Descriptiva”: tallo-hoja, boxplot, regresión lineal simple con presión arterial/peso) — no al Práctico 9 de Estimación Puntual del curso 2022/2023. Por lo tanto **no hubo material de referencia utilizable para cotejar**; toda la resolución de abajo es independiente, verificada con `sympy` / `numpy` / `scipy` y simulación Monte Carlo (script y resultados al final de cada sección relevante).

Las anotaciones a mano visibles en el PDF “L” de ambos prácticos (fórmulas sueltas de $\hat{p}$, λ , σ^2 , etc.) coinciden con los resultados obtenidos de forma independiente abajo; se usan solo como confirmación de notación, no como fuente de la demostración.

PRÁCTICO 8 — Convergencia Casi Segura y Ley de los Grandes Números

Ejercicio 1 — Desigualdad de Chebyshev: tamaño de muestra para encuesta

1. Estimador de p . Con $X_1, \dots, X_n$ iid $\mathrm{Ber}(p)$, el estimador natural es la proporción muestral $\widehat{p} = \frac{1}{n} \sum_{i=1}^n X_i$ (la frecuencia relativa de “sí” en la muestra).

2. Cantidad de datos necesarios.

Lema: $p(1-p) \leq \frac{1}{4}$ para todo $p \in [0, 1]$. Prueba: $p(1-p) = -\left(p - \frac{1}{2}\right)^2 + \frac{1}{4} \leq \frac{1}{4}$, con igualdad en $p = \frac{1}{2}$. ■

Como $E(\widehat{p}) = p$ y $\mathrm{Var}(\widehat{p}) = \frac{\mathrm{Var}(X_1)}{n} = \frac{p(1-p)}{n}$, Chebyshev da, para $\varepsilon = 0.03$:

$$P(|\widehat{p} - p| \geq \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}.$$

Queremos $P(|\widehat{p} - p| < \varepsilon) \geq 0.95$, es decir $P(|\widehat{p} - p| \geq \varepsilon) \leq 0.05$. Basta que la cota sea ≤ 0.05 :

$$\frac{1}{4n\varepsilon^2} \leq 0.05 \quad \Longleftrightarrow \quad n \geq \frac{1}{4 \cdot 0.05 \cdot \varepsilon^2} = \frac{1}{0.2 \cdot \varepsilon^2}.$$

Con $\varepsilon = 0.03$: $n \geq \frac{1}{0.2 \cdot 0.0009} = 5555.\overline{5}$, luego

$$\boxed{n = 5556}$$

(verificado numéricamente: $1/(4 \cdot 0.03^2 \cdot 0.05) = 5555.555\dots \rightarrow \text{ceil} = 5556$). Nótese que esta cota es independiente del p real (por eso se puede calcular “antes de tomar la muestra”) y es muy conservadora frente al TCL (que daría un n mucho menor, del orden de 1000), porque Chebyshev solo usa la varianza, no la forma de la distribución.

Ejercicio 2 — Álgebra de límites casi seguros

Idea general. Convergencia c.s. es convergencia **puntual** en un conjunto de probabilidad 1: $X_n \xrightarrow{\text{c.s.}} a$ significa que el conjunto $A = \{\omega: X_n(\omega) \rightarrow a\}$ cumple $P(A) = 1$. Todas las propiedades pedidas son, entonces, consecuencias directas de propiedades de límites de sucesiones **reales** (análisis real elemental), aplicadas punto a punto sobre un conjunto de medida 1.

Sean $A = \{\omega: X_n(\omega) \rightarrow a\}$, $B = \{\omega: Y_n(\omega) \rightarrow b\}$, con $P(A) = P(B) = 1$. Por subaditividad de P sobre los complementos: $P(A^c \cup B^c) \leq P(A^c) + P(B^c) = 0$; $\Rightarrow P(A \cap B) = 1$.

Para cualquier $\omega \in A \cap B$, las sucesiones **numéricas** $X_n(\omega)$ y $Y_n(\omega)$ convergen a a y b respectivamente. Por álgebra de límites de sucesiones reales:

1. $X_n(\omega) + Y_n(\omega) \rightarrow a + b$ para todo $\omega \in A \cap B$, y $P(A \cap B) = 1$, luego $X_n + Y_n \xrightarrow{\text{c.s.}} a + b$. ■
2. $X_n(\omega) Y_n(\omega) \rightarrow ab$ para todo $\omega \in A \cap B$ (producto de límites), luego $X_n Y_n \xrightarrow{\text{c.s.}} ab$. ■
3. Si $g: \mathbb{R} \rightarrow \mathbb{R}$ es continua en a : por definición de continuidad, $x_n \rightarrow a \Rightarrow g(x_n) \rightarrow g(a)$ para sucesiones reales. Aplicado a $\omega \in A$: $g(X_n(\omega)) \rightarrow g(a)$. Como $P(A) = 1$, $g(X_n) \xrightarrow{\text{c.s.}} g(a)$. ■

(Este ejercicio es exactamente la herramienta que se usa después en el Práctico 9, Ejercicio 1.2, para propagar la convergencia c.s. de $\overline{X}_n$ y de momentos hacia σ_n^2 , s_n^2 , etc.)

Ejercicio 3 — Método de Montecarlo

1. Integración. Sea $Z_i = f(U_i)$. Como U_i son iid y f es una función fija, $(Z_i)_{i \in \mathbb{N}}$ son iid. Como $f \in \mathcal{R}[a, b]$ (Riemann integrable en un intervalo cerrado y acotado), f es acotada, luego $E(Z_1) = E(f(U_1)) < \infty$ y está bien definida:

$$E(Z_1) = \int_a^b f(x) \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \int_a^b f(x) dx$$

(pues la densidad de $U \sim \mathcal{U}[a, b]$ es $\frac{1}{b-a} \mathbb{1}_{[a, b]}$). Por la **Ley Fuerte de los Grandes Números** aplicada a (Z_i) :

$$\frac{1}{n} \sum_{i=1}^n f(U_i) = \frac{1}{n} \sum_{i=1}^n Z_i \xrightarrow{\text{c.s.}} E(Z_1) = \frac{1}{b-a} \int_a^b f(x) dx. \quad \blacksquare$$

2. Área. Sea $Z_i = \mathbb{1}_{\{U_i \in D\}}$. Como U_i son iid, Z_i son iid $\text{Ber}(p)$ con $p = P(U_1 \in D) = \text{área}(D)$ (por la hipótesis dada sobre la distribución uniforme en el cuadrado). Entonces $a_n = \frac{1}{n} \sum Z_i$ y, por LGN, $a_n \xrightarrow{\text{c.s.}} E(Z_1) = \text{área}(D)$. ■

Verificación numérica (Monte Carlo con $n=2\{,000\}$):

- $f(x) = \sin(x)$ en $[0, 3]$: valor teórico de $\frac{1}{3} \int_0^3 \sin(x) dx = 0{,}66333$; estimado por simulación: $0{,}66346$ ✓.
- $D =$ círculo de radio $0{,}5$ centrado en $(0{,}5, 0{,}5)$ dentro de $[0, 1]^2$: área teórica $= \pi/4 = 0{,}78540$; estimado: $0{,}78520$ ✓.

Ejercicio 4 — Promedios móviles de a pares

$E(X_1) = 0$, $Y_i = \frac{X_i + X_{i+1}}{2}$. Queremos $\overline{Y}_n \xrightarrow{\text{c.s.}} 0$.

Reescritura de la suma. Sea $S_n = \sum_{i=1}^n X_i$. Notar que $\sum_{i=1}^n X_{i+1} = \sum_{j=2}^{n+1} X_j = S_n - X_1 + X_{n+1}$. Entonces:

$$\overline{Y}_n = \frac{1}{n} \sum_{i=1}^n \frac{X_i + X_{i+1}}{2} = \frac{1}{2n} [S_n + (S_n - X_1 + X_{n+1})] = \frac{S_n}{n} - \frac{X_1}{2n} + \frac{X_{n+1}}{2n} = \overline{X}_n - \frac{X_1}{2n} + \frac{X_{n+1}}{2n}.$$

Los tres términos convergen c.s.:

- $\overline{X}_n \xrightarrow{\text{c.s.}} 0$ por LGN (X_i iid, $E(X_1) = 0$).
- $\frac{X_1}{2n} \xrightarrow{\text{c.s.}} 0$: $X_1(\omega)$ es un número real fijo (finito c.s.), dividido entre $2n \rightarrow \infty$.
- $\frac{X_{n+1}}{2n} \xrightarrow{\text{c.s.}} 0$: esto requiere un argumento adicional porque X_{n+1} cambia con n . Usamos el **lema de Cesàro/Kronecker aplicado a la LGN**: si $S_n/n \rightarrow c$ c.s. (LGN, con $c=0$ acá), entonces $X_n/n \rightarrow 0$ c.s., pues $\frac{X_n}{n} = \frac{S_n}{n} - \frac{S_{n-1}}{n} = \frac{S_n}{n} - \frac{S_{n-1}}{n-1} \cdot \frac{n-1}{n} \xrightarrow{\text{c.s.}} c - c \cdot 1 = 0$ (usando el Ejercicio 2: producto y suma de límites c.s., y que $\frac{n-1}{n} \rightarrow 1$). Luego $\frac{X_{n+1}}{2n} = \frac{X_{n+1}}{n+1} \cdot \frac{n+1}{2n} \xrightarrow{\text{c.s.}} 0 \cdot \frac{1}{2} = 0$.

Sumando los tres límites (Ejercicio 2, ítem 1, aplicado dos veces): $\overline{Y}_n \xrightarrow{\text{c.s.}} 0 - 0 + 0 = 0$. ■

¿Por qué pueden ser dependientes Y_n, Y_{n+1} ? $Y_n = \frac{X_n + X_{n+1}}{2}$ e $Y_{n+1} = \frac{X_{n+1} + X_{n+2}}{2}$ comparten la variable X_{n+1} , así que en general $\mathrm{Cov}(Y_n, Y_{n+1}) = \frac{1}{4} \mathrm{Var}(X_{n+1}) \neq 0$ (salvo caso degenerado $\mathrm{Var}(X_1) = 0$). El punto pedagógico del ejercicio es que **la LGN clásica (para iid) no aplica directamente a (Y_n)** porque Y_n no son independientes entre sí — pero igual se puede probar la convergencia c.s. describiendo $\overline{Y}_n$ en términos de $\overline{X}_n$, que sí son promedios de iid.

Verificación numérica (simulación, $X_i \sim \mathcal{U}(-1, 1)$, $E(X_1) = 0$): $\overline{Y}_n$ en $n = 1000, 10000, 100000, 500000$: $0.0142, 0.0035, 0.0008, -0.0012$ — decreciendo hacia 0 en magnitud, consistente con la convergencia c.s. ✓.

Ejercicio 5 — Suma diverge a $+\infty$

X_n iid con $E(X_1) = a > 0$. Por LGN (fuerte), $\frac{S_n}{n} \xrightarrow{\text{c.s.}} a$, donde $S_n = \sum_{i=1}^n X_i$.

Sea $A = \{\omega : S_n(\omega)/n \not\rightarrow a\}$, con $P(A) = 1$. Fijado $\omega \in A$: como $a > 0$, tomando $\varepsilon = a/2 > 0$ en la definición de límite, existe $N(\omega)$ tal que para todo $n \geq N(\omega)$:

$$\left| \frac{S_n(\omega)}{n} - a \right| < \frac{a}{2} \quad ; \quad \frac{S_n(\omega)}{n} > \frac{a}{2} \quad ; \quad S_n(\omega) > \frac{a}{2} n \quad \xrightarrow{n \rightarrow \infty} +\infty.$$

Como $\frac{a}{2} n \rightarrow +\infty$, se sigue que $S_n(\omega) \rightarrow +\infty$. Esto vale para todo $\omega \in A$, y $P(A) = 1$, luego

$$S_n \xrightarrow{\text{c.s.}} +\infty. \quad \blacksquare$$

Verificación numérica ($X_i \sim \mathrm{Exp}(1)$, $a = E(X_1) = 1$): S_n en $n = 1000, 10000, 100000, 200000$ vale $973, 9976, 99959, 199915$ — crece linealmente con pendiente $\approx 1 = a$ ✓.

Ejercicio 6 — Límites c.s. con exponenciales

$X_1, \dots, X_n$ iid $\mathrm{Exp}(\lambda)$: $E(X_1) = \frac{1}{\lambda}$, $\mathrm{Var}(X_1) = \frac{1}{\lambda^2}$, $E(X_1^2) = \frac{2}{\lambda^2}$, $E(X_1^2) = \mathrm{Var}(X_1) + E(X_1)^2 = \frac{2}{\lambda^2}$.

1. Por LGN, $\overline{X}_n \xrightarrow{\text{c.s.}} \frac{1}{\lambda}$. Como $g(x) = x^2$ es continua, por el Ejercicio 2.3: $\left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 = (\overline{X}_n)^2 \xrightarrow{\text{c.s.}} \left(\frac{1}{\lambda} \right)^2 = \frac{1}{\lambda^2}$.

2. Sean $Z_i = X_i^2$, iid (función de iid), con $E(Z_1) = E(X_1^2) = \frac{2}{\lambda^2} < \infty$ (la exponencial tiene momentos finitos de todo orden). Por LGN aplicada a (Z_i) :

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{1}{n} \sum_{i=1}^n Z_i \xrightarrow{\text{c.s.}} E(Z_1) = \frac{2}{\lambda^2}.$$

Nótese que los dos límites son **distintos** ($\frac{1}{\lambda^2}$ vs. $\frac{2}{\lambda^2}$) — es el fenómeno esperado, ya que $\overline{X_n}^2 \neq \overline{X_n^2}$ en general (la diferencia es justamente Var , ver Práctico 9 Ej.1).

Verificación numérica ($\lambda=2$, $n=2,000$): $\overline{X_n}^2 = 0.24989$ vs. teórico $1/\lambda^2 = 0.25$ ✓; $\overline{X_n^2} = 0.49989$ vs. teórico $2/\lambda^2 = 0.5$ ✓.

PRÁCTICO 9 — Estimación Puntual

Ejercicio 1 — Consistencia de $\overline{X}_n$, σ_n^2 , s_n^2

1. X_n iid con $E(X_1) = \mu$, $\mathrm{Var}(X_1) = \sigma^2 < \infty$. Por la **Ley Fuerte de los Grandes Números** (aplicable porque $E|X_1| \leq \sqrt{E(X_1^2)} < \infty$): $\overline{X}_n \xrightarrow{\text{c.s.}} \mu$. $\square$ (consistente por definición)

2. Usamos la identidad sugerida: $\sigma_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\overline{X}_n)^2$.

Paso 1: $\frac{1}{n} \sum X_i^2 \xrightarrow{\text{c.s.}} E(X_1^2) = \sigma^2 + \mu^2$, por LGN aplicada a (X_1^2) — iid, con esperanza finita porque $\mathrm{Var}(X_1) < \infty \Rightarrow E(X_1^2) < \infty$.

Paso 2: $(\overline{X}_n)^2 \xrightarrow{\text{c.s.}} \mu^2$, por el Práctico 8 Ej.2.3 ($g(x) = x^2$ continua) aplicado a $\overline{X}_n \xrightarrow{\text{c.s.}} \mu$.

Paso 3: Restando (Práctico 8 Ej.2.1, con signo, o directamente $g(x,y) = x - y$ continua en $\mathbb{R}^2$ aplicada al par $(\frac{1}{n} \sum X_i^2, (\overline{X}_n)^2)$): $\sigma_n^2 \xrightarrow{\text{c.s.}} (\sigma^2 + \mu^2) - \mu^2 = \sigma^2$. $\square$

s_n^2 : $s_n^2 = \frac{n}{n-1} \sigma_n^2$. Como $\frac{n}{n-1} \rightarrow 1$ (sucesión numérica determinística) y $\sigma_n^2 \xrightarrow{\text{c.s.}} \sigma^2$, por el producto de límites c.s. (Práctico 8 Ej.2.2, con una de las dos sucesiones determinística): $s_n^2 \xrightarrow{\text{c.s.}} 1 \cdot \sigma^2 = \sigma^2$. $\square$

σ_n, s_n : $g(x) = \sqrt{x}$ es continua en $[0, \infty)$ en σ^2 (y $\sigma_n^2, s_n^2 \geq 0$ siempre), luego por el Práctico 8 Ej.2.3: $\sigma_n = \sqrt{\sigma_n^2} \xrightarrow{\text{c.s.}} \sqrt{\sigma^2} = \sigma$, $\square$
 $s_n = \sqrt{s_n^2} \xrightarrow{\text{c.s.}} \sigma$. $\square$

Verificación numérica ($N(\mu=5, \sigma=3)$, $n=15$, 200 000 réplicas): $E[\sigma_n^2]$ simulado $= 8.397$ vs. teórico $\frac{n-1}{n} \sigma^2 = 8.4$ ✓; $E[s_n^2]$ simulado $= 8.996$ vs. teórico $\sigma^2 = 9$ ✓ (adelanto del Ejercicio 6).

Ejercicio 2 — Estimadores por el método de los momentos

El método consiste en igualar los momentos poblacionales (en función de θ) con los momentos muestrales, y despejar θ .

1. **$\mathrm{Ber}(p)$** : $E(X)=p \rightarrow \boxed{\widehat{p} = \overline{X}_n}$.

2. **$\mathcal{P}(\lambda)$** : $E(X)=\lambda \rightarrow \boxed{\widehat{\lambda} = \overline{X}_n}$.

3. **$\mathrm{Geo}(p)$** (convención UdelaR: soporte $\{1,2,3,\dots\}$, $E(X)=1/p$):
 $\boxed{\widehat{p} = \frac{1}{\overline{X}_n}}$.

4. **$N(\mu, \sigma^2)$** : primer momento $m_1=\mu$, segundo $m_2=\sigma^2+\mu^2$.
 Despejando: $\boxed{\widehat{\mu} = \overline{X}_n, \quad \widehat{\sigma}^2 = \frac{1}{n} \sum X_i^2 - \overline{X}_n^2 = \sigma_n^2}$ (la versión con divisor n , no $n-1$ — el método de momentos entrega naturalmente el estimador sesgado).

5. **$\mathcal{U}[a,b]$** : $m_1=\frac{a+b}{2}$, $m_2-m_1^2 = \mathrm{Var}(X)=\frac{(b-a)^2}{12}$. Sea $\widehat{\sigma}_n^2 = \frac{1}{n} \sum X_i^2 - \overline{X}_n^2$ el segundo momento centrado muestral. De $(b-a)^2=12\widehat{\sigma}_n^2$ y $a+b=2\overline{X}_n$, resolviendo el sistema: $\boxed{\widehat{a} = \overline{X}_n - \sqrt{3}\widehat{\sigma}_n, \quad \widehat{b} = \overline{X}_n + \sqrt{3}\widehat{\sigma}_n}$ (pues $b-a=\sqrt{12}\widehat{\sigma}_n = 2\sqrt{3}\widehat{\sigma}_n$).

Ejercicio 3 — Vida útil de una pieza (Exponencial $\rightarrow$ Geométrica)

1. $X=[T]+1$, con $T \sim \mathrm{Exp}(\lambda)$. Por definición, $X=n \iff n-1 \leq T < n$:
 $P(X=n) = F_T(n) - F_T(n-1) = \left(1 - e^{-\lambda n}\right) - \left(1 - e^{-\lambda(n-1)}\right) = e^{-\lambda(n-1)} - e^{-\lambda n} = e^{-\lambda(n-1)} \big(1 - e^{-\lambda}\big)$.

Escribiendo $p=1-e^{-\lambda} \in (0,1)$: $P(X=n) = p(1-p)^{n-1}$ para $n=1,2,3,\dots$ — exactamente la función de probabilidad de $\mathrm{Geo}(p)$ con $p=1-e^{-\lambda}$. ■

2a. $\mu=E(X)=\frac{1}{1-e^{-\lambda}}$. Despejando λ : $1-e^{-\lambda}=\frac{1}{\mu} \rightarrow e^{-\lambda}=\frac{\mu-1}{\mu} \rightarrow \boxed{\lambda = \ln\left(\frac{\mu}{\mu-1}\right)} \quad (\mu>1, \text{ pues } p<1)$.

2b. Como $X_1, \dots, X_n$ son iid con $E(X_1)=\mu<\infty$, por LGN el estimador consistente natural de μ es la media muestral: $\boxed{\widehat{\mu} = \overline{X}_n} \rightarrow \text{c.s.}$

2c. Por 2a, $\lambda = g(\mu)$ con $g(x) = \ln\left(\frac{x}{x-1}\right)$, continua en $(1, \infty)$ en μ . Por el Práctico 8 Ej.2.3 aplicado a $\widehat{\mu} = \overline{X}_n$ $\xrightarrow{\text{c.s.}} \mu$: $\boxed{\widehat{\lambda} = \ln\left(\frac{\overline{X}_n}{\overline{X}_n - 1}\right)} \xrightarrow{\text{c.s.}} \lambda$ es un estimador consistente de λ (nótese: c.s. $\overline{X}_n > 1$ eventualmente, porque $\overline{X}_n \rightarrow \mu > 1$, así que $\widehat{\lambda}$ está bien definido para n suficientemente grande, con probabilidad 1).

Ejercicio 4 — Estimador por momentos con $E(X_1)=0$

$X \in \{-1, 0, 1\}$, $P(X = 1) = P(X = -1) = a$, $P(X = 0) = 1 - 2a$, $0 < a < 1/2$.

Observación clave: $E(X_1) = 1 \cdot a + (-1) \cdot a + 0 \cdot (1-2a) = 0$ — el primer momento no depende de a , así que el método de los momentos con m_1 es inútil aquí; hay que usar el **segundo momento**:

$$E(X^2) = 1^2 \cdot a + (-1)^2 \cdot a + 0^2 \cdot (1-2a) = 2a.$$

Igualando al segundo momento muestral $\frac{1}{n} \sum X_i^2$ y despejando:

$$\boxed{\widehat{a} = \frac{1}{2n} \sum_{i=1}^n X_i^2}$$

Consistencia: X_i^2 son iid con $E(X_1^2)=2a<\infty$, luego por LGN $\frac{1}{n}\sum X_i^2 \xrightarrow{c.s.} 2a$, y por el Práctico 8 Ej.2 (multiplicar por la constante $1/2$, caso particular de producto con sucesión determinística): $\widehat{a} \xrightarrow{c.s.} a$. ■

Verificación numérica ($a=0\{, \}2$, $n=50$, 300 000 réplicas): $E[\widehat{a}]$ simulado $=0\{, \}20004$ vs. teórico $0\{, \}2$ $\checkmark$.

Ejercicio 5 — Estimadores de máxima verosimilitud

1. $\mathrm{Ber}(p)$: $L(p) = \prod p^{x_i} (1-p)^{1-x_i}$, $\ell(p) = \ln L = \left(\sum x_i \right) \ln p + \left(n - \sum x_i \right) \ln (1-p)$. $\ell'(p) = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p} = 0$
 $\Rightarrow \boxed{\widehat{p}_{MLE} = \overline{X}_n} \quad (\text{text} = \text{MoM}).$

2. **$P(\lambda)$:** $\ell(\lambda) = -n\lambda + \left(\sum x_i\right)\ln\lambda - \sum \ln(x_i!)$. $\ell'(\lambda) = -n + \frac{\sum x_i}{\lambda} = 0$; $\Rightarrow$ $\boxed{\widehat{\lambda}_{MLE} = \overline{X}_n}$ $\Leftrightarrow$ (text = MoM).

3. **$\mathrm{Geo}(p)$** : $L(p) = \prod p(1-p)^{x_i-1} = p^n(1-p)^{\sum x_i - n}$. $\ell(p) = n \ln p + \left(\sum x_i - n\right) \ln(1-p)$, $\ell'(p) = \frac{n}{p} - \frac{\sum x_i - n}{1-p} = 0$. $\hat{p} = \frac{n}{\sum x_i}$; $\Rightarrow$; $\widehat{\mathrm{Geo}}$

$$p_{\text{MLE}} = \frac{n}{\sum x_i} = \frac{1}{\overline{X_n}} \quad (\text{MoM}).$$

4. $N(\mu, \sigma^2)$: resultado clásico, $\widehat{\mu}_{\text{MLE}} = \overline{X_n}$, $\widehat{\sigma^2}_{\text{MLE}} = \frac{1}{n} \sum (X_i - \overline{X_n})^2 = \sigma_n^2$ (= MoM en ambos casos).

5. $\text{mathcal{U}}[a, b]$: $L(a, b) = \left(\frac{1}{b-a}\right)^n$ si $a \leq X_{(1)}$ y $b \geq X_{(n)}$ (mín/máx muestral), y $L=0$ en otro caso. Para $a \leq X_{(1)}$ y $b \geq X_{(n)}$ fijos, L es **estrictamente decreciente en $(b-a)$** : crece al achicar el intervalo $[a, b]$ lo más posible sin violar las restricciones. El mínimo $(b-a)$ compatible con los datos es $b-a = X_{(n)} - X_{(1)}$, lo grado en: $\widehat{a}_{\text{MLE}} = X_{(1)}$, $\widehat{b}_{\text{MLE}} = X_{(n)}$.

⚠ Distinto del MoM (que da $\widehat{a} = \overline{X_n} - \sqrt{3}$, $\widehat{\sigma_n} = \overline{X_n} + \sqrt{3}$). Es el único caso de los 5 donde MLE y MoM **no coinciden** — vale la pena resaltarlo para el examen, ya que suele preguntarse explícitamente esta comparación. Además el MLE de $\theta = b$ en el caso análogo $U[0, \theta]$ (Ej. 9) resulta **sesgado** pero de menor ECM que el MoM (ver Ej. 9.2 y verificación numérica).

Ejercicio 6 — Sesgo de $\overline{X_n}$, σ_n^2 , s_n^2

$\overline{X_n}$ insesgado: $E(\overline{X_n}) = \frac{1}{n} \sum E(X_i) = \frac{1}{n} \cdot n \mu = \mu$. ■

σ_n^2 sesgado. Usamos $\sum_{i=1}^n (X_i - \overline{X_n})^2 = \sum X_i^2 - n \overline{X_n}^2$ (identidad algebraica estándar). Entonces:

- $E(\sum X_i^2) = n E(X_1^2) = n(\sigma^2 + \mu^2)$.
- $E(\overline{X_n}^2) = \text{Var}(\overline{X_n}) + E(\overline{X_n})^2 = \frac{\sigma^2}{n} + \mu^2$, luego $E(n \overline{X_n}^2) = \sigma^2 + n \mu^2$.

$$E(\sum (X_i - \overline{X_n})^2) = n(\sigma^2 + \mu^2) - (\sigma^2 + n \mu^2) = (n-1)\sigma^2.$$

$E(\sigma_n^2) = \frac{(n-1)}{n} \sigma^2 \neq \sigma^2$ — sesgado, con sesgo $E(\sigma_n^2) - \sigma^2 = -\frac{\sigma^2}{n} \rightarrow 0$ (asintóticamente insesgado).

s_n^2 insesgado: $s_n^2 = \frac{n}{n-1} \sigma_n^2 \rightarrow E(s_n^2) = \frac{n}{n-1} \cdot \frac{(n-1)}{n} \sigma^2 = \sigma^2$. ■ (Es exactamente la corrección de Bessel — la razón de dividir entre $n-1$.)

(Verificación numérica ya reportada en el Ejercicio 1: $\{397\}$ vs. $\{4\}$ y $\{996\}$ vs. $\{9\}$, con $n=15, \sigma=3$.)

Ejercicio 7 — Estimador lineal insesgado de varianza mínima

$\widehat{\mu} = \sum_{i=1}^n a_i X_i$, con X_i iid, $E(X_i) = \mu$, $\mathrm{Var}(X_i) = \sigma^2$.

1. Condición de insesgadez: $E(\widehat{\mu}) = \sum a_i E(X_i) = \mu \sum a_i$. Para que $E(\widehat{\mu}) = \mu$ para **todo** μ (no solo un valor particular), se necesita:
 $\boxed{\sum_{i=1}^n a_i = 1}$.

2. Varianza mínima entre estimadores lineales insesgados. Por independencia:
 $\mathrm{Var}(\widehat{\mu}) = \sum_{i=1}^n a_i^2 \mathrm{Var}(X_i) = \sigma^2 \sum_{i=1}^n a_i^2$. Hay que minimizar $\sum a_i^2$ sujeto a $\sum a_i = 1$. Por **Cauchy-Schwarz** en $\mathbb{R}^n$, con $\vec{a} = (a_1, \dots, a_n)$ y $\vec{1} = (1, \dots, 1)$: $\left(\sum_{i=1}^n a_i \cdot 1 \right)^2 \leq \left(\sum_{i=1}^n a_i^2 \right) \left(\sum_{i=1}^n 1^2 \right)$; $\Longrightarrow$ $1 \leq n \sum a_i^2$; $\Longrightarrow$ $\sum a_i^2 \geq \frac{1}{n}$, con **igualdad si y solo si** $\vec{a}$ es proporcional a $\vec{1}$ (condición de igualdad en Cauchy-Schwarz), es decir $a_i = c$ constante para todo i ; junto con $\sum a_i = 1$ se obtiene $c = 1/n$. Por lo tanto:
 $\boxed{a_i = \frac{1}{n} \text{ for all } i; \Longrightarrow \widehat{\mu} = \overline{X}_n, \quad \mathrm{Var}_{\min}(\widehat{\mu}) = \frac{\sigma^2}{n}}$

Es decir: **entre todos los estimadores lineales e insesgados de μ , la media muestral $\overline{X}_n$ es el de menor varianza** (caso particular del teorema de Gauss-Markov). ■

Verificación numérica ($\sigma=3, n=10$): $\mathrm{Var}(\overline{X}_n) = \sigma^2/n = 0.9$; comparado con un estimador insesgado alternativo que usa solo 5 de las 10 observaciones ($a_i = 1/5$ en 5 de ellas, 0 en el resto — sigue cumpliendo $\sum a_i = 1$): varianza $= 1.8$, es decir el doble — confirma que $\overline{X}_n$ domina. ✓

Ejercicio 8 — Estimadores para $\mathcal{P}(\lambda)$

$X_1, \dots, X_n$ iid $\sim \mathcal{P}(\lambda)$ (recordar $E(X_1) = \mathrm{Var}(X_1) = \lambda$).

1. Por el Ejercicio 2.2, $\widehat{\lambda}_{\mathrm{MoM}} = \overline{X}_n$. Por el Ejercicio 6, $E(\overline{X}_n) = \mu = \lambda$ (aquí $\mu = \lambda$) — **insesgado**. ■

2. s_n^2 es insesgado para $\mathrm{Var}(X_1) = \sigma^2$ **en general**, independientemente de la distribución (Ejercicio 6, la prueba solo usa $E(X_1) = \mu, \mathrm{Var}(X_1) = \sigma^2$ finitos — nunca se usó normalidad ni forma de la distribución). Como para $\mathcal{P}(\lambda)$ se tiene $\sigma^2 = \lambda$: $E(s_n^2) = \sigma^2 = \lambda$; $\rightarrow$; s_n^2 es insesgado para λ . $\square$

3. MLE ya calculado en Ejercicio 5.2: $\widehat{\lambda}_{\text{MLE}} = \overline{X}_n$, **coincide exactamente** con el MoM. $\blacksquare$

Verificación numérica ($\lambda=4, n=20, 300\,000$ réplicas): $E[\overline{X}_n] = 3.9992$ vs. 4 ✓; $E[s_n^2] = 3.9983$ vs. 4 ✓.

Ejercicio 9 — $\mathcal{U}[0, \theta]$: MoM vs. MLE

$X_1, \dots, X_n$ iid $\sim \mathcal{U}[0, \theta]$. $E(X_1) = \theta/2$, $\mathrm{Var}(X_1) = \theta^2/12$.

1. **MoM**: $E(X_1) = \theta/2 = m_1 \rightarrow \boxed{\widehat{\theta}_{\text{MoM}} = 2\overline{X}_n}$.

2. **Sesgo, varianza, ECM del MoM.**

- **Sesgo**: $E(\widehat{\theta}_{\text{MoM}}) = 2E(\overline{X}_n) = 2 \cdot \frac{\theta}{2} = \theta$ — **insesgado**.
- **Varianza**: $\mathrm{Var}(\widehat{\theta}_{\text{MoM}}) = 4 \cdot \mathrm{Var}(\overline{X}_n) = 4 \cdot \frac{\mathrm{Var}(X_1)}{n} = 4 \cdot \frac{\theta^2/12}{n} = \frac{\theta^2}{3n}$.
- **ECM** (= Varianza, pues es insesgado): $\mathrm{ECM}(\widehat{\theta}_{\text{MoM}}) = \frac{\theta^2}{3n}$.

3. **MLE es el máximo muestral**. $L(\theta) = \prod_i \frac{1}{\theta} \mathbb{1}_{\{0 \leq x_i \leq \theta\}} = \frac{1}{\theta^n} \mathbb{1}_{\{\theta \geq \max_i x_i\}}$. Para $\theta \geq X_{(n)}^* = \max\{X_1, \dots, X_n\}$, $L(\theta) = \frac{1}{\theta^n}$ es **estrictamente decreciente en θ** , así que se maximiza en el menor θ admisible: $\boxed{\widehat{\theta}_{\text{MLE}} = X_{(n)}^* = \max\{X_1, \dots, X_n\}}$. $\square$

Comentario adicional (fuera de lo pedido, útil para el examen — el sesgo/ECM del MLE):

se puede calcular con la densidad del máximo, $f_{X_{(n)}}(x) = n x^{n-1} / \theta^n$ en $[0, \theta]$: $E(X_{(n)}) = \frac{n}{n+1} \theta$ ($\Rightarrow$ **sesgado**, subestima sistemáticamente), $\mathrm{Var}(X_{(n)}) = \frac{n}{(n+1)^2(n+2)} \theta^2$, y su ECM resulta

$$\mathrm{ECM}(\widehat{\theta}_{\text{MLE}}) = \mathrm{Var} + \text{sesgo}^2 = \frac{n \theta^2}{(n+1)^2(n+2)} + \left(\frac{\theta}{n+1}\right)^2 = \frac{2 \theta^2}{(n+1)(n+2)}.$$

Comparando con $\mathrm{ECM}(\widehat{\theta}_{\text{MoM}}) = \theta^2/(3n)$: para $n=20, \theta=10$ da $\mathrm{ECM}\{MLE\} \approx 0{,}433$ vs. $\mathrm{ECM}\{\text{MoM}\} \approx 1{,}667$ — **el MLE, aunque sesgado, tiene ECM muchísimo menor** que el MoM insesgado. Es un buen ejemplo concreto de que “insesgado” no implica “mejor estimador” (trade-off sesgo-varianza).

Verificación numérica ($\theta=10, n=20$, 300 000 réplicas):

- MoM: $E=10{,}0047$ (teórico 10) ✓, $\mathrm{Var}=1{,}663$ (teórico $\theta^2/(3n)=1{,}667$) ✓.
 - MLE: $E=9{,}524$ (teórico $\frac{n}{n+1}\theta=9{,}524$) ✓, $\mathrm{Var}=0{,}2062$ (teórico $0{,}2061$) ✓, $\mathrm{ECM}=0{,}4328$ (teórico $0{,}4329$) ✓ — todo cuadra perfecto con las fórmulas cerradas.
-

Resumen de técnicas usadas en estos prácticos

Ejercicio	Técnica
P8.1	Chebyshev + cota universal $p(1-p) \leq 1/4$ para tamaño de muestra “distribution-free”
P8.2	Álgebra de límites c.s. = álgebra de límites reales aplicada punto a punto en un conjunto de prob. 1
P8.3	LGN aplicada a $f(U_i)$ o a $\mathbb{1}_{\{U_i \in D\}}$ — método de Montecarlo
P8.4	Reescribir sumas dependientes en términos de sumas iid + lema $X_n/n \rightarrow 0$ c.s. (consecuencia de LGN)
P8.5	LGN + argumento de ε -vecindad para divergencia a $+\infty$
P8.6	LGN + funciones continuas (x^2) aplicadas a $\overline{X_n}$ vs. a $\overline{X_n^2}$
P9.1	Identidad $\sigma_n^2 = \overline{X^2} - \overline{X}^2$ + LGN + composición con funciones continuas (Ej.2 P8)
P9.2, P9.5	Método de momentos vs. máxima verosimilitud (coinciden salvo en $\mathcal{U}[a,b]$)
P9.3	Cambio de variable Exp $\rightarrow$ Geo, consistencia por composición con función continua
P9.4	Momento de orden 2 cuando el de orden 1 no identifica al parámetro
P9.6, P9.8	Cálculo exacto de $E(\sigma_n^2)$ vs. $E(s_n^2)$ — corrección de Bessel
P9.7	Cauchy-Schwarz para varianza mínima entre estimadores lineales insesgados (Gauss-Markov)
P9.9	Comparación sesgo/varianza/ECM: insesgado (MoM) vs. sesgado de menor ECM (MLE)

Para el examen: el hilo conductor de estos dos prácticos es que la **convergencia casi segura hereda todas las propiedades algebraicas de los límites de sucesiones reales** (P8 Ej.2), y esa es la única herramienta que hace falta para demostrar consistencia de estimadores compuestos (P9 Ej.1, 3): basta descomponer el estimador en operaciones (suma, producto, composición con función continua) de cosas que ya convergen c.s. por LGN. La segunda idea transversal es la **distinción sesgo vs. ECM**: un estimador insesgado no es automáticamente el

mejor (P9 Ej.9); y **MoM y MLE coinciden en las familias exponenciales estándar (Bernoulli, Poisson, Geométrica, Normal) pero no en la Uniforme**, donde el MLE usa estadísticos de orden (min/máx) en vez de momentos — es la comparación que más se pregunta en parciales.

Script de verificación

Todas las verificaciones numéricas reportadas arriba (Monte Carlo, sesgo/varianza de estimadores, comparación MoM/MLE) se generaron con `numpy` / `scipy` en Python 3.12, semillas fijas para reproducibilidad. Resultados completos:

```
P8 Ej3.1: teorico E[f(U)]=0.66333 estimado=0.66346
P8 Ej3.2: area teorica=0.78540 estimado=0.78520
P8 Ej4: Ybar en n=1e3..5e5: 0.0142, 0.0035, 0.0008, -0.0012 (-> 0)
P8 Ej5: Sn/n en n=1e3..2e5: ~0.973..1.00 (-> a=1, Sn -> +inf)
P8 Ej6: (Xbar)^2=0.24989 (teo 0.25); Xbar(X^2)=0.49989 (teo 0.5)
P9 Ej1.2: E[sigma_n^2]=8.397 (teo 8.4); E[s_n^2]=8.996 (teo 9)
P9 Ej4: E[a_hat]=0.20004 (teo 0.2)
P9 Ej7: Var(Xbar)=0.9 vs Var(estimador con 5/10 obs)=1.8
P9 Ej8: E[Xbar]=3.9992 (teo 4); E[s_n^2]=3.9983 (teo 4)
P9 Ej9: MoM: E=10.005 Var=1.663 (teo 10, 1.667)
      MLE: E=9.524 Var=0.2062 ECM=0.4328 (teo 9.524, 0.2061, 0.4329)
```