

CONTENTS

Axiomas de Kolmogorov y Probabilidad Condicional	
Guía de estudio con tolerancia cero — Temas 1.2 y 1.3, Probabilidad y Estadística (FING UdelaR)	
0. Por qué existen estos temas	
1. Los axiomas de Kolmogorov	
2. Propiedades derivadas de los axiomas	
2.1 — $P(\emptyset) = 0$	
2.2 — Complemento: $P(A^c) = 1 - P(A)$	
2.3 — Regla de la resta y monotonía	
2.4 — División en casos (partición finita)	
2.5 — Inclusión-exclusión (2 eventos)	
2.6 — Cota de la unión (desigualdad de Boole, 2 eventos)	
2.7 — Desigualdad de Boole general (n eventos) y cota de la unión ∞ -numerable	
3. Espacios equiprobables y probabilidades geométricas	
3.1 — Espacios equiprobables (casos favorables/posibles)	
3.2 — Probabilidades geométricas	
3.3 — Ejemplo de modelo discreto no equiprobable	
4. Probabilidad condicional	
4.1 — Definición	
4.2 — Regla del producto (regla de la multiplicación)	

5. Partición del espacio y probabilidad total	
6. Teorema de Bayes	
6.1 — Enunciado y demostración	
6.2 — Ejemplo clásico: test médico con falsos positivos/negativos	
6.3 — Segundo ejemplo: urnas con Bayes	
7. Independencia de eventos	
7.1 — Definición	
7.2 — Independencia por pares vs. independencia mutua	
7.3 — Independencia condicional	
8. Trampas típicas de examen	
Tabla de referencia rápida	
Resumen ultra-rápido (2 minutos)	

Axiomas de Kolmogorov y Probabilidad Condicional

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMAS 1.2 Y 1.3, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existen estos temas

Antes de Kolmogorov (1933), “probabilidad” era una palabra intuitiva sin una base matemática común: distintos autores discutían sobre paradojas (como la de Bertrand) porque cada uno tenía una idea distinta de qué significa “elegir al azar”. Kolmogorov resolvió esto reduciendo toda la teoría a **4 reglas mínimas** (los axiomas) de las que se deduce *todo* lo demás: complementos, uniones, particiones, inclusión-exclusión. Esta es la razón por la que el examen pide tan seguido “demostrar a partir de los axiomas” — quiere ver que entendés que estas propiedades no son “trucos” sueltos, sino consecuencias lógicas de 3-4 reglas.

La **probabilidad condicional** (Tema 1.3) resuelve el problema inverso y más común en la práctica: casi nunca calculamos probabilidades “desde cero”, sino que *actualizamos* una probabilidad cuando llega información nueva (“dado que salió tal cosa, ¿qué tan probable es tal otra?”). El **Teorema de Bayes** es la herramienta que permite invertir el sentido de esa información — de “ $P(\text{síntoma} \mid \text{enfermedad})$ ” (que sabe el médico por estudios clínicos) a “ $P(\text{enfermedad} \mid \text{síntoma})$ ” (que es lo que realmente le interesa al paciente). Es, con diferencia, el resultado más citado de todo el curso fuera del ámbito académico (diagnóstico médico, spam, IA, justicia), y también el que más errores de examen genera, porque el error más común — confundir $P(A|B)$ con $P(B|A)$ — es exactamente el tipo de error que la gente comete todos los días fuera de la facultad.

Regla de oro que atraviesa TODO este documento: la probabilidad condicional **no es una fórmula nueva**, es la **misma** probabilidad P , pero aplicada a un espacio muestral **reducido** (el evento condicionante B pasa a jugar el papel de “todo” el espacio). Por eso $P(\cdot|B)$ cumple los axiomas de Kolmogorov igual que P : todo lo que ya sabés de probabilidad (inclusión-exclusión, complemento, etc.) también vale condicionando.

1. Los axiomas de Kolmogorov

Definición. Sea Ω un espacio muestral. Una probabilidad es una función P que a cada evento A le asigna un número real $P(A) \in [0, 1]$, cumpliendo:

- **Ax.1:** $P(A) \geq 0$ para cualquier evento A .
- **Ax.2:** $P(\Omega) = 1$.
- **Ax.3:** $P(A \cup B) = P(A) + P(B)$ si A y B son **incompatibles** ($A \cap B = \emptyset$).
- **Ax.4 (continuidad):** si $\{A_k\}$ es una sucesión **creciente** de eventos ($A_1 \subset A_2 \subset A_3 \subset \dots$), entonces $P(\lim_{k \rightarrow \infty} A_k) = \lim_{k \rightarrow \infty} P(A_k)$, donde $\lim_{k \rightarrow \infty} A_k := \bigcup_k A_k$.

Forma equivalente (la que más se usa para demostrar): Ax.1, Ax.2, y **Ax.3(∞)**: si $\{A_k\}$ son incompatibles dos a dos (no solo de a pares consecutivos, sino cualquier par $i \neq k$), entonces $P(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} P(A_k)$. Se puede probar que $\{\text{Ax.1, Ax.2, Ax.3, Ax.4}\} \Leftrightarrow \{\text{Ax.1, Ax.2, Ax.3}(\infty)\}$ — son dos formas de escribir exactamente la misma teoría. Si Ω es finito, Ax.4 se cumple automáticamente y solo hace falta trabajar con Ax.1-Ax.3.

Error de tolerancia cero: el Ax.3 (aditividad) SOLO aplica a eventos **incompatibles** ($A \cap B = \emptyset$). Escribir $P(A \cup B) = P(A) + P(B)$ para dos eventos cualesquiera es un error grave — la fórmula general es inclusión-exclusión (ver sección 2.5), que resta $P(A \cap B)$ precisamente para corregir este caso.

2. Propiedades derivadas de los axiomas

Todas se demuestran **solo** a partir de Ax.1–Ax.3 (más Ax.4/Ax.3(∞) cuando se indica). El examen pide reproducir estas demostraciones cortas de memoria.

2.1 — $P(\emptyset) = 0$

Demostración. Ω y $\emptyset$ son incompatibles ($\Omega \cap \emptyset = \emptyset$) y $\Omega \cup \emptyset = \Omega$. Por Ax.3: $P(\Omega) = P(\Omega) + P(\emptyset)$, y por Ax.2, $P(\Omega) = 1$, así que $1 = 1 + P(\emptyset) \Rightarrow P(\emptyset) = 0$. ■

2.2 — COMPLEMENTO: $P(A^c) = 1 - P(A)$

Demostración. $A \cup A^c = \Omega$ y esta unión es disjunta ($A \cap A^c = \emptyset$). Por Ax.3 y Ax.2: $1 = P(\Omega) = P(A) + P(A^c) \Rightarrow P(A^c) = 1 - P(A)$. ■

2.3 — REGLA DE LA RESTA Y MONOTONÍA

Si $A \subset B$, entonces $P(B \setminus A) = P(B) - P(A)$, y por lo tanto $P(A) \leq P(B)$.

Demostración. $B = A \cup (B \setminus A)$ es una unión disjunta (todo lo que está en $B \setminus A$, por definición, no está en A). Por Ax.3: $P(B) = P(A) + P(B \setminus A) \Rightarrow P(B \setminus A) = P(B) - P(A)$. Como $P(B \setminus A) \geq 0$ (Ax.1), se sigue $P(A) \leq P(B)$. ■

Corolario inmediato: junto con Ax.1 y Ax.2, la monotonía implica $0 \leq P(A) \leq 1$ para todo evento A (tomando $B = \Omega$).

2.4 — DIVISIÓN EN CASOS (PARTICIÓN FINITA)

Si $C_1, \dots, C_n$ son disjuntos dos a dos y cubren Ω (una partición), entonces para cualquier evento A :

$$P(A) = \sum_{i=1}^n P(A \cap C_i)$$

Demostración. $A = \bigcup_i (A \cap C_i)$ es una unión disjunta (los $A \cap C_i$ heredan la disjunción de los C_i). Aplicar Ax.3 (extendido por inducción a n eventos). ■

Esta propiedad es la semilla de la fórmula de la **probabilidad total** (sección 6).

2.5 — INCLUSIÓN-EXCLUSIÓN (2 EVENTOS)

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración. Descomponer $A \cup B$ en 3 piezas disjuntas: $A \cup B = [A \setminus (A \cap B)] \cup [B \setminus (A \cap B)] \cup [A \cap B]$. Por Ax.3 (extendido a 3 términos) y la regla de la resta (2.3) aplicada a $A \cap B \subset A$ y $A \cap B \subset B$: $P(A \cup B) = [P(A) - P(A \cap B)] + [P(B) - P(A \cap B)] + P(A \cap B) = P(A) + P(B) - P(A \cap B)$. ■

2.6 — COTA DE LA UNIÓN (DESIGUALDAD DE BOOLE, 2 EVENTOS)

$$P(A \cup B) \leq P(A) + P(B)$$

Demostración. Consecuencia directa de 2.5, ya que $P(A \cap B) \geq 0$ (Ax.1). ■

Ejemplo 2.1 — Inclusión-exclusión con 3 eventos (deducción).

Aplicando 2.5 dos veces (tratando $A \cup B$ como un solo evento): $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$ **Verificación con números:** $P(A)=0.5$, $P(B)=0.4$, $P(C)=0.3$, $P(A \cap B)=0.2$, $P(A \cap C)=0.15$, $P(B \cap C)=0.1$, $P(A \cap B \cap C)=0.05$.

$P(A \cup B \cup C) = 0.5 + 0.4 + 0.3 - 0.2 - 0.15 - 0.1 + 0.05 = \mathbf{0.8}$. Verificación en Python (partición del espacio en las 8 regiones del diagrama de Venn, sumando directamente): da 0.8 ✓ (ver código en la sección 2.7).

2.7 — DESIGUALDAD DE BOOLE GENERAL (N EVENTOS) Y COTA DE LA UNIÓN ∞ -NUMERABLE

Por inducción, extendiendo 2.6: para $A_1, \dots, A_n$ eventos cualesquiera,

$$P\left(\bigcup_{n=1}^m A_n\right) \leq \sum_{n=1}^m P(A_n)$$

Y usando Ax.4/Ax.3(∞) se extiende a una cantidad numerable de eventos: $P(\cup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} P(A_n)$ (este es, de hecho, el Ejercicio 10 del Práctico 2 — ver la resolución).

Truco de verificación universal: cuando el enunciado te da datos “raros” con inclusión-exclusión de 3 eventos, siempre podés verificar armando las 8 regiones disjuntas del diagrama de Venn (Aonly, Bonly, Conly, AB solo, AC solo, BC solo, ABC, ninguno) y chequeando que suman exactamente 1. Código de verificación:

```
from itertools import product
PA,PB,PC = 0.5,0.4,0.3
PAB,PAC,PBC = 0.2,0.15,0.1
PABC = 0.05
P_AuBuC = PA+PB+PC-PAB-PAC-PBC+PABC
print(P_AuBuC) # 0.8
```

Error frecuente de tolerancia cero: en inclusión-exclusión de 3 eventos, olvidar el signo final “ $+P(A \cap B \cap C)$ ” (queda restado dos veces si no se lo vuelve a sumar) — es el error de conteo por inclusión-exclusión más común en el curso, análogo al de combinatoria.

3. Espacios equiprobables y probabilidades geométricas

3.1 — ESPACIOS EQUIPROBABLES (CASOS FAVORABLES/POSIBLES)

Si Ω es finito con n elementos igualmente probables ($p_i = 1/n$ para todo i), entonces para cualquier evento A :

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{casos favorables}}{\text{casos posibles}}$$

Esta fórmula **no es un axioma nuevo**: es un caso particular del modelo general de probabilidades discretas (asignar $p_i = 1/n$ a cada resultado elemental) que automáticamente cumple Ax.1-Ax.3. La condición de normalización $\sum p_i = 1$ es lo único que hace falta verificar al definir un modelo de probabilidad discreto no necesariamente equiprobable (ver el ejemplo del dado cargado, sección 3.3).

3.2 — PROBABILIDADES GEOMÉTRICAS

Cuando el espacio muestral es un continuo (un segmento, un círculo, una región del plano) no tiene sentido “contar” casos, pero se puede seguir usando la misma idea con **longitudes o áreas** en vez de cardinales:

$$P(A) = \frac{\text{long}(A)}{\text{long}(\Omega)} \quad \text{ó} \quad P(A) = \frac{\text{Área}(A)}{\text{Área}(\Omega)}$$

Esta fórmula es la **única** función que cumple simultáneamente $P(\text{long total})=1$, $P \geq 0$, y aditividad sobre trozos disjuntos de un segmento — se puede demostrar rigurosamente (ver Carrasco, Clase 2) que si “al azar” significa “la probabilidad de un sub-intervalo depende solo de su longitud, no de su posición”, entonces necesariamente $P(CD) = \text{long}(CD)/\text{long}(AB)$. No es una convención arbitraria.

Ejemplo 3.1 — Barra que se rompe (probabilidad geométrica 1D).

Una barra de longitud L se rompe en un punto al azar. ¿Cuál es la probabilidad de que la pieza más chica mida más de $L/4$?

$\Omega = [0, L]$ (punto de ruptura). El evento ocurre si el punto de ruptura cae en el segmento central $(L/4, 3L/4)$, de longitud $L/2$.

$$P(A) = (L/2)/L = 1/2.$$

Verificación Monte Carlo ($L=1$, un millón de puntos uniformes en $[0, 1]$):

```
import random
N = 1_000_000
count = 0
for _ in range(N):
    x = random.random()           # punto de ruptura en [0,1]
    pieza_chica = min(x, 1-x)
    if pieza_chica > 0.25:
        count += 1
print(count/N)  # converge a 0.5
```


Resultado de la simulación: ≈ 0.4996 , consistente con $1/2$ ✓.

Ejemplo 3.2 — Dardo en un cuadrado (probabilidad geométrica 2D).

Se elige un número a al azar en $(-1, 1)$. ¿Cuál es la probabilidad de que $ax^2+x+1=0$ tenga 2 raíces reales?

$\Omega=(-1, 1)$, $\text{long}(\Omega)=2$. Hay 2 soluciones reales $\Leftrightarrow$ discriminante $1-4a>0 \Leftrightarrow a<1/4$. El evento es $A=(-1, 1/4)$, $\text{long}(A)=5/4$.

$P(A) = (5/4)/2 = 5/8 = 0.625$.

Verificación Monte Carlo:

```
import random
N = 1_000_000
count = 0
for _ in range(N):
    a = random.uniform(-1, 1)
    disc = 1 - 4*a
    if disc > 0:
        count += 1
print(count/N) # converge a 0.625
```

Resultado: ≈ 0.6253 , consistente con $5/8$ ✓.

3.3 — EJEMPLO DE MODELO DISCRETO NO EQUIPROBABLE

Ejemplo 3.3 — Dado cargado (Práctico 2, Ej.7).

$P(i) = \alpha i$ para $i=1, \dots, 6$. Normalización: $\sum_{i=1}^6 \alpha i = \alpha(1+2+\dots+6) = 21\alpha = 1 \Rightarrow \alpha=1/21$.

$P(\text{sacar } 5) = 5\alpha = 5/21$. $P(\text{sacar par}) = P(2)+P(4)+P(6) = (2+4+6)\alpha = 12\alpha = 12/21 = 4/7$.

Verificación: $\sum_{i=1}^6 P(i) = 21 \times (1/21) = 1$ ✓ (condición de normalización de un espacio discreto no equiprobable, sección 3.1).

4. Probabilidad condicional

4.1 — DEFINICIÓN

Sean A, B eventos con $P(B) > 0$. La **probabilidad condicional de A dado B** es:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

Representa “la probabilidad de A, sabiendo que B ya ocurrió” — equivale a reducir el espacio muestral a B y renormalizar (dividir entre $P(B)$ para que el nuevo espacio tenga probabilidad total 1).

$P(\cdot|B)$ es, ella misma, una probabilidad (cumple los 3 axiomas de Kolmogorov en el rol de P): $P(\Omega|B)=1$, $P(A|B)\geq 0$, y $P(\cup A_n|B)=\sum P(A_n|B)$ para A_n disjuntos. Por eso **todas** las propiedades de la sección 2 (complemento, inclusión-exclusión, etc.) valen también condicionando: $P(A^c|B) = 1-P(A|B)$, $P(A \cup C|B)=P(A|B)+P(C|B)-P(A \cap C|B)$, etc.

Error de tolerancia cero — la falacia del fiscal (“prosecutor’s fallacy”): $P(A|B) \neq P(B|A)$ EN GENERAL. Son cantidades distintas que solo coinciden en casos especiales. Contraejemplo simple: lanzamiento de un dado, $A=\{\text{sale } 6\}$, $B=\{\text{sale par}\}$. $P(A|B) = 1/3$ (de los 3 resultados pares, uno es 6). $P(B|A) = 1$ (si salió 6, seguro que es par). Claramente $1/3 \neq 1$. Confundir estas dos cantidades es el error más citado en la literatura de probabilidad aplicada al derecho — de ahí el nombre: un fiscal que argumenta “P(evidencia | inocente) es bajísima, entonces P(inocente | evidencia) es bajísima” está cometiendo exactamente este error (ver sección 8, falacia de la frecuencia base).

4.2 — REGLA DEL PRODUCTO (REGLA DE LA MULTIPLICACIÓN)

Despejando $P(A \cap B)$ de la definición:

$$P(A \cap B) = P(B)P(A|B), P(A \cap B) = P(A)P(B|A)$$

Generalización a n eventos (regla de la cadena): si $P(A_1 \cap \dots \cap A_{n-1}) > 0$,

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$$

Demostración (por inducción / telescópico): cada factor de la derecha es, por la definición de probabilidad condicional, exactamente $P(A_1 \cap \dots \cap A_k) / P(A_1 \cap \dots \cap A_{k-1})$. Al multiplicar todos los factores consecutivos se cancelan todos los numeradores con los denominadores del término siguiente, dejando solo $P(A_1 \cap \dots \cap A_n)$ en el numerador final y $P(A_1)$ sin cancelar en el denominador... que también se cancela porque el primer factor es $P(A_1)$ sin dividir. Queda exactamente $P(A_1 \cap \dots \cap A_n)$. ■

Ejemplo 4.1 — Regla de la cadena: 2 cartas de un mazo (Clase 4, Ej.4).

S_1 ="primera carta es ♠", S_2 ="segunda carta es ♠". $P(S_1)=13/52$. Dado que la primera fue ♠,

quedan 12 ♠ entre 51 cartas: $P(S_2|S_1)=12/51$.

$P(S_1 \cap S_2) = (13/52)(12/51) = 3/51 \approx 0.0588$.

Verificación Monte Carlo (simulando mazos de 52 cartas, 13 de cada palo):

```
import random
palos = ["picas"]*13 + ["otro"]*39
N = 500_000
count = 0
for _ in range(N):
    mazo = palos[:]
    random.shuffle(mazo)
    if mazo[0]=="picas" and mazo[1]=="picas":
        count += 1
print(count/N)    # converge a 3/51 ~ 0.0588
```

Error de tolerancia cero: usar la regla del producto **simplificada** $P(A \cap B) = P(A)P(B)$ sin haber verificado (o sin que el enunciado lo diga explícitamente) que A y B son independientes. La regla del producto **general** siempre lleva la condicional: $P(A \cap B) = P(A)P(B|A)$. Solo se simplifica a $P(A)P(B)$ en el caso particular de independencia (sección 7).

5. Partición del espacio y probabilidad total

Definición de partición. $C_1, C_2, \dots$ es una partición de Ω si son disjuntos dos a dos ($C_i \cap C_j = \emptyset$ para $i \neq j$) y su unión es todo Ω ($\bigcup_i C_i = \Omega$), con $P(C_i) > 0$ para cada i .

Fórmula de la probabilidad total. Sea A un evento cualquiera:

$$P(A) = \sum_i P(A \mid C_i) P(C_i)$$

Demostración. Por la propiedad 2.4 (división en casos), $P(A) = \sum_i P(A \cap C_i)$. Por la regla del producto (4.2), $P(A \cap C_i) = P(A|C_i)P(C_i)$. Sustituyendo se obtiene la fórmula. ■

Esta fórmula es exactamente la que se visualiza con un **árbol de probabilidades**: cada C_i es una rama del primer nivel (con probabilidad $P(C_i)$), y de cada rama sale otra con probabilidad $P(A|C_i)$. El valor de $P(A)$ es la suma de los productos de las probabilidades a lo largo de cada camino que termina en “A ocurre”.

Ejemplo 5.1 — Urna con reposición condicional al color extraído.

Una urna tiene 5 bolas rojas y 2 verdes. Se extrae una bola; si es verde se agrega una roja a la urna, si es roja se agrega una verde (la bola extraída no vuelve). Se extrae una segunda bola. ¿ $P(\text{segunda es roja})$?

Partición: R_1 ="primera roja" ($P=5/7$), V_1 ="primera verde" ($P=2/7$).

$P(R_2|R_1)=4/7$ (quedan 4R, 2V+1V=3V, total 7). $P(R_2|V_1)=6/7$ (quedan 5R+1R=6R, 1V, total 7).

$P(R_2) = (4/7)(5/7) + (6/7)(2/7) = 20/49 + 12/49 = \mathbf{32/49 \approx 0.653}$.

Verificación Monte Carlo:

```
import random
N = 500_000
count = 0
for _ in range(N):
    urna = ["R"]*5 + ["V"]*2
    i1 = random.randrange(len(urna))
    c1 = urna.pop(i1)
    urna.append("R" if c1=="V" else "V")
    i2 = random.randrange(len(urna))
    c2 = urna[i2]
    if c2=="R":
        count += 1
print(count/N) # converge a 32/49 ~ 0.653
```

Resultado de la simulación: ≈ 0.6531 , consistente con $32/49 \checkmark$.

6. Teorema de Bayes

6.1 — ENUNCIADO Y DEMOSTRACIÓN

Fórmula de inversión. De la regla del producto (4.2), $P(A \cap B)$ tiene dos expresiones equivalentes:

$$P(A \mid B), P(B) = P(A \cap B) = P(B \mid A), P(A) \quad \Longleftrightarrow \quad P(A \mid B) = \frac{P(B \mid A), P(A)}{P(B)}$$

Teorema de Bayes (forma general con partición). Sea $C_1, C_2, \dots$ una partición de Ω y A un evento con $P(A) > 0$:

$$P(C_k \mid A) = \frac{P(C_k), P(A \mid C_k)}{\sum_i P(C_i), P(A \mid C_i)}$$

Demostración. El numerador es $P(A|C_k)P(C_k) = P(A \cap C_k) = P(C_k|A)P(A)$ por la fórmula de inversión, así que $P(C_k|A) = P(A|C_k)P(C_k)/P(A)$. El denominador se reescribe usando la fórmula de la probabilidad total (sección 5): $P(A) = \sum_i P(A|C_i)P(C_i)$. ■

Bayes “invierte” el sentido de la condicionalidad: parte de las probabilidades **directas** $P(A|C_i)$ (que suelen ser datos del enunciado, por ejemplo la sensibilidad de un test médico) y devuelve la probabilidad **inversa** $P(C_k|A)$ (lo que realmente interesa, por ejemplo “¿tengo la enfermedad dado que el test dio positivo?”). C_k se llama probabilidad **a priori** antes de conocer A , y $P(C_k|A)$ la probabilidad **a posteriori**.

6.2 — EJEMPLO CLÁSICO: TEST MÉDICO CON FALSOS POSITIVOS/NEGATIVOS

Ejemplo 6.1 — Test de una enfermedad rara.

Una enfermedad afecta al 1% de la población. Un test tiene sensibilidad 99% ($P(+|Enfermo)=0.99$) y especificidad 95% ($P(-|Sano)=0.95$, es decir $P(+|Sano)=0.05$, un 5% de falsos positivos). Si una persona da positivo, ¿cuál es la probabilidad de que esté realmente enferma?

Partición: E =“enfermo” ($P=0.01$), E^c =“sano” ($P=0.99$).

$$P(+) = P(+|E)P(E) + P(+|E^c)P(E^c) = 0.99 \times 0.01 + 0.05 \times 0.99 = 0.0099 + 0.0495 = 0.0594.$$

$P(E|+) = \frac{0.99 \times 0.01}{0.0594} = \frac{0.0099}{0.0594} = \frac{1}{6} \approx 0.1667$ Aunque el test es “99% sensible”, solo **1 de cada 6** personas que dan positivo está realmente enferma — porque la enfermedad es rara (1%) y el 5% de falsos positivos, aplicado a la enorme mayoría sana de la población, genera muchos más falsos positivos en términos absolutos que verdaderos positivos. Esta es la **falacia de la frecuencia base** (ver sección 8).

Verificación Monte Carlo (2 millones de personas simuladas):

```

import random
prev, sens, esp = 0.01, 0.99, 0.95
N = 2_000_000
pos = 0; enfermo_y_pos = 0
for _ in range(N):
    enfermo = random.random() < prev
    if enfermo:
        positivo = random.random() < sens
    else:
        positivo = random.random() < (1 - esp)
    if positivo:
        pos += 1
        if enfermo:
            enfermo_y_pos += 1
print(enfermo_y_pos / pos) # converge a 1/6 ~ 0.1667

```

Resultado real de la simulación: **0.1672** sobre 118 612 positivos simulados — consistente con el valor teórico $1/6 \checkmark$.

6.3 — SEGUNDO EJEMPLO: URNAS CON BAYES

Ejemplo 6.2 — ¿De qué urna vino la bola?

Urnas: 1: 3 rojas y 7 azules. Urna 2: 6 rojas y 4 azules. Se elige una urna al azar (50/50) y se extrae una bola, que resulta roja. ¿Cuál es la probabilidad de que haya sido la urna 1? $P(U_1)=P(U_2)=0.5$. $P(\text{roja}|U_1)=0.3$, $P(\text{roja}|U_2)=0.6$.

$P(\text{roja}) = 0.5 \times 0.3 + 0.5 \times 0.6 = 0.15 + 0.3 = 0.45$.

$$P(U_1 | \text{roja}) = \frac{0.5 \times 0.3}{0.45} = \frac{0.15}{0.45} = \frac{1}{3}$$

Tiene sentido: la urna 2 tiene el doble de proporción de rojas, así que es más probable que la bola roja haya salido de ahí ($P(U_2|\text{roja})=2/3$, el doble que $P(U_1|\text{roja})=1/3$).

Verificación Monte Carlo (1 millón de repeticiones): resultado ≈ 0.3337 , consistente con $1/3 \checkmark$.

7. Independencia de eventos

7.1 — DEFINICIÓN

Dos eventos A y B son **independientes** si

$$P(A \cap B) = P(A) \cdot P(B)$$

Equivalencia con probabilidad condicional (cuando $P(B) > 0$): A y B son independientes $\Leftrightarrow P(A|B) = P(A)$ — es decir, saber que B ocurrió no cambia en nada la probabilidad de A. Se deduce directamente de la definición de probabilidad condicional: $P(A|B) = P(A \cap B)/P(B) = P(A)P(B)/P(B) = P(A)$.

Incompatible $\neq$ independiente — son casi opuestos. Si A y B son incompatibles ($A \cap B = \emptyset$) y ambos tienen probabilidad positiva, entonces $P(A \cap B) = 0$ pero $P(A)P(B) > 0$, así que **no** pueden ser independientes (salvo el caso degenerado en que alguno tenga probabilidad 0). Confundir “incompatible” con “independiente” es un error conceptual grave y frecuente — son dos nociones completamente distintas: incompatibilidad es una propiedad de los *conjuntos* (no se pueden solapar), independencia es una propiedad de las *probabilidades* (no se influyen).

7.2 — INDEPENDENCIA POR PARES VS. INDEPENDENCIA MUTUA

Para **tres** eventos A, B, C se dice que son **mutuamente independientes** si se cumplen **las 4 condiciones simultáneamente**:

$$P(A \cap B) = P(A)P(B), \quad P(A \cap C) = P(A)P(C), \quad P(B \cap C) = P(B)P(C), \quad P(A \cap B \cap C) = P(A)P(B)P(C)$$

Las primeras tres condiciones se llaman **independencia de a pares**. La cuarta condición es una restricción **adicional**, no una consecuencia de las anteriores.

⚠ Error de tolerancia cero — independencia de a pares NO implica independencia mutua. Este es uno de los contraejemplos clásicos más citados en teoría de probabilidad, y aparece seguido en examen como pregunta teórica.

Ejemplo 7.1 — Contraejemplo: dos monedas independientes que “esconden” dependencia en su XOR.

Se lanzan dos monedas justas independientes $X, Y \in \{0, 1\}$. Se define $Z = X \oplus Y$ (XOR: $Z = 1$ si $X \neq Y$, $Z = 0$ si $X = Y$). Sean $A = \{X = 1\}$, $B = \{Y = 1\}$, $C = \{Z = 1\}$.

Los 4 resultados $(X, Y) \in \{(0, 0), (0, 1), (1, 0), (1, 1)\}$ son equiprobables (prob. $1/4$ c/u).

$P(A) = P(B) = P(C) = 1/2$ (cada evento ocurre en exactamente 2 de los 4 casos).

$P(A \cap B) = P(X = 1, Y = 1) = 1/4 = P(A)P(B)$ ✓ independientes.

$P(A \cap C)$: $A \cap C = \{X = 1, X \neq Y\} = \{(1, 0)\}$, prob $1/4 = P(A)P(C)$ ✓ independientes.

$P(B \cap C)$: análogo, $= 1/4 = P(B)P(C)$ ✓ independientes.

Pero $P(A \cap B \cap C) = P(X = 1, Y = 1, X \neq Y) = P(\emptyset) = 0$, mientras que $P(A)P(B)P(C) = (1/2)^3 = 1/8 \neq 0$.

Los tres eventos son independientes **de a pares**, pero **no** mutuamente independientes: si sabés que ocurrieron A y B ($X=1$ e $Y=1$), sabés con certeza que C NO ocurre ($Z=0$), así que C no es “independiente” de la ocurrencia conjunta de A y B.

Verificación (enumeración exacta + Monte Carlo con 2 millones de tiradas):

```
import random
N = 2_000_000
cntA=cntB=cntC=cntAB=cntABC=0
for _ in range(N):
    x = random.randint(0,1); y = random.randint(0,1)
    a = x==1; b = y==1; c = (x^y)==1
    cntA+=a; cntB+=b; cntC+=c
    cntAB += a and b
    cntABC += a and b and c
print("P(A)P(B)=", (cntA/N)*(cntB/N), " P(AB)=", cntAB/N)      # ~0.25 y ~0.25 (coinciden)
print("P(A)P(B)P(C)=", (cntA/N)*(cntB/N)*(cntC/N), " P(ABC)=", cntABC/N) # ~0.125 vs 0.0 (NO coinciden)
```

Resultado real: $P(AB) \approx 0.2498 \approx P(A)P(B) \approx 0.2499$ (coinciden, independencia de a pares confirmada), pero $P(ABC)=0.0$ exactamente mientras $P(A)P(B)P(C) \approx 0.125$ (no coinciden — la independencia mutua falla) ✓.

7.3 — INDEPENDENCIA CONDICIONAL

Dos eventos A y B son **condicionalmente independientes dado C** (con $P(C)>0$) si

$$P(A \cap B \mid C) = P(A \mid C) P(B \mid C)$$

La independencia condicional **no implica ni es implicada** por la independencia “a secas”. Es perfectamente posible que A y B sean independientes pero dependientes condicionados a C (o viceversa) — es la misma idea de que $P(A|B) \neq P(A|B \cap C)$ en general. Ejemplo clásico: A=“la alarma de casa suena”, B=“hay un terremoto” pueden ser aproximadamente independientes sin información adicional; pero condicionado a C=“entró un ladrón”, A y B se vuelven negativamente dependientes en cierto sentido (explicación causal común, “explaining away”).

8. Trampas típicas de examen

1. Falacia del fiscal — confundir $P(A|B)$ con $P(B|A)$. Ver sección 4.1. Regla práctica: antes de escribir una condicional, pregúntate explícitamente “¿qué es lo que ya se sabe (lo que va después de la barra) y qué es lo que quiero calcular (lo que va antes)?” — invertir el orden es el error más común de todo el tema.

2. Usar la regla del producto simplificada sin verificar independencia.

$P(A \cap B) = P(A)P(B)$ SOLO vale si A y B son independientes (dato del enunciado o demostrado explícitamente). Si no, hay que usar la regla general $P(A \cap B) = P(A)P(B|A)$ (sección 4.2). El enunciado casi siempre da suficiente información para calcular $P(B|A)$ directamente (por conteo, por una tabla, etc.) — no asumas independencia porque “simplifica las cuentas”.

3. Mal identificar la partición del espacio en problemas de Bayes. Antes de aplicar la fórmula de Bayes o de probabilidad total, hay que verificar EXPLÍCITAMENTE que los C_i elegidos (a) son disjuntos dos a dos y (b) cubren todo Ω ($\sum P(C_i) = 1$). Un error muy común es usar como “partición” un conjunto de eventos que se solapan (por ejemplo, en problemas de exámenes múltiples, tratar “aprobó al menos una materia” y “aprobó Prog3” como partes de una partición, cuando se solapan). Regla de oro: dibujar (aunque sea mentalmente) el árbol de probabilidades — si en el primer nivel las ramas no “agotan” todos los casos posibles y sin overlap, no es una partición válida.

4. Falacia de la frecuencia base (base rate fallacy). Ver Ejemplo 6.1. Un test “muy preciso” (alta sensibilidad y especificidad) puede seguir teniendo $P(\text{enfermo}|\text{positivo})$ baja si la enfermedad es rara — porque el numerador de Bayes depende del producto $P(+|E) \cdot P(E)$, y $P(E)$ chico puede dominar sobre una sensibilidad alta. Antes de intuir la respuesta “a ojo”, siempre conviene armar la tabla de 100 000 personas (o el árbol) y contar directamente.

5. Independencia por pares $\Rightarrow$ independencia mutua (falso). Ver sección 7.2 y el contraejemplo del Ejemplo 7.1. Si el enunciado dice “A, B y C son independientes de a pares”, NO se puede concluir automáticamente que $P(A \cap B \cap C) = P(A)P(B)P(C)$ — hay que verificarlo aparte, o el enunciado debe decir explícitamente “mutuamente independientes”.

Tabla de referencia rápida

Concepto	Fórmula
Axiomas de Kolmogorov	$P(A) \geq 0$; $P(\Omega)=1$; $P(A \cup B)=P(A)+P(B)$ si $A \cap B=\emptyset$; continuidad (Ax.4)
Complemento	$P(A^c) = 1 - P(A)$
Regla de la resta ($A \subset B$)	$P(B \setminus A) = P(B) - P(A)$
Inclusión-exclusión (2 eventos)	$P(A \cup B) = P(A)+P(B)-P(A \cap B)$
Inclusión-exclusión (3 eventos)	$P(A \cup B \cup C) = \sum P(\text{single}) - \sum P(\text{pares}) + P(A \cap B \cap C)$
Cota de la unión (Boole)	$P(\cup A_n) \leq \sum P(A_n)$
Casos favorables/posibles	$P(A) = A / \Omega $ (Ω finito equiprobable)
Probabilidad geométrica	$P(A) = \text{long}(A)/\text{long}(\Omega)$ ó $\text{Área}(A)/\text{Área}(\Omega)$
Probabilidad condicional	$P(A B) = P(A \cap B)/P(B)$, con $P(B)>0$
Regla del producto (2 eventos)	$P(A \cap B) = P(B)P(A B) = P(A)P(B A)$
Regla de la cadena (n eventos)	$P(\cap A_i) = P(A_1)P(A_2 A_1) \cdots P(A_n A_1 \cap \dots \cap A_{n-1})$
Probabilidad total	$P(A) = \sum_i P(A C_i)P(C_i)$, $\{C_i\}$ partición
Teorema de Bayes	$P(C_k A) = P(C_k)P(A C_k) / \sum_i P(C_i)P(A C_i)$
Independencia (2 eventos)	$P(A \cap B) = P(A)P(B) \Leftrightarrow P(A B)=P(A)$
Independencia mutua (3 eventos)	Las 3 condiciones de a pares y $P(A \cap B \cap C)=P(A)P(B)P(C)$
Independencia condicional	$P(A \cap B C) = P(A C)P(B C)$

Resumen ultra-rápido (2 minutos)

- **Kolmogorov = 3-4 reglas mínimas** ($P \geq 0$, $P(\Omega)=1$, aditividad en incompatibles, continuidad) de las que se deduce TODO lo demás por demostración corta: complemento, resta, monotonía, inclusión-exclusión, cota de Boole.

- **Equiprobable:** $P(A) = |A|/|\Omega|$. **Geométrico:** $P(A) = \text{long}(A)/\text{long}(\Omega)$ o $\text{Área}(A)/\text{Área}(\Omega)$ — misma idea, con medida continua en vez de cardinal.
- **Probabilidad condicional** $P(A|B) = P(A \cap B)/P(B)$ es simplemente P restringida y renormalizada al evento B — por eso **cumple los mismos axiomas** que P .
- **$P(A|B) \neq P(B|A)$** — la falacia del fiscal es el error #1 de todo el tema. Siempre identificar qué va antes y qué va después de la barra.
- **Regla del producto:** $P(A \cap B) = P(A)P(B|A)$. Se simplifica a $P(A)P(B)$ SOLO si son independientes — nunca asumir independencia sin justificarla.
- **Partición + probabilidad total:** $P(A) = \sum P(A|C_i)P(C_i)$, verificando SIEMPRE que los C_i sean disjuntos y cubran Ω .
- **Bayes** invierte la condicional usando probabilidad total en el denominador: $P(C_k|A) = P(C_k)P(A|C_k) / \sum P(C_i)P(A|C_i)$. Clave para “tests médicos”, “urnas”, “sorteos arreglados”.
- **Falacia de la frecuencia base:** un test muy preciso puede dar $P(\text{enfermo}|+)$ sorprendentemente baja si la enfermedad es rara — siempre armar la tabla/árbol con números concretos, no confiar en la intuición.
- **Independencia:** $P(A \cap B) = P(A)P(B)$. Incompatible $\neq$ independiente (son casi opuestos si ambas probabilidades son positivas). **Independencia de a pares NO implica independencia mutua** — contraejemplo estándar: X, Y monedas independientes, $Z = X \oplus Y$; A, B, C definidos a partir de $X=1, Y=1, Z=1$ son independientes de a pares pero $P(A \cap B \cap C) = 0 \neq P(A)P(B)P(C)$.