

CONTENTS

Variable Aleatoria, Función de Distribución y Variables Discretas	
Guía de estudio con tolerancia cero — Temas 1.4 y 1.5, Probabilidad y Estadística (FING UdelaR)	
0. Por qué existe este tema	
1. Variable aleatoria y función de distribución	
1.1 Definición formal de variable aleatoria	
1.2 Función de distribución acumulada (f.d.a.)	
1.3 Las 4 propiedades características de FX	
1.4 Fórmulas derivadas de las 4 propiedades (Práctico 4, Ejercicio 3)	
2. Función de probabilidad puntual (f.p.p.) para variables discretas	
3. Los 5 modelos discretos clásicos	
3.1 Bernoulli(p)	
3.2 Binomial(n, p)	
3.3 Geométrica(p)	
3.4 Poisson(λ)	
3.5 Hipergeométrica(N, D, n)	
3.6 Tabla resumen de los 5 modelos	
4. Trampas típicas de examen	
Resumen de repaso rápido (2 minutos)	

Variable Aleatoria, Función de Distribución y Variables Discretas

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMAS 1.4 Y 1.5, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existe este tema

Hasta el Módulo 1.3 del curso trabajaste directamente con sucesos: A, B, “sale par”, “el examen da positivo”. Eso funciona bien mientras el resultado de interés es una etiqueta cualitativa. Pero la mayoría de los problemas reales piden un **número**: cuántos clientes llegan, cuánto dura un componente, cuánto suma un dado. La variable aleatoria es el objeto matemático que traduce “el resultado incierto de un experimento” en “un número al que le puedo aplicar álgebra, calcular un promedio, graficar”.

La segunda idea de este bloque —la función de distribución $F_X(x) = P(X \leq x)$ — es la **huella dactilar completa** de una variable aleatoria: si conocés F_X para todo x , podés recuperar la probabilidad de cualquier evento que involucre a X ($P(a < X \leq b)$, $P(X=a)$, $P(X>a)$, etc.), sin necesitar el espacio muestral original. Por eso el examen dedica ejercicios enteros a “despejar” probabilidades a partir de una F_X dada (ver Práctico 4, Ejercicios 3 y 4): es literalmente aprender a leer esa huella dactilar.

La tercera idea —los 5 modelos discretos clásicos (Bernoulli, Binomial, Geométrica, Poisson, Hipergeométrica)— son las “huellas dactilares con nombre y apellido”: fórmulas cerradas para $p_X(x)$ que aparecen una y otra vez porque describen situaciones extremadamente comunes (éxito/fracaso, conteo de éxitos, tiempo de espera, conteo de eventos raros, muestreo sin reposición). Identificar **cuál** modelo corresponde a cada enunciado es la habilidad central que se evalúa — y es exactamente donde más puntos se pierden, porque los cinco modelos comparten “aire de familia” (todos cuentan éxitos de algún tipo) pero tienen hipótesis distintas que cambian la fórmula por completo.

Regla de oro de todo el tema: antes de escribir una fórmula, respondé tres preguntas sobre el experimento — (1) **¿hay un número fijo de ensayos n , o se repite hasta lograr algo?** (2) **¿se repone lo extraído entre ensayos (población “infinita”/con reposición) o no (población finita, sin reposición)?** (3) **¿el fenómeno ocurre en un continuo de tiempo/espacio en vez de en “intentos” discretos?** Las respuestas determinan sin ambigüedad cuál de los cinco modelos usar (ver tabla de la Sección 3.6).

1. Variable aleatoria y función de distribución

1.1 DEFINICIÓN FORMAL DE VARIABLE ALEATORIA

Definición. Sea $(\Omega, \mathcal{A}, P)$ un espacio de probabilidad. Una **variable aleatoria** es una función

$$X : \Omega \rightarrow \mathbb{R}$$

que a cada resultado ω del experimento le asigna un número real $X(\omega)$, y que además es “medible”: para todo $x \in \mathbb{R}$, el conjunto $\{\omega \in \Omega : X(\omega) \leq x\}$ es un suceso de $\mathcal{A}$ (es decir, tiene una probabilidad bien definida). En este curso, con espacios muestrales discretos o con la σ -álgebra de Borel en $\mathbb{R}$, esta condición técnica se cumple automáticamente para cualquier función razonable, así que en la práctica basta con verificar que X esté bien definida como función $\Omega \rightarrow \mathbb{R}$.

La idea intuitiva (Carrasco, Clase 6): **no importa poder describir Ω explícitamente** (a veces es imposible, como la “historia genética completa” de una planta); lo único que importa es poder calcular la probabilidad de los distintos valores que X puede tomar. Esa es la ventaja práctica enorme del concepto: reduce un problema potencialmente infinito-dimensional (el espacio muestral completo) a una única función de una variable real.

Ejemplo 1.1 — Construcción explícita.

Se lanzan dos dados equilibrados. $\Omega = \{(i,j) : i,j \in \{1,\dots,6\}\}$, con $P(i,j)=1/36$ para cada resultado.

Definimos $X(i,j) = i+j$ (la suma). Entonces $X:\Omega \rightarrow \mathbb{R}$ es una variable aleatoria con recorrido $R_X = \{2,3,\dots,12\}$.

Verificación de que está bien definida: cada uno de los 36 elementos de Ω tiene asignado un único valor real (no hay ambigüedad), y para cualquier x , el conjunto $\{(i,j): i+j \leq x\}$ es un subconjunto de Ω al que se le puede calcular probabilidad sumando las $1/36$ correspondientes.

Variable aleatoria discreta. X es discreta si su recorrido R_X es un conjunto numerable (finito o infinito numerable): $R_X = \{x_1, x_2, \dots\}$. Intuitivamente: “contamos” en vez de “medimos”.

1.2 FUNCIÓN DE DISTRIBUCIÓN ACUMULADA (F.D.A.)

Definición. La función de distribución (f.d.a.) de X es

$$F_X : \mathbb{R} \rightarrow [0,1], F_X(x) = P(X \leq x)$$

Nota el signo $\leq$ (no $<$): es la convención universal del curso y determina en qué lado va el círculo lleno/vacío al graficar.

F_X determina **toda** la distribución de X : cualquier probabilidad de la forma $P(X \in I)$ para I un intervalo (abierto, cerrado, semiabierto) se puede escribir en términos de F_X y de sus límites laterales. Esto es lo que resuelve el Ejercicio 3 del Práctico 4 (ver tabla completa en la Sección 1.4).

1.3 LAS 4 PROPIEDADES CARACTERÍSTICAS DE F_X

Toda función de distribución, sin importar si X es discreta, continua o mixta, cumple estas cuatro propiedades — y **solo** estas cuatro son necesarias y suficientes para que una función F sea la f.d.a. de alguna variable aleatoria (Teorema de existencia, no se prueba en el curso pero se usa constantemente en el Ejercicio 2 del Práctico 4 para “completar” parámetros).

(P1) Monotonía no decreciente. Si $x \leq y$ entonces $F_X(x) \leq F_X(y)$.

Demostración. Si $x \leq y$, el evento $\{X \leq x\}$ está contenido en el evento $\{X \leq y\}$ (todo ω que cumple $X(\omega) \leq x$ también cumple $X(\omega) \leq y$). Por monotonía de la probabilidad (axioma de Kolmogorov: $A \subseteq B \Rightarrow P(A) \leq P(B)$), $P(X \leq x) \leq P(X \leq y)$, es decir $F_X(x) \leq F_X(y)$. ■

(P2) Límites en infinito. $\lim_{x \rightarrow -\infty} F_X(x) = 0$ y $\lim_{x \rightarrow +\infty} F_X(x) = 1$.

Demostración (caso $+\infty$). Los eventos $A_n = \{X \leq n\}$ son crecientes ($A_n \subseteq A_{n+1}$) y su unión sobre todo $n \in \mathbb{N}$ es Ω (todo resultado tiene un valor real de X , que siempre es $\leq$ algún entero n). Por el axioma de continuidad de la probabilidad (consecuencia de la σ -aditividad), $\lim_{n \rightarrow \infty} P(X \leq n) = P(\cup A_n) = P(\Omega) = 1$. El caso $-\infty$ es análogo, usando que los eventos $\{X \leq -n\}$ son decrecientes con intersección vacía, de modo que $\lim_{n \rightarrow \infty} P(X \leq -n) = P(\emptyset) = 0$. ■

(P3) Continuidad a derecha. Para todo x , $\lim_{y \rightarrow x^+} F_X(y) = F_X(x)$.

Demostración. Los eventos $B_n = \{X \leq x + 1/n\}$ son decrecientes y su intersección es exactamente $\{X \leq x\}$ (para cualquier ω con $X(\omega) \leq x$, se cumple $X(\omega) \leq x + 1/n$ para todo n ; y si $X(\omega) > x$, existe n suficientemente grande tal que $X(\omega) > x + 1/n$). Por continuidad de la probabilidad (para sucesiones decrecientes), $\lim_{n \rightarrow \infty} P(X \leq x + 1/n) = P(X \leq x) = F_X(x)$. Como esto vale para la sucesión particular $1/n \rightarrow 0^+$, y F_X es monótona (P1), el límite lateral por derecha en cualquier trayectoria coincide: $\lim_{y \rightarrow x^+} F_X(y) = F_X(x)$. ■

(P4) El salto en x es $P(X=x)$. $F_X(x) - \lim_{y \rightarrow x^-} F_X(y) = P(X=x)$.

Demostración. El límite por izquierda es $\lim_{y \rightarrow x^-} F_X(y) = P(X < x)$: los eventos $C_n = \{X \leq x - 1/n\}$ son crecientes con unión $\{X < x\}$, así que por continuidad de la probabilidad $\lim_{n \rightarrow \infty} P(X \leq x - 1/n) = P(X < x)$. Entonces

$$F_X(x) - \lim_{y \rightarrow x^-} F_X(y) = P(X \leq x) - P(X < x) = P(X=x)$$

(la última igualdad porque $\{X \leq x\} = \{X < x\} \cup \{X=x\}$, unión disjunta). En particular, **F_X es continua en x si y solo si $P(X=x)=0$** — por eso las variables discretas (donde $P(X=x)>0$ en los puntos del recorrido) siempre tienen F_X “escalonada”, con saltos exactamente en los puntos de R_X , y las variables continuas ($P(X=x)=0$ para todo x) tienen F_X continua en todas partes. ■

Truco de verificación universal (Ejercicio 2 del Práctico 4): cuando te dan una F candidata a trozos con parámetros desconocidos, las incógnitas se despejan imponiendo, en este orden: (1) el límite en $+\infty$ debe dar 1; (2) el límite en $-\infty$ debe dar 0; (3) en cada punto de empalme entre trozos, si la función debe ser continua ahí (o si el enunciado no indica un salto), el límite por izquierda debe igualar el valor de la función evaluada por derecha — la continuidad a derecha (P3) es automática si F está bien definida por trozos con “ $\leq$ ” en el borde derecho de cada tramo, pero el límite por IZQUIERDA en el empalme es una ecuación real que hay que plantear.

Ejemplo 1.2 — Despejar parámetros (Práctico 4, Ej. 2.1).

$$F(x) = \beta e^x \text{ si } x < 0; \beta \text{ si } x = 0; 1/4 \text{ si } 0 < x < 1; \alpha \cdot x / (1+x) \text{ si } x \geq 1.$$

Paso 1 (límite en $+\infty = 1$): $\lim_{x \rightarrow +\infty} \alpha \cdot x / (1+x) = \alpha \cdot 1 = \alpha \Rightarrow \alpha = 1$.

Paso 2 (continuidad a derecha en $x=0$, forzada por P3): $F(0)$ debe ser igual a $\lim_{x \rightarrow 0^+} F(x) = 1/4$.

Como $F(0) = \beta$ por definición, $\beta = 1/4$.

Verificación de monotonía: en $x=0^-$, $\lim_{x \rightarrow 0^-} \beta e^x = \beta = 1/4 = F(0)$ ✓ (no hay salto extra, coherente con que el tramo $x < 0$ y el punto $x=0$ empalman). Para $x \geq 1$, $\alpha \cdot x / (1+x) = x / (1+x)$ es creciente y en $x=1$ vale $1/2 > 1/4$ ✓ (sigue subiendo, consistente con P1).

1.4 FÓRMULAS DERIVADAS DE LAS 4 PROPIEDADES (PRÁCTICO 4, EJERCICIO 3)

A partir de los axiomas de probabilidad y de $F_X(x) = P(X \leq x)$, se deducen todas estas identidades (todas se prueban descomponiendo el evento de interés como unión o diferencia de eventos del tipo $\{X \leq t\}$):

#	Probabilidad pedida	Fórmula en términos de F_X	Idea de la demostración
1	$P(a < X \leq b)$	$F_X(b) - F_X(a)$	$\{X \leq b\} = \{X \leq a\} \cup \{a < X \leq b\}$, restar
2	$P(X=a)$	$F_X(a) - \lim_{x \rightarrow a^-} F_X(x)$	$\{X \leq a\} = \{X < a\} \cup \{X=a\}$, P4
3	$P(a \leq X \leq b)$	$F_X(b) - \lim_{x \rightarrow a^-} F_X(x)$	combinar 1 y 2
4	$P(a < X < b)$	$\lim_{x \rightarrow b^-} F_X(x) - F_X(a)$	$\{X < b\} = \{X \leq a\} \cup \{a < X < b\}$
5	$P(a \leq X < b)$	$\lim_{x \rightarrow b^-} F_X(x) - \lim_{x \rightarrow a^-} F_X(x)$	combinar 2 y 4
6	$P(X > a)$	$1 - F_X(a)$	complemento de $\{X \leq a\}$
7	$P(X \geq a)$	$1 - \lim_{x \rightarrow a^-} F_X(x)$	complemento de $\{X < a\}$

Error frecuente de tolerancia cero: usar $F_X(a)$ en vez de $\lim_{x \rightarrow a^-} F_X(x)$ cuando el evento pedido tiene un “ $\leq$ ” o “ $<$ ” mal ubicado respecto al borde. Para una v.a. **discreta**, si a NO es un punto de salto de F_X (es decir $P(X=a)=0$), entonces $F_X(a) = \lim_{x \rightarrow a^-} F_X(x)$ y las fórmulas 1 y 3 (o 4 y 5) coinciden numéricamente — pero si a SÍ es un punto de salto ($a \in R_X$), las fórmulas dan resultados distintos y usar la incorrecta es un error de examen clásico. Ver Ejemplo 1.3.

Ejemplo 1.3 — Aplicar la tabla con una F_X discreta (Práctico 4, Ej. 4.1).

$F_X(x) = 0$ si $x < -3$; $1/4$ si $-3 \leq x < 1$; $3/4$ si $1 \leq x < 2$; 1 si $x \geq 2$.

Calculemos $P(-3 \leq X < 1)$ y $P(-3 < X < 1)$ — a propósito, para mostrar que dan distinto:

$P(-3 \leq X < 1)$ [fórmula 5]: $\lim_{x \rightarrow 1^-} F_X(x) - \lim_{x \rightarrow -3^-} F_X(x) = 1/4 - 0 = 1/4$.

$P(-3 < X < 1)$ [fórmula 4]: $\lim_{x \rightarrow 1^-} F_X(x) - F_X(-3) = 1/4 - 1/4 = 0$.

¿Por qué la diferencia? Porque $x=-3$ es un punto de salto ($P(X=-3) = F_X(-3) - \lim_{x \rightarrow -3^-} F_X(x) = 1/4 - 0 = 1/4 > 0$). Al usar " $\leq$ " en -3 Sí estás incluyendo ese $1/4$ de probabilidad puntual; al usar " $<$ " NO.

Confundir $F_X(-3)$ con $\lim_{x \rightarrow -3^-} F_X(x)$ aquí cambia la respuesta de $1/4$ a 0 — no es un error menor.

Verificación con Python (cálculo directo sobre la f.p.p. derivada de los saltos): $p_X(-3)=1/4$, $p_X(1)=1/2$, $p_X(2)=1/4$ (saltos de F). Sumando directamente: $P(-3 \leq X < 1) = p_X(-3) = 0.25 \checkmark$. $P(-3 < X < 1) = 0$ (no hay masa estrictamente entre -3 y 1) $\checkmark$.

2. Función de probabilidad puntual (f.p.p.) para variables discretas

Definición. Si X es discreta, su función de probabilidad puntual (f.p.p., o "masa de probabilidad") es

$$p_X : \mathbb{R} \rightarrow [0, 1], p_X(x) = P(X=x)$$

Fuera del recorrido R_X , $p_X(x)=0$. Dos propiedades básicas (se verifican, no se asumen, en cada ejercicio de "hallar k para que sea función de probabilidad"):

1. $p_X(x) \geq 0$ para todo x .
2. $\sum_{x \in R_X} p_X(x) = 1$ (la suma de toda la masa de probabilidad es 1, porque R_X cubre a Ω completo bajo X).

Relación entre p_X y F_X : los saltos SON la f.p.p.

Por la propiedad P4 de la sección anterior, el salto de F_X en cualquier punto x es exactamente $P(X=x)=p_X(x)$. Esto da dos caminos equivalentes para pasar de una representación a la otra:

- **De p_X a F_X :** $F_X(x) = \sum_{y \leq x, y \in R_X} p_X(y)$ (acumular la masa hasta x).
- **De F_X a p_X :** $p_X(x) = \text{tamaño del salto de } F_X \text{ en } x$ (0 si F_X es continua ahí).

Gráficamente: p_X se dibuja como "palitos" (o "bastones") de altura $P(X=x)$ en cada punto del recorrido — nunca una curva continua. F_X se dibuja como una "escalera" que sube exactamente en esos mismos puntos, con esa misma altura de salto, y es constante entre ellos. El círculo relleno en cada escalón de F_X va del lado derecho (por la continuidad a derecha, P3); el círculo vacío queda del lado izquierdo, marcando dónde termina el valor "viejo" antes del salto.

3. Los 5 modelos discretos clásicos

3.1 BERNOULLI(P)

Experimento que modela: un único ensayo con dos resultados posibles: "éxito" (probabilidad p) o "fracaso" (probabilidad $1-p$). X vale 1 si hay éxito, 0 si hay fracaso.

Fórmula: $p_X(1)=p$, $p_X(0)=1-p$, con $0<p<1$. Soporte: $R_X=\{0,1\}$.

Verificación $\Sigma p_X=1$: $p+(1-p)=1$ ✓ (trivial, pero es la pieza base de la que se construyen los otros modelos).

Es el “átomo” del proceso de Bernoulli: si $X_1, \dots, X_n$ son Bernoulli(p) independientes (ensayos repetidos e independientes del mismo experimento), su suma $S_n=X_1+\dots+X_n$ es exactamente la variable Binomial que sigue.

3.2 BINOMIAL(N,P)

Experimento que modela: se repite **n veces**, de forma **independiente**, un ensayo de Bernoulli(p). X = cantidad total de éxitos en los n ensayos.

Fórmula: $p_X(k) = C(n,k) \cdot p^k \cdot (1-p)^{n-k}$, para $k \in \{0, 1, \dots, n\}$. Parámetros: $n \in \mathbb{N}$ (cantidad de ensayos), $p \in (0, 1)$ (probabilidad de éxito en cada ensayo). Notación: $X \sim \text{Bin}(n, p)$.

Demostración de la fórmula (combinatoria). Fijado k , cada secuencia particular de n ensayos con exactamente k éxitos y $n-k$ fracasos (por ejemplo, éxito-éxito-fracaso-...-fracaso, en algún orden específico) tiene probabilidad $p^k(1-p)^{n-k}$ por independencia (se multiplican las probabilidades de cada ensayo, sin importar el orden en que aparecen los p 's y los $(1-p)$'s — la multiplicación es conmutativa). El evento $\{X=k\}$ es la unión de **todas** las secuencias con exactamente k éxitos entre las n posiciones, y estas secuencias son mutuamente excluyentes entre sí. La cantidad de esas secuencias es la cantidad de formas de elegir **cuáles** k de las n posiciones son los éxitos, es decir $C(n, k)$. Sumando las $C(n, k)$ probabilidades iguales (cada una $p^k(1-p)^{n-k}$):

$$p_X(k) = C(n, k) \cdot p^k \cdot (1-p)^{n-k}. \blacksquare$$

Verificación $\Sigma p_X=1$ (binomio de Newton): $\sum_{k=0}^n C(n, k) p^k (1-p)^{n-k} = (p+(1-p))^n = 1^n = 1$ ✓ (identidad directa del binomio de Newton, de ahí el nombre “distribución binomial”).

Ejemplo 3.1 — Transmisión de mensaje (Práctico 4, Ej. 5.2).

Mensaje de $n=4$ signos, $P(\text{error en un signo})=0.1=p$. X =cantidad de errores, $X \sim \text{Bin}(4, 0.1)$.

(a) $P(0 \text{ errores}) = C(4, 0) \cdot 0.1^0 \cdot 0.9^4 = 0.9^4 = \mathbf{0.6561}$.

(b) $P(\text{exactamente 1 error}) = C(4, 1) \cdot 0.1 \cdot 0.9^3 = 4 \cdot 0.1 \cdot 0.729 = \mathbf{0.2916}$.

(c) $P(\text{al menos 1 error}) = 1 - P(0 \text{ errores}) = 1 - 0.6561 = \mathbf{0.3439}$.

Verificación con Python (scipy/cálculo directo): `comb(4, 0)*0.1**0*0.9**4 = 0.6561` ;

`comb(4, 1)*0.1*0.9**3 = 0.2916` ; suma de las 5 probabilidades $p_X(0..4) = 1.0$ exacto ✓.

3.3 GEOMÉTRICA(P)

Experimento que modela: se repite, de forma independiente, un ensayo de Bernoulli(p) **hasta obtener el primer éxito**. X = cantidad de ensayos realizados (incluyendo el que tuvo éxito).

Fórmula: $p_X(k) = p \cdot (1-p)^{k-1}$, para $k \in \{1, 2, 3, \dots\}$. Parámetro: $p \in (0, 1)$. Notación: $X \sim \text{Geo}(p)$.

Demostración de la fórmula. $\{X=k\}$ ocurre si y solo si los primeros $k-1$ ensayos son fracaso **y** el k -ésimo es éxito. Por independencia, $P(X=k) = (1-p)^{k-1} \cdot p$ — el producto de $k-1$ probabilidades de fracaso por 1 probabilidad de éxito. ■

Verificación $\sum p_X=1$ (serie geométrica): $\sum_{k=1}^{\infty} p(1-p)^{k-1} = p \cdot \sum_{j=0}^{\infty} (1-p)^j = p \cdot (1/(1-(1-p))) = p \cdot (1/p) = 1$ ✓
(converge porque $0 < 1-p < 1$; de esta serie geométrica viene el nombre de la distribución — nada que ver con las “probabilidades geométricas” del tema 1.1).

⚠ Dos convenciones distintas para el parámetro — aclaración obligatoria de examen.

Este curso (Carrasco, Práctico 4 Ej. 9) define $X =$ **cantidad de ensayos hasta el éxito inclusive**, con soporte $\{1, 2, 3, \dots\}$ y fórmula $p_X(k) = p(1-p)^{k-1}$.

Existe una **segunda convención**, igual de común en otros libros (y en algún ejercicio de exámenes viejos), que define $Y =$ **cantidad de FRACASOS antes del primer éxito**, con soporte $\{0, 1, 2, \dots\}$ y fórmula $p_Y(k) = p(1-p)^k$. La relación entre ambas es $Y = X - 1$ (mismo experimento, distinto conteo). Antes de aplicar la fórmula, fijate SIEMPRE si el enunciado cuenta “intentos totales” (empieza en 1, este curso) o “fracasos previos” (empieza en 0). Mezclar las dos convenciones en un mismo cálculo es el error más común de este modelo.

Propiedad de falta de memoria discreta (Práctico 4, Ej. 9.3).

Enunciado: $\forall m, n \in \mathbb{N}, P(X > m+n \mid X > m) = P(X > n)$.

Demostración. Primero, $P(X > k) = (1-p)^k$ para cualquier $k \geq 0$: el evento $\{X > k\}$ equivale a “los primeros k ensayos fueron todos fracaso” (si no, X habría sido $\leq k$), y por independencia esa probabilidad es $(1-p)^k$. Entonces

$$P(X > m+n \mid X > m) = P(X > m+n, X > m) / P(X > m) = P(X > m+n) / P(X > m)$$

(porque $\{X > m+n\} \subseteq \{X > m\}$, así que la intersección es simplemente $\{X > m+n\}$). Sustituyendo:

$$= (1-p)^{m+n} / (1-p)^m = (1-p)^n = P(X > n). \quad \blacksquare$$

Interpretación: si en el ensayo m todavía no hubo éxito, la distribución de “cuántos ensayos más” faltan es exactamente la misma que si empezara de nuevo desde cero — el proceso “no recuerda” cuántos fracasos ya ocurrieron. Es la versión discreta exacta de la falta de memoria de la exponencial (tema 1.6).

Ejemplo 3.2 — Línea telefónica (Práctico 4, Ej. 9.4).

$p=0.05$ (probabilidad de conseguir línea en cada intento). $X \sim \text{Geo}(0.05)$. Se pide $P(X=5)$ (necesitar exactamente 5 intentos).

$$p_X(5) = 0.05 \cdot (0.95)^4 = \mathbf{0.0407} \ (\approx 4.07\%).$$

Verificación con Python: `0.05*0.95**4 = 0.040725...` ✓. Suma de $p_X(k)$ para $k=1..2000 \approx 1.0000$ ✓
(la cola restante es $(0.95)^{2000} \approx 0$, despreciable).

3.4 POISSON(λ)

Experimento que modela: conteo de “eventos raros” que ocurren en un continuo (de tiempo, espacio, área, volumen), donde los eventos son independientes entre subintervalos disjuntos y la probabilidad de más de un evento en un instante infinitesimal es despreciable. λ es la cantidad **promedio** de eventos en el intervalo unidad considerado.

Fórmula: $p_X(k) = e^{-\lambda} \cdot \lambda^k / k!$, para $k \in \{0, 1, 2, \dots\}$. Parámetro: $\lambda > 0$. Notación: $X \sim P(\lambda)$ (o $\text{Pois}(\lambda)$).

Verificación $\sum p_X = 1$ (serie de Taylor de e^λ): $\sum_{k=0}^{\infty} e^{-\lambda} \lambda^k / k! = e^{-\lambda} \cdot \sum_{k=0}^{\infty} \lambda^k / k! = e^{-\lambda} \cdot e^\lambda = 1 \checkmark$.

Poisson como límite de Binomial (Práctico 4, Ej. 11.1) — sucesos raros.

Enunciado: sea $X_n \sim \text{Bin}(n, p_n)$ con $n \rightarrow +\infty$ tal que $\lim_{n \rightarrow \infty} n \cdot p_n = \lambda$ ($0 < \lambda < \infty$, es decir $p_n \rightarrow 0$ al mismo ritmo que $n \rightarrow \infty$, manteniendo el producto constante). Entonces para todo k fijo:

$$\lim_{n \rightarrow \infty} P(X_n = k) = e^{-\lambda} \cdot \lambda^k / k!$$

Idea de la demostración (usando $p = \lambda/n$ y la fórmula de Stirling $n! \approx \sqrt{(2\pi n)}(n/e)^n$):

$$P(X_n = k) = C(n, k) \cdot (\lambda/n)^k \cdot (1 - \lambda/n)^{n-k}$$

Se separa el producto en tres factores y se calcula el límite de cada uno por separado, para k fijo cuando $n \rightarrow \infty$:

1. $n(n-1)\cdots(n-k+1)/n^k \rightarrow 1$: es un producto de k factores, cada uno de la forma $(1-j/n)$ con $j=0, \dots, k-1$ fijo, y cada uno tiende a 1.
2. $(1-\lambda/n)^n \rightarrow e^{-\lambda}$: es el límite notable que define la función exponencial, $\lim_{n \rightarrow \infty} (1+x/n)^n = e^x$ con $x = -\lambda$.
3. $(1-\lambda/n)^{-k} \rightarrow 1$: k fijo, $\lambda/n \rightarrow 0$.

El factor $\lambda^k/k!$ queda fijo (no depende de n). Multiplicando los tres límites: $1 \cdot e^{-\lambda} \cdot 1 \cdot (\lambda^k/k!) = e^{-\lambda} \lambda^k/k!$. ■

Condiciones prácticas para que la aproximación sea buena: n grande y p pequeño, de forma que $\lambda = np$ quede en un rango moderado. Reglas empíricas usuales: **$n \geq 20$ y $p \leq 0.05$** , o **$n \geq 100$ y $p \leq 0.10$** (más laxo, funciona razonablemente incluso fuera de estos límites, ej. $n=50$, $p=0.12$).

Ejemplo 3.3 — Partículas radiactivas (Práctico 4, Ej. 8.2).

Promedio $\lambda=4$ partículas por milisegundo. $P(\text{entren exactamente 6 en un milisegundo}) = p_X(6) = e^{-4} \cdot 4^6 / 6! = \mathbf{0.1042}$ ($\approx 10.42\%$).

Verificación con Python: `exp(-4)*4**6/factorial(6) = 0.10420` $\checkmark$. Simulación Monte Carlo con 1.000.000 de repeticiones dio 0.10478, dentro del margen esperable de error de muestreo ($\pm 0.03\%$ de desvío típico aprox.) $\checkmark$.

Ejemplo 3.4 — Aproximación Binomial $\rightarrow$ Poisson (Práctico 4, Ej. 11.2).

$P(\text{acertar un disparo}) = 0.001$, $n = 5000$ disparos. Se pide $P(\geq 2 \text{ aciertos})$.

Exacto (Binomial): $1 - C(5000,0)(0.001)^0(0.999)^{5000} - C(5000,1)(0.001)^1(0.999)^{4999} = 0.95964$.

Aproximado (Poisson, $\lambda=np=5$): $1 - e^{-5} - 5e^{-5} = 0.95957$.

Diferencia ≈ 0.00007 (0.007 puntos porcentuales) — excelente, porque $n=5000$ es enorme y $p=0.001$ es diminuto ($np=5$, condición ideal para la aproximación).

⚠ Corrección del material fuente: la resolución manuscrita de referencia (carpeta del estudiante) plantea esta cuenta directamente con la Binomial exacta pero la etiqueta como “cuentas poco lindas” sin resolverlas numéricamente ni mostrar la aproximación de Poisson en paralelo para contrastar — acá se agrega el cálculo numérico completo de ambas vías para verificar que efectivamente coinciden, que es el punto pedagógico central del ejercicio.

3.5 HIPERGEOMÉTRICA(N,D,n)

Experimento que modela: una población de N elementos, de los cuales D pertenecen a una categoría de interés (y $N-D$ no). Se extrae una muestra de tamaño n , **sin reposición** (cada elemento extraído no vuelve a la población). X = cantidad de elementos de la categoría de interés en la muestra.

Fórmula: $p_X(k) = [C(D,k) \cdot C(N-D,n-k)] / C(N,n)$, para $k \in \{0,1,\dots,\min(D,n)\}$ (y también $k \geq n-(N-D)$, aunque en la práctica de este curso siempre se trabaja con N grande y esa cota inferior no es activa). Notación: $X \sim \text{Hip}(N,D,n)$.

Demostración de que $\sum p_X = 1$ (identidad de Vandermonde). El numerador $C(D,k) \cdot C(N-D,n-k)$ cuenta la cantidad de muestras de tamaño n que tienen exactamente k elementos “de interés” (elegir cuáles k de los D , y cuáles $n-k$ de los $N-D$ restantes) — todas igualmente probables, ya que cada subconjunto de tamaño n de la población tiene la misma probabilidad de ser la muestra (muestreo sin reposición y sin orden). El denominador $C(N,n)$ es el total de muestras posibles de tamaño n . La suma sobre todos los valores posibles de k debe dar el total de muestras posibles, es decir:

$$\sum_{k=0}^n C(D,k) \cdot C(N-D,n-k) = C(N,n)$$

(identidad de Vandermonde: contar de dos formas la cantidad de subconjuntos de tamaño n de un conjunto de tamaño N , particionando según cuántos elementos vienen del subgrupo D). Dividiendo ambos lados por $C(N,n)$: $\sum p_X(k) = 1$. ■

Diferencia clave con la Binomial: sin reposición vs. con reposición.

	Binomial(n,p)	Hipergeométrica(N,D,n)
Población	"infinita" o se repone entre extracciones	finita, tamaño N fijo
Independencia entre ensayos	Sí (por reposición o población infinita)	No — cada extracción cambia la composición de lo que queda
Parámetro de "éxito"	p fijo en cada ensayo	D/N (proporción inicial, pero cambia tras cada extracción)
Cuándo se aproxima Binomial≈Hipergeométrica	—	Cuando $N \gg n$ (población mucho más grande que la muestra): "casi no importa" no reponer

Ejemplo 3.5 — Comparación numérica directa Hipergeométrica vs. Binomial (Práctico 4, Ej. 7.3).

Lote de $N=10$ herramientas, $D=3$ defectuosas, se extraen $n=4$ sin reposición. X =cantidad de defectuosas en la muestra, $X \sim \text{Hip}(10,3,4)$.

k	Hipergeométrica exacta (sin reposición)	"Binomial ingenua" con $p=D/N=0.3$ (si hubiera reposición)
0	0.1667	0.2401
1	0.5000	0.4116
2	0.3000	0.2646
3	0.0333	0.0756
4	0 (imposible: solo hay 3 defectuosas)	0.0081

Notar que la **Binomial(4,0.3)** le asigna probabilidad positiva a $k=4$ (4 defectuosas en la muestra), lo cual es **imposible** en la realidad del problema porque solo hay 3 herramientas defectuosas en todo el lote — este es el error conceptual exacto de usar Binomial cuando corresponde Hipergeométrica: la Binomial "no sabe" que la población es finita y se va agotando.

Ítems del ejercicio original, resueltos con la fórmula exacta (Hipergeométrica):

- (a) $P(\text{las 4 funcionen, 0 defectuosas}) = p_X(0) = \mathbf{0.1667}$.
 (b) $P(\text{al menos 2 no funcionen}) = P(X \geq 2) = p_X(2) + p_X(3) = 0.3000 + 0.0333 = \mathbf{0.3333}$.
 (c) $P(\text{solo 1 funciona, 3 defectuosas}) = p_X(3) = \mathbf{0.0333}$.
 (d) $P(\text{por lo menos 1 funciona}) = 1 - p_X(4) = 1 - 0 = \mathbf{1}$ (certeza, porque X nunca puede ser 4).

Verificación con Python: `comb(3,0)*comb(7,4)/comb(10,4) = 0.16667` ✓; suma de $p_X(0..3) = 1.0$ exacto ✓.

Ejemplo 3.6 — Control de calidad con N grande (Práctico 4, Ej. 7.2).

Caja con $N=40$ herramientas, muestra $n=5$ sin reposición, $D=3$ defectuosas. Se rechaza la caja si hay al menos 1 defectuosa en la muestra.

$$P(\text{rechazar}) = 1 - p_X(0) = 1 - C(3,0)C(37,5)/C(40,5) = 1 - 0.6624 = \mathbf{0.3376}.$$

Verificación con Python: `1 - comb(3,0)*comb(37,5)/comb(40,5) = 0.33755` ✓.

3.6 TABLA RESUMEN DE LOS 5 MODELOS

Modelo	Notación	Soporte	$p_X(k)$	Parámetros	Pregunta clave para identificarlo
Bernoulli	Ber(p)	$\{0,1\}$	$p^k(1-p)^{1-k}$	$p \in (0,1)$	¿Es un único ensayo éxito/fracaso?
Binomial	Bin(n,p)	$\{0,\dots,n\}$	$C(n,k)p^k(1-p)^{n-k}$	$n \in \mathbb{N}, p \in (0,1)$	¿n ensayos fijos, independientes, cuento éxitos?
Geométrica	Geo(p)	$\{1,2,\dots\}$	$p(1-p)^{k-1}$	$p \in (0,1)$	¿Repito hasta el PRIMER éxito, cuento intentos?
Poisson	P(λ)	$\{0,1,2,\dots\}$	$e^{-\lambda}\lambda^k/k!$	$\lambda > 0$	¿Cuento eventos raros en un continuo (tiempo/espacio)?
Hipergeométrica	Hip(N,D,n)	$\{0,\dots,\min(D,n)\}$	$C(D,k)C(N-D,n-k)/C(N,n)$	$N,D,n \in \mathbb{N}, D \leq N$	¿Muestreo SIN reposición de una población finita?

4. Trampas típicas de examen

Trampa 1 — Binomial en vez de Hipergeométrica.

Si el enunciado dice “se extraen n elementos de una población de tamaño N (chico), sin reposición”, y usas la fórmula Binomial(n, D/N), estás asumiendo independencia entre extracciones que NO existe. El error es más grave cuanto más chica es la población relativa a la muestra (n/N grande) — con N=10 y n=4 (Ejemplo 3.5) el error en $p_X(0)$ es de casi 7 puntos porcentuales (0.1667 vs. 0.2401). Regla práctica: si $N/n \geq 20$ (población al menos 20 veces la muestra), la aproximación Binomial es aceptable en la práctica; si no, hay que usar Hipergeométrica exacta.

Trampa 2 — Confundir las dos convenciones de la Geométrica.

Este curso define X=“cantidad de intentos hasta el éxito inclusive” (soporte desde 1, fórmula $p(1-p)^{k-1}$). Si en un enunciado de otro libro o examen viejo aparece “cantidad de fracasos antes del éxito” (soporte desde 0, fórmula $p(1-p)^k$), son la MISMA distribución subyacente pero corridas en 1 — hay que fijarse

cuál pide el enunciado antes de sumar o evaluar la fórmula. Mezclar ambas (usar el soporte de una convención con la fórmula de la otra) da resultados sistemáticamente desplazados en 1 unidad.

Trampa 3 — Aplicar la aproximación de Poisson sin verificar las condiciones.

La aproximación $\text{Bin}(n,p) \approx \text{Pois}(np)$ requiere n grande Y p chico simultáneamente (no alcanza con que n sea grande si p también lo es: por ejemplo $\text{Bin}(1000, 0.5)$ NO se aproxima bien por $\text{Poisson}(500)$, ahí corresponde la aproximación normal, tema 2.4). Reglas prácticas: $n \geq 20$ con $p \leq 0.05$, o $n \geq 100$ con $p \leq 0.10$. Fuera de esos rangos, calculá la Binomial exacta o al menos aclará que la aproximación puede no ser precisa.

Trampa 4 — No verificar que $\sum p_X(k)=1$ al hallar un parámetro desconocido.

En ejercicios tipo “hallar k para que p sea función de probabilidad” (frecuentes en el práctico y en el examen), el único camino confiable es imponer $\sum p_X=1$ y despejar — no “adivinar” la constante de normalización por analogía con otro ejercicio. Cada modelo tiene su propia identidad de suma (binomio de Newton para Binomial, serie geométrica para Geométrica, serie de Taylor de e^x para Poisson, identidad de Vandermonde para Hipergeométrica) y usar la identidad equivocada lleva a una constante incorrecta.

Resumen de repaso rápido (2 minutos)

- **Variable aleatoria:** función $X: \Omega \rightarrow \mathbb{R}$. $F_X(x) = P(X \leq x)$, con las 4 propiedades: (1) no decreciente, (2) límites 0 en $-\infty$ y 1 en $+\infty$, (3) continua a derecha, (4) el salto en x es $P(X=x)$.
- **Para variables discretas:** $p_X(x) = P(X=x)$ son los “saltos” de F_X ; $F_X(x) = \sum_{y \leq x} p_X(y)$.
- **Tabla de fórmulas $P(a < X \leq b)$ etc.:** siempre en términos de F_X y de sus límites laterales — cuidado con $F_X(a)$ vs. $\lim_{x \rightarrow a^-} F_X(x)$ cuando a es un punto de salto.
- **Bernoulli(p):** un ensayo, $p_X(1)=p$, $p_X(0)=1-p$.
- **Binomial(n,p):** n ensayos independientes, cuento éxitos. $p_X(k) = C(n,k)p^k(1-p)^{n-k}$. Suma=1 por binomio de Newton.
- **Geométrica(p):** repito hasta el primer éxito, cuento intentos (desde 1). $p_X(k) = p(1-p)^{k-1}$. Suma=1 por serie geométrica. Tiene falta de memoria: $P(X > m+n | X > m) = P(X > n)$.
- **Poisson(λ):** eventos raros en un continuo. $p_X(k) = e^{-\lambda} \lambda^k / k!$. Suma=1 por serie de Taylor de e^λ . Es el límite de $\text{Bin}(n, p_n)$ cuando $n \rightarrow \infty$, $np_n \rightarrow \lambda$.
- **Hipergeométrica(N,D,n):** muestreo SIN reposición de población finita. $p_X(k) = C(D,k)C(N-D, n-k) / C(N,n)$. Suma=1 por identidad de Vandermonde. Se acerca a Binomial($n, D/N$) cuando $N \gg n$.
- **Trampa #1 de examen:** Binomial vs. Hipergeométrica — mirar si hay reposición o no, y si la población es chica respecto a la muestra.
- **Trampa #2:** confirmar la convención de la Geométrica (soporte desde 1 o desde 0) antes de aplicar la fórmula.

- **Trampa #3:** aproximación de Poisson solo es buena con n grande Y p chico simultáneamente ($np=\lambda$ moderado).