

CONTENTS

Variables Continuas y Vectores Aleatorios	
Guía de estudio con tolerancia cero — Temas 1.6 y 1.7, Probabilidad y Estadística (FING UdelaR)	
0. Por qué existe este tema/problema	
1. La función de densidad $f_X(x)$	
2. Cambio de variable (transformación de v.a. continuas)	
3. Los cuatro modelos continuos clásicos	
3.1 Uniforme(a,b)	
3.2 Exponencial(λ)	
3.3 Normal(μ, σ^2)	
3.4 Gamma(α, λ)	
4. Distribución de vectores aleatorios: conjunta, marginales, condicionales	
5. Independencia de variables aleatorias continuas	
6. Trampas típicas de examen (resumen de errores frecuentes)	
Tabla de referencia rápida de los 4 modelos	
Ejercicios de repaso rápido (con respuesta)	
Resumen ultra-rápido (2 minutos)	

Variables Continuas y Vectores Aleatorios

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMAS 1.6 Y 1.7, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existe este tema/problema

Hasta el Tema 1.5 (Variables Discretas), toda variable aleatoria tomaba un conjunto **numerable** de valores, y su distribución quedaba descrita sumando probabilidades puntuales $P(X = x)$. Pero muchísimas cantidades de interés — un tiempo de espera, una altura, un error de medición — pueden tomar **cualquier valor real** dentro de un intervalo. Ahí la suma deja de tener sentido: si X puede tomar un continuo de valores, es fácil convencerse de que **$P(X = x) = 0$ para todo x** (si no, la suma de infinitas probabilidades positivas divergería). Sin embargo, eventos como $P(a \leq X \leq b)$ sí pueden ser positivos.

La salida es cambiar la suma por una **integral**, y la f.p.p. por una **función de densidad** $f_X(x)$. Esto no es un simple cambio cosmético de notación: una densidad **no es una probabilidad** (puede valer más de 1), y esa es la trampa número uno de todo el tema — se explica en la Sección 1.

La segunda mitad del tema (1.7) extiende esta misma idea a **pares de variables** (vectores aleatorios): así como la Sección “Distribución conjunta” del Tema 1.5 definía $p(x,y) = P(X=x, Y=y)$ para el caso discreto, ahora hace falta una **densidad conjunta** $f_{\{X,Y\}}(x,y)$, de la cual se derivan las marginales, las condicionales, y el criterio de independencia. La trampa más frecuente aquí no es de cálculo sino de **soporte**: una densidad conjunta puede “verse” como si factorizara y sin embargo las variables no ser independientes, si el dominio donde vive la densidad no es un rectángulo — se explica en la Sección 5.

Regla de oro que atraviesa todo el tema: en el mundo discreto, **suma** $\leftrightarrow$ **f.p.p.** $\leftrightarrow$ **$P(X=x)$ es una probabilidad real**. En el mundo continuo, **integral** $\leftrightarrow$ **densidad** **$f(x) \leftrightarrow f(x)$ NO es una probabilidad** (es una “probabilidad por unidad de longitud”). Toda fórmula discreta de los Temas 1.5 (marginales, condicionales, independencia, esperanza de una función) tiene un espejo continuo: cambiar Σ por $\int$ y p por f .

1. La función de densidad $f_X(x)$

Definición. Una variable aleatoria X es **absolutamente continua** si existe una función $f_X : \mathbb{R} \rightarrow \mathbb{R}$ (la densidad) tal que

$$P(X \in I) = \int_I f_X(x) dx, \text{ para todo intervalo } I \subseteq \mathbb{R}.$$

Propiedades que toda densidad debe cumplir:

1. $f_X(x) \geq 0$ para todo x (positividad).
2. $\int_{-\infty}^{+\infty} f_X(x) dx = 1$ (integra uno en todo el soporte — es el análogo continuo de $\sum p(x) = 1$).

Relación con la función de distribución acumulada (f.d.a.):

$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt$, y recíprocamente $f_X(x) = F_X'(x)$ en todo punto donde F_X es derivable.

Esta segunda igualdad (derivar la f.d.a. para obtener la densidad) es, en la práctica, el método más usado para *hallar* una densidad cuando resulta más fácil calcular primero $P(X \leq x)$.

⚠ Trampa clásica de tolerancia cero — la densidad NO es una probabilidad.

A diferencia de la f.p.p. discreta $p(x) = P(X=x)$, que sí es una probabilidad y por lo tanto vive en $[0, 1]$, la densidad $f_X(x)$ puede tomar **cualquier valor no negativo**, incluso mayor que 1. Por ejemplo, la densidad Uniforme(0, 0.5) vale $f(x) = 1/0.5 = 2$ en todo el intervalo (0, 0.5) — y $2 > 1$. Lo que sí debe valer siempre entre 0 y 1 es el *área* bajo el tramo de la curva, es decir $P(X \in I) = \int_I f(x)dx$, nunca $f(x)$ mismo.

Además, para toda variable absolutamente continua, **$P(X = x) = 0$ para todo x real** (el área bajo un solo punto es cero). Por eso, a diferencia del caso discreto, da exactamente lo mismo escribir $P(a \leq X \leq b)$, $P(a < X \leq b)$, $P(a \leq X < b)$ o $P(a < X < b)$: las cuatro expresiones valen lo mismo, porque quitar o agregar los extremos no cambia el área.

Ejemplo 1.1 — Hallar una constante y calcular una probabilidad.

Sea X con densidad $f(x) = Cx^2$ en $[0, 1]$ (y 0 fuera de ese intervalo). Como debe integrar 1:

$$\int_0^1 Cx^2 dx = C/3 = 1 \Rightarrow \mathbf{C = 3}.$$

$$\text{Luego } P(X \leq 1/2) = \int_0^{1/2} 3x^2 dx = [x^3]_0^{1/2} = 1/8.$$

Verificación con Python (sympy): integrando $3x^2$ en (0,1) da exactamente 1, y $\int_0^{0.5} 3x^2 dx = 0.125 = 1/8$. ✓

2. Cambio de variable (transformación de v.a. continuas)

Problema: dada X con densidad f_X conocida, y una función $Y = g(X)$, ¿cuál es la densidad de Y ?

Caso g monótona (creciente o decreciente) y derivable. La idea clave es que el evento $\{Y \in dy\}$ es literalmente el mismo evento que $\{X \in dx\}$, donde dx y dy son intervalos infinitesimales correspondientes bajo $y = g(x)$. Esto da $P(Y \in dy) = P(X \in dx)$, es decir $f_Y(y)dy = f_X(x)dx$, de donde:

$$f_Y(y) = f_X(g^{-1}(y)) \cdot |d/dy g^{-1}(y)| = f_X(x) / |g'(x)|, \text{ con } x = g^{-1}(y).$$

El valor absoluto aparece porque una densidad nunca puede ser negativa: si g es decreciente, $dy/dx < 0$, pero lo que importa es cuánto se “estira o encoge” la longitud de un intervalo, no el signo.

Interpretación geométrica: el área bajo f_X entre x y $x+dx$ debe ser igual al área bajo f_Y entre $y=g(x)$ y $y+dy=g(x+dx)$ (es la misma probabilidad vista con otra “regla”). Si g estira los intervalos ($|g'| > 1$), la densidad de Y se *achica* proporcionalmente; si los contrae ($|g'| < 1$), la densidad de Y *crece*. Por eso aparece dividiendo y no multiplicando.

Ejemplo 2.1 — Cambio de variable completo y verificado.

Sea $X \sim \text{Exp}(1)$, es decir $f_X(x) = e^{-x}$ para $x \geq 0$. Sea $Y = \sqrt{X}$ (función creciente y biyectiva en $[0, +\infty)$).

Despejamos $x = y^2$ (la inversa), y calculamos $dx/dy = 2y$. Entonces:

$$f_Y(y) = f_X(y^2) \cdot |2y| = e^{-y^2} \cdot 2y = 2y \cdot e^{-y^2}, \text{ para } y \geq 0.$$

Verificación con Python (sympy): se calculó simbólicamente $f_Y(y) = f_X(x) \cdot |dx/dy|$ sustituyendo $x=y^2$, obteniendo exactamente `2*y*exp(-y^2)`, y se integró en $(0, \infty)$: el resultado dio **1**, confirmando que es una densidad válida. ✓

Error frecuente de tolerancia cero: olvidar el valor absoluto y arrastrar una densidad negativa cuando g es decreciente, o — más grave — despejar $x=g^{-1}(y)$ y quedarse con dy/dx en vez de invertirlo (dx/dy). La fórmula pide la derivada de la función inversa (x en términos de y), no la derivada de g directamente evaluada “al revés”.

Para el caso de dos variables, $Z = g(X, Y)$, la fórmula análoga usando derivadas parciales (que se usa por ejemplo para hallar la densidad de una suma o un producto de independientes vía convolución) es:

$$f_Z(z) = \int_{-\infty}^{+\infty} (1/|\partial_y g(x,y)|) \cdot f_{X,Y}(x,y) dx, \text{ con } z = g(x,y).$$

Un caso particular importante: si X e Y son independientes y $Z = X+Y$, se obtiene la **fórmula de convolución** $f_Z(z) = \int f_X(x) f_Y(z-x) dx$.

3. Los cuatro modelos continuos clásicos

3.1 UNIFORME(A,B)

Densidad: $f(x) = 1/(b-a)$ para $x \in (a,b)$, y 0 fuera. **Soporte:** (a,b) . **Parámetros:** $a < b$ reales.

$$E[X] = (a+b)/2 \text{ y } \text{Var}(X) = (b-a)^2/12.$$

Ejemplo 3.1 — Uniforme.

La Uniforme es la densidad “más plana” posible: todo intervalo de igual longitud dentro de (a,b) tiene la misma probabilidad, sin importar dónde esté ubicado.

Verificación con Python (sympy): se integró simbólicamente $f(x)=1/(b-a)$ en (a,b) , dando exactamente 1; se calcularon $E[X]=(a+b)/2$ y $\text{Var}(X)$ simplificada dio exactamente $(b-a)^2/12$.

✓

3.2 EXPONENCIAL(λ)

Densidad: $f(t) = \lambda e^{-\lambda t}$ para $t \geq 0$ (y 0 si $t < 0$). **Soporte:** $[0, +\infty)$. **Parámetro:** $\lambda > 0$ (tasa).

$$E[T] = 1/\lambda \text{ y } \text{Var}(T) = 1/\lambda^2.$$

La Exponencial modela **tiempos de espera hasta el primer éxito** en un proceso de Poisson (ver Sección 3.4), y es la versión continua de la distribución **Geométrica** (Tema 1.5).

Demostración completa de la falta de memoria continua. Queremos probar que, para $s, t \geq 0$:

$$P(T > s+t \mid T > s) = P(T > t).$$

Partiendo de la función de supervivencia $P(T > t) = 1 - F(t) = e^{-\lambda t}$ (que se obtiene integrando la densidad desde t hasta $+\infty$), y usando la definición de probabilidad condicional:

$$P(T > s+t \mid T > s) = P(T > s+t, T > s) / P(T > s) = P(T > s+t) / P(T > s)$$

(porque el evento $\{T > s+t\} \subseteq \{T > s\}$, así que la intersección es simplemente el más restrictivo)

$$= e^{\{-\lambda(s+t)\}} / e^{\{-\lambda s\}} = e^{\{-\lambda s\}} \cdot e^{\{-\lambda t\}} / e^{\{-\lambda s\}} = e^{\{-\lambda t\}} = P(T > t). \blacksquare$$

Interpretación: si T es el tiempo de vida de un componente (un fusible, un átomo radiactivo), “saber que ya sobrevivió un tiempo s ” no aporta ninguna información sobre cuánto más va a durar — el componente “no envejece”, es tan bueno como nuevo en cada instante.

Contraste con la falta de memoria discreta (Geométrica, Tema 1.5).

La Geométrica(p) cumple la versión discreta de la misma propiedad: $P(X > k+j \mid X > k) = P(X > j)$, con demostración idéntica en espíritu (usando $P(X > k) = (1-p)^k$ en vez de $e^{\{-\lambda k\}}$).

Este es un resultado profundo, no una coincidencia de cálculo: **la Exponencial es la ÚNICA distribución continua en $[0, +\infty)$ con la propiedad de falta de memoria, y la Geométrica es la ÚNICA distribución discreta en $\{0, 1, 2, \dots\}$ con esa propiedad.**

Intuitivamente, la Exponencial es “el límite continuo” de la Geométrica cuando se hacen los ensayos de Bernoulli cada vez más frecuentes y con probabilidad de éxito cada vez más chica (exactamente como la Poisson es el límite de la Binomial — ver Tema del Proceso de Poisson).

Ejemplo 3.2 — Verificación numérica de la falta de memoria.

Con $\lambda=0.7$, $s=1.3$, $t=2.1$: $P(T>s+t \mid T>s) = e^{\{-0.7 \cdot 3.4\}} / e^{\{-0.7 \cdot 1.3\}} = 0.229925$, y $P(T>t) = e^{\{-0.7 \cdot 2.1\}} = 0.229925$. **Coinciden exactamente** (Python, comparación con `np.isclose`: True).

Análogamente, en el caso discreto con $p=0.35$, $k_1=3$, $k_2=5$: $P(X>k_1+k_2 \mid X>k_1) = (0.65)^8 / (0.65)^3 = 0.116029 = (0.65)^5 = P(X>k_2)$. También coinciden. ✓

3.3 NORMAL(M, Σ^2)

Densidad: $\varphi_{\{\mu, \sigma^2\}}(x) = (1/(\sigma\sqrt{2\pi})) \cdot e^{\{-(x-\mu)^2/(2\sigma^2)\}}$, para todo $x \in \mathbb{R}$. **Soporte:** toda la recta real. **Parámetros:** $\mu \in \mathbb{R}$ (media, centro de simetría) y $\sigma^2 > 0$ (varianza, “ancho” de la campana).

$$E[X] = \mu \text{ y } \text{Var}(X) = \sigma^2.$$

Cuando $\mu=0$ y $\sigma^2=1$ se llama **normal estándar**, se nota $Z \sim N(0,1)$, y su densidad se escribe $\varphi(z) = (1/\sqrt{2\pi})e^{\{-z^2/2\}}$. Su f.d.a. $\Phi(z) = P(Z \leq z)$ **no tiene primitiva elemental** (teorema de Risch), por eso se usan tablas o software.

Estandarización. Si $X \sim N(\mu, \sigma^2)$, entonces $Z = (X-\mu)/\sigma \sim N(0,1)$. Esto permite calcular cualquier probabilidad de una normal general reduciéndola a la tabla de la normal estándar:

$$P(a \leq X \leq b) = \Phi((b-\mu)/\sigma) - \Phi((a-\mu)/\sigma).$$

Ejemplo 3.3 — Uso de tabla, paso a paso (igual al del apunte de cátedra).

Sea $X \sim N(1.5, 4)$, es decir $\mu=1.5$ y $\sigma^2=4 \Rightarrow \sigma=2$. Calcular $P(0.16 < X < 6.12)$.

Paso 1 — estandarizar los extremos:

$$z_a = (0.16 - 1.5)/2 = -0.67$$

$$z_b = (6.12 - 1.5)/2 = 2.31$$

Paso 2 — buscar en la tabla de la normal estándar:

$\Phi(2.31) = 0.9896$ (lectura directa de tabla).

$\Phi(-0.67) = 1 - \Phi(0.67) = 1 - 0.7486 = 0.2514$ (por simetría, ya que la tabla solo trae valores positivos).

Paso 3 — restar:

$$P(0.16 < X < 6.12) = 0.9896 - 0.2514 = \mathbf{0.7382}.$$

Verificación con Python (scipy.stats.norm): `norm.cdf(2.31) = 0.9896`,

`norm.cdf(-0.67) = 0.2514`, diferencia = **0.7381** (coincide, la diferencia de 0.0001 respecto al valor de tabla es solo redondeo de tabla a 4 decimales). También se verificó con

`norm.cdf(6.12, loc=1.5, scale=2) - norm.cdf(0.16, loc=1.5, scale=2) = 0.7381`, calculando directamente sobre la normal general sin estandarizar a mano — mismo resultado.

✓

Truco de verificación rápida: antes de restar dos valores de tabla, comprobá que el resultado tenga sentido: como Φ es creciente, siempre $\Phi(z_b)$ debe ser mayor que $\Phi(z_a)$ si $z_b > z_a$, y la diferencia final debe quedar en $(0,1)$. Un resultado negativo o mayor que 1 indica que invertiste el orden de la resta o el signo de algún z .

3.4 GAMMA(A,Λ)

Densidad: $f(x) = (\lambda^\alpha / \Gamma(\alpha)) \cdot x^{\alpha-1} \cdot e^{-\lambda x}$, para $x > 0$ (donde $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$ es la función Gamma, que para α entero coincide con $(\alpha-1)!$). **Soporte:** $(0, +\infty)$. **Parámetros:** $\alpha > 0$ (forma) y $\lambda > 0$ (tasa, misma unidad que en la Exponencial).

$$E[X] = \alpha/\lambda \text{ y } \text{Var}(X) = \alpha/\lambda^2.$$

Relación con la suma de exponenciales i.i.d. (proceso de Poisson). Si $T_1, T_2, \dots, T_k$ son variables i.i.d. $\text{Exp}(\lambda)$ — por ejemplo, los tiempos entre eventos consecutivos de un proceso de Poisson de tasa λ — entonces la suma $T_1 + \dots + T_k$, que representa **el tiempo de espera hasta el k-ésimo evento**, tiene distribución **Gamma(k, λ)**. Con $\alpha=k$ entero esta variante se llama a veces distribución de **Erlang**.

Esto generaliza directamente la Exponencial: $\text{Gamma}(1, \lambda) = \text{Exp}(\lambda)$ (el “tiempo hasta el primer evento” es un caso particular con $k=1$).

Caso particular relevante: cuando $\alpha = k/2$ (k entero positivo) y $\lambda = 1/2$, la distribución $\text{Gamma}(k/2, 1/2)$ se llama **Chi-cuadrado con k grados de libertad** (χ^2_k), muy usada más adelante en inferencia estadística (intervalos de confianza y tests para la varianza). Si el módulo de cátedra que estás usando la introduce, esta es su definición formal en términos de la Gamma.

Ejemplo 3.4 — Gamma como suma de exponenciales, verificado con sympy + Monte Carlo.

Se verificó simbólicamente con sympy que $\int_0^\infty f(x)dx = 1$ para $\alpha=1,2,3,4$ (todas dieron exactamente 1.000000), y que para $\alpha=3$ (entero), $E[X] = 3/\lambda$ y $\text{Var}(X) = 3/\lambda^2$ (coinciden con α/λ y α/λ^2 con $\alpha=3$). ✓

Verificación por simulación (Monte Carlo, $\lambda=2$, $N=2\,000\,000$): se generaron 2 millones de tripletas de $\text{Exp}(2)$ independientes y se sumaron cada tres; la media de esas sumas dio 1.4994 (teórico: $3/2=1.5000$) y la varianza 0.7487 (teórico: $3/4=0.7500$). Además, los cuantiles (10%,25%,50%,75%,90%) de “suma de 3 exponenciales” [0.5506, 0.8631, 1.337, 1.9609, 2.6588] coinciden con los de una $\text{Gamma}(3,2)$ generada directamente [0.5513, 0.8636, 1.3371, 1.9581, 2.6572] y con los teóricos de `scipy.stats.gamma` [0.551, 0.8636, 1.337, 1.9602, 2.6612], confirmando que “suma de 3 $\text{Exp}(\lambda)$ i.i.d.” y “ $\text{Gamma}(3,\lambda)$ ” son, en efecto, la misma distribución. ✓

4. Distribución de vectores aleatorios: conjunta, marginales, condicionales

Así como en el Tema 1.5 la distribución conjunta discreta era $p(x,y)=P(X=x,Y=y)$ y las marginales se obtenían sumando filas/columnas de la tabla de contingencia, en el caso continuo:

Función de distribución conjunta: $F_{\{X,Y\}}(x,y) = P(X \leq x, Y \leq y)$.

Densidad conjunta $f_{\{X,Y\}}(x,y)$: función tal que, para toda región B del plano,

$$P((X,Y) \in B) = \iint_B f_{\{X,Y\}}(x,y) \, dx \, dy,$$

con las mismas dos condiciones que en una dimensión: $f_{\{X,Y\}}(x,y) \geq 0$, y $\iint_{\mathbb{R}^2} f_{\{X,Y\}}(x,y) \, dx \, dy = 1$ (el volumen total bajo la superficie es 1).

Densidades marginales. Se obtienen “integrando la otra variable” (el análogo continuo de sumar filas/columnas):

$$f_X(x) = \int_{-\infty}^{+\infty} f_{\{X,Y\}}(x,y) \, dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f_{\{X,Y\}}(x,y) \, dx.$$

Densidad condicional. Se define, para $f_Y(y) > 0$, como

$$f_{\{X|Y\}}(x|y) = f_{\{X,Y\}}(x,y) / f_Y(y).$$

(Y simétricamente $f_{\{Y|X\}}(y|x) = f_{\{X,Y\}}(x,y)/f_X(x)$ para $f_X(x) > 0$.) La condición $f_Y(y) > 0$ es indispensable: no tiene sentido condicionar sobre un valor de Y que tiene densidad nula en ese punto.

Ejemplo 4.1 — Marginales sobre un triángulo (caso con soporte no rectangular).

Sea (X,Y) uniforme en el triángulo $T = \{(x,y) : 0 < x < y < 1\}$. Como el área de T es $1/2$, la densidad conjunta constante que integra 1 es $f(x,y) = 2$ en T , y 0 fuera.

Marginal de X (fijo x , y recorre desde x hasta 1 — ¡el límite inferior de integración depende de x , porque el soporte es un triángulo!):

$$f_X(x) = \int_{y=x}^1 2 \, dy = 2(1-x), \text{ para } 0$$

Marginal de Y (fijo y , x recorre desde 0 hasta y):

$$f_Y(y) = \int_{x=0}^y 2 \, dx = 2y, \text{ para } 0$$

Verificación con Python (sympy): se integró simbólicamente $f(x,y)=2$ con esos límites variables, obteniendo exactamente $f_X(x)=2-2x=2(1-x)$ y $f_Y(y)=2y$; y se verificó que $\int_0^1 \int_x^1 2 \, dy \, dx = 1$ (integral doble sobre todo el triángulo). ✓ (Este ejemplo se retoma en la Sección 5 para mostrar que X e Y NO son independientes.)

5. Independencia de variables aleatorias continuas

Definición. Dos variables aleatorias continuas X e Y (con densidad conjunta $f_{\{X,Y\}}$) son **independientes** si y solo si

$$f_{\{X,Y\}}(x,y) = f_X(x) \cdot f_Y(y), \text{ para todo } (x,y) \in \mathbb{R}^2.$$

Es el espejo exacto de la condición discreta $p(x,y) = p_X(x) \cdot p_Y(y)$ del Tema 1.5.

⚠ Trampa de tolerancia cero — el criterio tiene DOS partes, no una.

Para que X e Y sean independientes hacen falta **dos** cosas simultáneamente:

1. Que la densidad conjunta **factorice algebraicamente** como producto de una función solo de x por una función solo de y .
2. Que el **soporte** (la región donde $f_{\{X,Y\}}$ es distinta de cero) sea un **rectángulo** — es decir, un producto cartesiano de un intervalo de x por un intervalo de y , sin que los límites de una variable dependan de la otra.

Si el soporte no es un rectángulo (por ejemplo, un triángulo, un círculo, o cualquier región donde el rango de x depende de y o viceversa), **las variables NO son independientes**, aunque la fórmula de $f_{\{X,Y\}}$ “parezca” simple o incluso constante. La razón de fondo: si supieras que $Y=0.9$ en el triángulo $\{0$

Ejemplo 5.1 — Conjunta que NO es independiente (soporte triangular, sección 4.1 continuada).

Retomando el triángulo $T=\{0 \leq x \leq 1, 0 \leq y \leq 1-x\}$, $f_X(x) \cdot f_Y(y) = 2(1-x) \cdot 2y = 4y(1-x)$, que **no es igual** a $f(x,y)=2$ (una es constante, la otra depende de x e y).

Por ejemplo en $(x,y)=(0.2,0.3)$: $f(0.2,0.3)=2$ (Si está en el soporte, porque $0 < 0.2 < 0.3 < 1$), pero $f_X(0.2) \cdot f_Y(0.3) = 2(0.8) \cdot 2(0.3) = 1.6 \cdot 0.6 = 0.96 \neq 2$.

Conclusión: X e Y NO son independientes — a pesar de que la densidad conjunta es la función constante más simple posible, 2. La causa es exclusivamente el soporte triangular (no rectangular): al fijar $Y=y$, el rango de X (que es $(0,y)$) cambia con y .

Verificación con Python: se confirmó simbólicamente que $f(x,y)=2 \neq f_X(x)f_Y(y)=4y(1-x)$ en general, evaluando numéricamente en $(0.2,0.3)$. ✓

Ejemplo 5.2 — Conjunta que SÍ es independiente (soporte rectangular).

Sean $X \sim \text{Exp}(\lambda)$ e $Y \sim \text{Exp}(\mu)$ independientes, con soporte cada una en $(0, +\infty)$. El soporte conjunto es $(0, +\infty) \times (0, +\infty)$, que **sí es un rectángulo** (infinito, pero rectángulo al fin: los límites de x no dependen de y).

Por definición de independencia, $f_{\{X,Y\}}(x,y) = \lambda e^{-\lambda x} \cdot \mu e^{-\mu y} = \lambda \mu \cdot e^{-\lambda x - \mu y}$. Al calcular $P(X \leq x, Y \leq y)$.

Verificación con Python (sympy, simbólico): se calculó la integral doble

simbólicamente con λ y μ genéricos, obteniendo exactamente $\frac{1}{\lambda + \mu}$. ✓

Verificación por simulación (Monte Carlo, $\lambda=1.3$, $\mu=2.7$, $N=2\,000\,000$): $P(X$

Ejemplo 5.3 — Contraejemplo aún más sutil: factoriza en $x \cdot y$ pero el soporte NO es rectangular.

Sea $f(x,y) = 8xy$ en el mismo triángulo $T = \{0 \leq x \leq 1, 0 \leq y \leq 1-x\}$.
 $f_X(x) = \int_0^{1-x} 8xy \, dy = 4x(1-x)^2$,
 $f_Y(y) = \int_0^1 8xy \, dx = 4y^3$.

El producto $f_X(x)f_Y(y) = 4x(1-x)^2 \cdot 4y^3 = 16xy^3(1-x)^2$, que en $(0.2, 0.3)$ vale 0.0829, mientras que $f(0.2, 0.3) = 8(0.2)(0.3) = 0.48$. ****No coinciden $\Rightarrow$ NO independientes****, confirmando otra vez que el soporte triangular por sí solo ya descarta la independencia, sin importar qué tan “factorizable” luzca la fórmula de $f(x,y)$.

Verificación con Python: confirmado simbólicamente y numéricamente ($0.48 \neq 0.0829$). ✓

6. Trampas típicas de examen (resumen de errores frecuentes)

⚠ Trampa 1 — Confundir densidad marginal con densidad condicional.

$f_X(x)$ (marginal) es una función de x sola, obtenida *integrando* a Y afuera de la conjunta — describe el comportamiento de X “promediando” sobre todos los valores de Y . $f_{X|Y}(x|y)$ (condicional) es también función de x , pero para un valor de y **fijo**, y se obtiene *dividiendo* la conjunta por $f_Y(y)$, no integrando. Son objetos distintos: la marginal no depende de ningún valor particular de y , la condicional sí. Un error muy común es escribir $f_X(x)$ cuando en realidad el ejercicio pide $f_{X|Y}(x|y_0)$ para un y_0 dado.

⚠ Trampa 2 — Olvidar que el soporte determina los límites de integración.

Cuando el soporte de (X,Y) no es un rectángulo (por ejemplo, un triángulo como el de la figura), una variable depende del valor de la **otra**. Al calcular $f_X(x) = \int f_{X,Y}(x,y) \, dy$, hay que preguntarse primero: “para este x fijo, ¿entre qué valores se mueve y dentro del soporte?” — y esos límites, no “ $-\infty$ a $+\infty$ ” mecánicamente, son los que hay que usar. Poner límites constantes cuando en realidad dependen de la otra variable es el error de cálculo más común en integrales dobles de este tema (ver Ejemplos 4.1 y 5.1).

⚠ Trampa 3 — Multiplicar probabilidades sin haber verificado independencia.

Antes de escribir $P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B)$ hay que **justificar** la independencia, chequeando las DOS condiciones de la Sección 5: (a) que $f_{\{X,Y\}}$ factorice algebraicamente como $f_X(x)f_Y(y)$, Y (b) que el soporte conjunto sea un rectángulo. Faltar cualquiera de las dos invalida la factorización de probabilidades. En el examen, si el enunciado da directamente “X e Y independientes con densidades f_X y f_Y ”, no hace falta verificar nada — pero si da una densidad conjunta $f_{\{X,Y\}}(x,y)$ y pregunta si son independientes, hay que hacer ambas verificaciones explícitamente (Ejemplos 5.1, 5.2 y 5.3 arriba).

Tabla de referencia rápida de los 4 modelos

Modelo	Densidad	Soporte	Parámetros	$E[X]$	$\text{Var}(X)$
Uniforme(a,b)	$1/(b-a)$	(a,b)	$a < b$	$(a+b)/2$	$(b-a)^2/12$
Exponencial(λ)	$\lambda e^{-\lambda x}$	$(0, +\infty)$	$\lambda > 0$	$1/\lambda$	$1/\lambda^2$
Normal(μ, σ^2)	$(1/(\sigma\sqrt{2\pi}))e^{-(x-\mu)^2/2\sigma^2}$	$\mathbb{R}$	$\mu \in \mathbb{R}, \sigma^2 > 0$	μ	σ^2
Gamma(α, λ)	$(\lambda^\alpha/\Gamma(\alpha))x^{\alpha-1}e^{-\lambda x}$	$(0, +\infty)$	$\alpha > 0, \lambda > 0$	α/λ	α/λ^2

Ejercicios de repaso rápido (con respuesta)

#	Enunciado	Respuesta
1	¿ $f(x)=1.5$ en algún tramo puede ser una densidad válida?	Sí — una densidad puede ser mayor que 1, lo único que no puede es ser negativa ni dejar de integrar 1
2	Si X es absolutamente continua, ¿cuánto vale $P(X=3)$?	0, para cualquier valor puntual, sin importar cuál
3	$X \sim \text{Exp}(2)$. ¿Cuánto vale $P(X>5 X>2)$?	Por falta de memoria = $P(X>3) = e^{-6}$
4	$Y=aX+b$ con $X \sim U(0,1)$ y $a>0$. ¿Distribución de Y ?	Uniforme($b, a+b$), densidad $1/a$ en ese intervalo
5	$X \sim N(10,25)$. ¿Cuánto vale $\text{Var}(X)$ y σ ?	$\text{Var}(X)=25$, $\sigma=5$ (σ^2 es el segundo parámetro, no σ !)
6	Suma de 4 exponenciales i.i.d. $\text{Exp}(3)$. ¿Qué distribución tiene?	$\text{Gamma}(4,3)$ — tiempo hasta el 4º evento de un proceso de Poisson de tasa 3
7	(X,Y) uniforme en el círculo unitario. ¿ X e Y son independientes?	No — el soporte (círculo) no es un rectángulo, aunque la densidad sea constante
8	$f_{\{X,Y\}}(x,y)=e^{-x}e^{-y}$ para $x,y>0$. ¿Independientes?	Sí — factoriza en $f(x) \cdot f(y)$ Y el soporte $(0,\infty) \times (0,\infty)$ es un rectángulo
9	$f_{\{X Y\}}(x y)$ se calcula...	Dividiendo $f_{\{X,Y\}}(x,y)$ entre $f_Y(y)$, con $f_Y(y)>0$
10	¿Cuál es la única distribución discreta con falta de memoria?	La Geométrica (análoga discreta de la Exponencial)

Resumen ultra-rápido (2 minutos)

- **Densidad $f_X(x)$:** $f_X \geq 0$, $\int f_X = 1$, **NO es una probabilidad** (puede ser >1); $P(X=x)=0$ siempre. $F_X(x) = \int_{-\infty}^x f_X$, y $f_X = F_X'$ donde F_X es derivable.
- **Cambio de variable** (g monótona): $f_Y(y) = f_X(x) \cdot |dx/dy|$, con $x=g^{-1}(y)$ — nunca olvidar el valor absoluto.
- **Uniforme(a,b):** pareja, $E=(a+b)/2$, $\text{Var}=(b-a)^2/12$.

- **Exponencial(λ):** $E=1/\lambda$, $Var=1/\lambda^2$, **falta de memoria** $P(T>s+t|T>s)=P(T>t)$ — única continua con esa propiedad (análoga discreta: Geométrica).
- **Normal(μ, σ^2):** estandarizar $Z=(X-\mu)/\sigma \sim N(0, 1)$, usar tabla de Φ , simetría $\Phi(-z)=1-\Phi(z)$.
- **Gamma(α, λ):** $E=\alpha/\lambda$, $Var=\alpha/\lambda^2$ — suma de α exponenciales $Exp(\lambda)$ i.i.d. = tiempo hasta el α -ésimo evento de un proceso de Poisson de tasa λ ; $Gamma(1, \lambda)=Exp(\lambda)$.
- **Vector aleatorio:** $f_{\{X,Y\}}(x,y) \geq 0$, $\iint f_{\{X,Y\}}=1$. Marginal: integrar la otra variable (¡cuidado con límites que dependen de la otra variable si el soporte no es un rectángulo!). Condicional: $f_{\{X|Y\}}(x|y)=f_{\{X,Y\}}(x,y)/f_Y(y)$.
- **Independencia:** $f_{\{X,Y\}}(x,y)=f_X(x)f_Y(y)$ **para todo (x,y)** , Y el soporte debe ser un **rectángulo** — faltando cualquiera de las dos condiciones, NO son independientes.
- **Verificación obligatoria en todo ejercicio:** si el soporte no es un rectángulo (triángulo, círculo, etc.), las variables nunca son independientes, sin importar qué tan simple luzca la fórmula de la densidad conjunta.