

CONTENTS

Esperanza, Varianza, Covarianza y Ley de los Grandes Números

Guía de estudio con tolerancia cero — Temas 2.1 y 2.2, Probabilidad y Estadística (FING UdelaR)

0. Por qué existen estos temas

1. Valor esperado $E(X)$

1.1 Definición

1.2 Teorema del estadístico inconsciente (esperanza de una función de X)

1.3 Linealidad de la esperanza

2. Varianza, desvío estándar y momentos

2.1 Definición

2.2 Fórmula práctica: $\text{Var}(X) = E(X^2) - E(X)^2$

2.3 Propiedades de la varianza

2.4 Momentos de orden k

3. Desigualdad de Chebyshev

3.1 Motivación y enunciado

3.2 Demostración (vía desigualdad de Markov)

3.3 Ejemplo numérico: qué tan conservadora es la cota

3.4 Corolario útil: forma con k desvíos

4. Covarianza y correlación

4.1 Definición

4.2 Relación con independencia — ida sí, vuelta no	
4.3 Coeficiente de correlación y su rango [-1, 1]	
4.4 Propiedades de la covarianza (producto interno)	
5. Varianza de una suma: $\text{Var}(X+Y)$	
5.1 Fórmula general	
5.2 Caso particular: independientes (o solo incorrelacionadas)	
5.3 Generalización a n variables	
6. Variables i.i.d. y la Ley de los Grandes Números	
6.1 Notación i.i.d. y esperanza/varianza del promedio	
6.2 Enunciado de la LGN débil	
6.3 Demostración vía Chebyshev	
6.4 LGN fuerte (mención)	
6.5 Verificación numérica: convergencia del promedio muestral	
7. Introducción a estimadores	
7.1 Qué es un estimador puntual	
7.2 Sesgo e insesgadez	
7.3 Consistencia — relación directa con la LGN	
8. Trampas típicas de examen — resumen	
Tabla de referencia rápida	
Resumen ultra-rápido (2 minutos)	

Esperanza, Varianza, Covarianza y Ley de los Grandes Números

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMAS 2.1 Y 2.2, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existen estos temas

Hasta este punto del curso ya sabés describir **toda** la distribución de una variable aleatoria (f.p.p. o densidad, f.d.a.). Pero en la práctica casi nunca se necesita — ni se puede manejar — la distribución completa: lo que hace falta es **resumir** esa distribución en un puñado de números que capturen lo esencial. Esos números son el valor esperado (dónde “está centrada” la variable) y la varianza (qué tan dispersa está alrededor de ese centro).

La segunda motivación, más profunda, es esta pregunta: *si repito un experimento aleatorio muchísimas veces y promedio los resultados, ¿a qué converge ese promedio?* La respuesta — a la esperanza, con una velocidad de convergencia que se puede cuantificar — es la **Ley de los Grandes Números (LGN)**, y es la base teórica de absolutamente todo lo que se hace después en el curso: estimación de parámetros, intervalos de confianza, tests de hipótesis. Un estimador (como el promedio muestral) solo es útil porque, por la LGN, se acerca al valor real que se quiere medir a medida que hay más datos.

La **covarianza** completa el panorama: mide si dos variables tienden a moverse juntas, y es la pieza que falta para calcular la varianza de una suma cuando las variables **no** son independientes — un error de examen extremadamente común es olvidar este término.

Hilo conductor de todo el tema: **$E(X)$** resume el centro, **$\text{Var}(X)$** resume la dispersión, **$\text{Cov}(X, Y)$** resume la relación lineal entre dos variables, y la **LGN** explica por qué el promedio de muchas observaciones es un buen estimador de $E(X)$. Todo lo demás (Chebyshev, momentos, inesgidez, consistencia) son herramientas al servicio de estas cuatro ideas.

1. Valor esperado $E(X)$

1.1 DEFINICIÓN

Caso discreto. Si X es discreta con recorrido $R_X = \{x_1, x_2, \dots\}$ y f.p.p. $p(x)$:

$$E(X) = \sum_{x \in R_X} x \cdot p(x)$$

Caso continuo. Si X es continua con densidad $p(x)$:

$$E(X) = \int_{-\infty}^{+\infty} x p(x) dx$$

Interpretación física (muy usada en el curso): $E(X)$ es el **centro de masa** de la distribución — si en cada valor x_i pongo un “bloque” que pesa $p(x_i)$ kg sobre un tablón, el punto de apoyo donde el tablón queda en equilibrio es exactamente $E(X)$.

Interpretación frecuentista: si repito el experimento n veces y promedio los resultados, ese promedio converge a $E(X)$ cuando $n \rightarrow \infty$ (esto ya es, informalmente, la LGN — se demuestra rigurosamente en la Sección 6).

Ejemplo 1.1 — Bernoulli. Si $X \sim \text{Ber}(p)$, entonces $E(X) = 1 \cdot p + 0 \cdot (1-p) = p$. Este resultado es tan usado que conviene memorizarlo: la esperanza de un indicador de un evento es exactamente la probabilidad de ese evento.

Ejemplo 1.2 — Uniforme continua. Si $X \sim U(a,b)$, su densidad es $p(x) = 1/(b-a)$ en (a,b) . Entonces $E(X) = \int_a^b x/(b-a) dx = (a+b)/2$ (el punto medio, por simetría). **Verificación en Python** ($a=2$, $b=10$, teórico = 6):

```
import numpy as np
np.random.seed(0)
x = np.random.uniform(2, 10, 2_000_000)
print(x.mean()) # -> 5.9994... (converge a 6.0)
```

1.2 TEOREMA DEL ESTADÍSTICO INCONSCIENTE (ESPERANZA DE UNA FUNCIÓN DE X)

Si $Y = g(X)$ para alguna función g , **no hace falta calcular la distribución de Y** para hallar $E(Y)$: alcanza con “pesar” $g(x)$ con la distribución de X .

Discreto: $E(g(X)) = \sum_{x \in R_X} g(x) \cdot p(x)$ **Continuo:** $E(g(X)) = \int_{-\infty}^{+\infty} g(x) p(x) dx$

Se llama “del estadístico inconsciente” porque se usa constantemente sin siquiera notar que es un teorema (y no la definición de esperanza) — de hecho, es la forma en que se define **Var(X)** en la Sección 2, tomando $g(x) = (x - E(X))^2$.

Ejemplo 1.3. Sea X con f.p.p. $p(1)=p(2)=p(3)=1/3$. Calcular $E(X^2)$ sin hallar la distribución de X^2 . $E(X^2) = 1^2 \cdot (1/3) + 2^2 \cdot (1/3) + 3^2 \cdot (1/3) = (1+4+9)/3 = 14/3 \approx 4.667$. **Verificación:** la distribución de $Y=X^2$ es $p(1)=p(4)=p(9)=1/3$, y $E(Y) = (1+4+9)/3 = 14/3 \checkmark$ (coincide, como debe ser).

1.3 LINEALIDAD DE LA ESPERANZA

Esta es la propiedad más importante y más usada del curso, porque vale **siempre**, sin ninguna hipótesis de independencia:

Para X, Y variables aleatorias cualesquiera (con esperanza finita) y a, b constantes: **$E(aX + b) = a \cdot E(X) + b$** **$E(X + Y) = E(X) + E(Y)$** — vale aunque X e Y sean dependientes.

Error frecuente de tolerancia cero: pensar que $E(X+Y)=E(X)+E(Y)$ “requiere independencia”. **No.** La linealidad de la esperanza no pide nada sobre la relación entre X e Y — es simplemente linealidad de una suma/integral. Lo que Sí requiere independencia es $E(XY)=E(X)E(Y)$ (ver Sección 4) y $\text{Var}(X+Y)=\text{Var}(X)+\text{Var}(Y)$ (ver Sección 5). Confundir estas dos propiedades es el error más común del tema.

Ejemplo 1.4 — Truco de “partir en Bernoulli” (problema de cumpleaños). En un grupo de n personas, ¿cuántas coincidencias de cumpleaños se esperan? Para cada par $\{i,j\}$ defino $X_{ij} \sim \text{Ber}(1/365)$ (vale 1 si i y j cumplen el mismo día). El total de coincidencias es $X = \sum_{\{i,j\}} X_{ij}$, y aunque las X_{ij} están fuertemente correlacionadas entre sí (comparten personas), la linealidad de la esperanza no necesita independencia: $E(X) = \sum E(X_{ij}) = C(n,2) \cdot (1/365) = n(n-1)/730$. **Verificación numérica** para $n=30$: $30 \cdot 29/730 \approx 1.192$ coincidencias esperadas — consistente con el hecho conocido de que con 23-30 personas ya es “más probable que no” tener al menos una coincidencia.

```
import itertools, random
random.seed(0)
def sim(n, trials=200_000):
    total = 0
    for _ in range(trials):
        days = [random.randint(1,365) for _ in range(n)]
        total += sum(1 for i,j in itertools.combinations(range(n),2) if
days[i]==days[j])
    return total/trials
print(sim(30))    # -> approx 1.19   (teórico: 30*29/730 = 1.1918)
```

2. Varianza, desvío estándar y momentos

2.1 DEFINICIÓN

$$\text{Var}(X) = E[(X - E(X))^2]$$

Aplicando el teorema del estadístico inconsciente con $g(x)=(x-E(X))^2$: en discreto $\text{Var}(X)=\sum(x-E(X))^2p(x)$, en continuo $\text{Var}(X)=\int(x-E(X))^2p(x)dx$. Mide la dispersión de X alrededor de su centro (interpretación física: **momento de inercia** de la distribución de bloques respecto al centro de masa — cuanto más lejos están los bloques del centro, más “cuesta” hacerlos girar).

El **desvío estándar** es $\sigma = \sqrt{\text{Var}(X)}$, y tiene las mismas unidades que X (la varianza tiene unidades al cuadrado).

2.2 FÓRMULA PRÁCTICA: $\text{VAR}(X) = E(X^2) - E(X)^2$

Desarrollando el cuadrado $(X-E(X))^2 = X^2 - 2X \cdot E(X) + E(X)^2$ y tomando esperanza (usando linealidad, tratando a $E(X)$ como constante):

$$\text{Var}(X) = E(X^2) - 2E(X) \cdot E(X) + E(X)^2 = E(X^2) - E(X)^2$$

Esta es, en la práctica, la fórmula que casi siempre conviene usar para calcular, porque evita expandir $(x-E(X))^2$ dentro de la suma/integral.

Ejemplo 2.1 — Varianza de una Bernoulli. $X \sim \text{Ber}(p)$: $E(X)=p$, $E(X^2)=1^2 \cdot p + 0^2 \cdot (1-p)=p$ (porque $X^2=X$ cuando $X \in \{0,1\}$). Entonces **$\text{Var}(X) = p - p^2 = p(1-p)$** . Máximo en $p=1/2$, donde $\text{Var}(X)=1/4$ (tiene sentido: la incertidumbre es máxima cuando el resultado es “moneda justa”).

Ejemplo 2.2 — Varianza de una uniforme. $X \sim U(a,b)$: se prueba (cambio de variable a $U \sim U(0,1)$) que **$\text{Var}(X) = (b-a)^2/12$** . **Verificación numérica** ($a=2, b=10$, teórico= $(10-2)^2/12=64/12 \approx 5.333$):

```
import numpy as np
np.random.seed(0)
x = np.random.uniform(2, 10, 2_000_000)
print(x.var())    # -> 5.331... (converge a 5.333)
```

2.3 PROPIEDADES DE LA VARIANZA

1. **$\text{Var}(X + c) = \text{Var}(X)$** para cualquier constante c (sumar una constante no cambia la dispersión, solo traslada el centro).
2. **$\text{Var}(cX) = c^2 \text{Var}(X)$** (la varianza es “cuadrática” en escala — por eso el desvío σ , no la varianza, tiene las mismas unidades que X).
3. **$\text{Var}(X) \geq 0$ siempre**, y $\text{Var}(X)=0 \Leftrightarrow X$ es constante (casi seguramente).

Ejemplo 2.3. Si $\text{Var}(X)=9$ y defino $Y = 3X - 5$, entonces $\text{Var}(Y) = 3^2 \cdot \text{Var}(X) = 9 \cdot 9 = 81$ (el -5 no afecta la varianza).

2.4 MOMENTOS DE ORDEN K

El **momento de orden k** de X es $E(X^k)$. El **momento centrado de orden k** es $E[(X-E(X))^k]$.

- Momento de orden 1: $E(X)$, la esperanza misma.
- Momento centrado de orden 2: $E[(X-E(X))^2] = \text{Var}(X)$.
- Los momentos de orden superior ($k=3$, $k=4$) miden **asimetría** (skewness) y **apuntamiento/curtosis** de la distribución, respectivamente — se mencionan aquí porque el examen a veces pide “calcular el momento de orden k ” como generalización directa del cálculo de $E(X)$ y $\text{Var}(X)$, usando el teorema del estadístico inconsciente con $g(x)=x^k$ o $g(x)=(x-E(X))^k$.

Si X es una variable **centrada** ($E(X)=0$), entonces $\text{Var}(X) = E(X^2)$: el momento de orden 2 “a secas” coincide con el momento centrado de orden 2. Esta simplificación aparece seguido en demostraciones (por ejemplo, en la desigualdad de Chebyshev, Sección 3).

3. Desigualdad de Chebyshev

3.1 MOTIVACIÓN Y ENUNCIADO

Sin conocer la distribución completa de X , ¿qué tan probable es que X se aleje mucho de su esperanza? La desigualdad de Chebyshev da una cota (conservadora, válida para **cualquier** distribución con varianza finita) usando solamente $\mu=E(X)$ y $\sigma^2=\text{Var}(X)$.

Desigualdad de Chebyshev. Sea X con $E(X)=\mu$, $\text{Var}(X)=\sigma^2$. Para todo $\varepsilon>0$: **$P(|X - \mu| \geq \varepsilon) \leq \sigma^2/\varepsilon^2$**

3.2 DEMOSTRACIÓN (VÍA DESIGUALDAD DE MARKOV)

Primero, la **desigualdad de Markov**: si $Y \geq 0$ es una variable aleatoria positiva, entonces para todo $t > 0$, $P(Y \geq t) \leq E(Y)/t$.

Demostración de Markov: sea Z la Bernoulli que vale 1 si $Y \geq t$ y 0 si no, con $p = P(Y \geq t)$. Como $tZ \leq Y$ siempre (si $Z=0$ la desigualdad es trivial $0 \leq Y$; si $Z=1$ es porque $Y \geq t$), tomando esperanza: $t \cdot p = E(tZ) \leq E(Y)$, de donde $P(Y \geq t) = p \leq E(Y)/t$. ■

Demostración de Chebyshev a partir de Markov: sea $Y = (X - \mu)^2$, que es ≥ 0 y tiene $E(Y) = E[(X - \mu)^2] = \text{Var}(X) = \sigma^2$. Aplicando Markov a Y con $t = \varepsilon^2$:

$$P(Y \geq \varepsilon^2) \leq E(Y)/\varepsilon^2 = \sigma^2/\varepsilon^2$$

Pero $\{Y \geq \varepsilon^2\} = \{(X - \mu)^2 \geq \varepsilon^2\} = \{|X - \mu| \geq \varepsilon\}$ (tomando raíz cuadrada en ambos lados, válido porque ambos son ≥ 0). Por lo tanto $P(|X - \mu| \geq \varepsilon) \leq \sigma^2/\varepsilon^2$. ■

3.3 EJEMPLO NUMÉRICO: QUÉ TAN CONSERVADORA ES LA COTA

Ejemplo 3.1. Sea $\bar{X}_n$ el promedio de $n=100$ Bernoulli(0.5) independientes (por ejemplo, proporción de caras en 100 tiradas de moneda). Entonces $\mu=0.5$, $\text{Var}(\bar{X}_n) = p(1-p)/n = 0.25/100 = 0.0025$. Tomo $\varepsilon=0.1$: ¿qué tan probable es que el promedio muestral se aleje más de 0.1 de 0.5? **Cota de Chebyshev**: $P(|\bar{X}_n - 0.5| \geq 0.1) \leq 0.0025/0.01 = \mathbf{0.25}$.

Probabilidad real (calculable exactamente porque $100 \cdot \bar{X}_n \sim \text{Binomial}(100, 0.5)$): $\approx \mathbf{0.0352}$.

Verificación en Python:

```
from scipy.stats import binom
n, p, eps = 100, 0.5, 0.1
cheb_bound = (p*(1-p)/n) / eps**2
k_lo = int(n*(p-eps)) - 1 # borde inferior (entero, ceil-1)
k_hi = int(n*(p+eps))      # borde superior
real_prob = 1 - (binom.cdf(k_hi, n, p) - binom.cdf(k_lo, n, p))
print(cheb_bound, real_prob) # -> 0.25 0.0352
```

La cota de Chebyshev (0.25) es válida ($0.0352 \leq 0.25$ ✓) pero muy conservadora: sobreestima la probabilidad real por un factor ≈ 7 . Esto es típico: Chebyshev es una cota universal (vale para cualquier distribución con esa media y varianza, incluso las “peor posible”), por eso no puede ser ajustada — su ventaja es que no requiere conocer la distribución exacta.

3.4 COROLARIO ÚTIL: FORMA CON K DESVÍOS

Tomando $\varepsilon = k\sigma$ en la desigualdad:

$$P(|X - \mu| \geq k\sigma) \leq 1/k^2$$

Por ejemplo, la probabilidad de alejarse más de 2 desvíos estándar de la media es, para cualquier distribución, a lo sumo $1/4 = 25\%$ (compárese con el caso normal, donde es exactamente $\approx 4.5\%$ — de nuevo, Chebyshev es conservadora).

Errores frecuentes de tolerancia cero con Chebyshev:

- **Aplicarla sin verificar que la varianza es finita.** Si $\text{Var}(X) = \infty$ (existen distribuciones así, como la Cauchy), la cota es $\sigma^2/\varepsilon^2 = \infty$, es decir, no dice nada — la desigualdad sigue siendo “cierta” pero inútil.
- **Usar la varianza incorrecta.** Si $X_1, \dots, X_n$ son i.i.d. con varianza σ^2 , la desigualdad para el **promedio** $\bar{X}_n$ usa $\text{Var}(\bar{X}_n) = \sigma^2/n$, **no** σ^2 a secas. Confundir la varianza de una observación individual con la del promedio es el error más común en ejercicios de “cuántos datos necesito” (ver Ejercicio 1 del Práctico 8, resuelto en el archivo de ejercicios).
- **Tratarla como una igualdad.** Chebyshev da una cota superior, no el valor exacto de la probabilidad — nunca escribir “=” donde corresponde “ $\leq$ ”.

4. Covarianza y correlación

4.1 DEFINICIÓN

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

(la segunda igualdad se prueba desarrollando el producto, igual que con la varianza — de hecho **$\text{Cov}(X, X) = \text{Var}(X)$** , la varianza es un caso particular de covarianza).

4.2 RELACIÓN CON INDEPENDENCIA — IDA SÍ, VUELTA NO

Si X e Y son **independientes**, entonces $E(XY) = E(X)E(Y)$, y por lo tanto **$\text{Cov}(X, Y) = 0$** .

⚠ Trampa de tolerancia cero — el recíproco es FALSO en general. $\text{Cov}(X, Y) = 0$ (variables “in correlacionadas”) **no implica** independencia. Contraejemplo explícito (de la clase 10 del curso): Sea X que vale 1 o -1 con probabilidad 1/2 cada uno. Sea $Y = 0$ si $X = -1$, y si

$X=1$, Y vale 1 o -1 con probabilidad 1/2 cada uno (independiente del signo de X en ese caso).

	$X=-1$	$X=1$	p_Y
$Y=-1$	0	1/4	1/4
$Y=0$	1/2	0	1/2
$Y=1$	0	1/4	1/4
p_X	1/2	1/2	1

$E(X)=0$, $E(Y)=0$, $E(XY) = (-1)(0)(0) + (-1)(1)(0) + (-1)(-1)(1/4) + (1)(-1)(1/4) + (1)(0)(1/2) + (1)(1)(1/4) = 1/4 - 1/4 + 1/4 = 1/4$... calculando directo de la tabla: $E(XY) = \sum xy \cdot p(x,y) = (-1)(-1)(0) + (-1)(0)(1/2) + (-1)(1)(0) + (1)(-1)(1/4) + (1)(0)(0) + (1)(1)(1/4) = -1/4 + 1/4 = 0$. Entonces $\text{Cov}(X,Y) = E(XY) - E(X)E(Y) = 0 - 0 = 0$. Pero la tabla conjunta claramente **no** es el producto de las marginales: $P(X=-1, Y=0) = 1/2 \neq P(X=-1)P(Y=0) = (1/2)(1/2) = 1/4$. Por lo tanto X e Y **no son independientes** a pesar de tener covarianza cero — Y depende fuertemente de X (si $X=-1$, Y es determinísticamente 0), solo que esa dependencia no es de tipo *lineal*, que es todo lo que la covarianza puede detectar.

```
import numpy as np
np.random.seed(0)
n = 2_000_000
X = np.random.choice([-1,1], size=n)
Y = np.where(X==-1, 0, np.random.choice([-1,1], size=n))
print("Cov empírica:", np.cov(X,Y)[0,1]) # -> approx 0.000x (converge a 0)
```

Caso especial donde Sí vale la vuelta: si X e Y son ambas **Bernoulli**, entonces $\text{Cov}(X,Y)=0 \Leftrightarrow$ independencia (porque XY también es Bernoulli, y su parámetro $P(X=1, Y=1)$ coincide con $P(X=1)P(Y=1)$ exactamente cuando $\text{Cov}=0$ — no hay margen para dependencia “no lineal” con solo dos valores posibles).

4.3 COEFICIENTE DE CORRELACIÓN Y SU RANGO [-1, 1]

$$\rho_{X,Y} = \text{Cov}(X,Y) / (\sigma_X \sigma_Y)$$

Demostración de que $|\rho| \leq 1$ (vía discriminante — forma elemental, sin necesitar Cauchy-Schwarz general):

Para cualquier $a \in \mathbb{R}$, $\text{Var}(Y - aX) \geq 0$ (toda varianza es no negativa). Desarrollando:

$$\text{Var}(Y - aX) = a^2 \text{Var}(X) - 2a \cdot \text{Cov}(X, Y) + \text{Var}(Y) \geq 0$$

Esto es un polinomio cuadrático en a que nunca es negativo — para que un polinomio cuadrático (con coeficiente principal $\text{Var}(X) > 0$) sea siempre ≥ 0 , su **discriminante debe ser ≤ 0** :

$$\Delta = [2\text{Cov}(X, Y)]^2 - 4\text{Var}(X)\text{Var}(Y) \leq 0 \Rightarrow \text{Cov}(X, Y)^2 \leq \text{Var}(X)\text{Var}(Y) \Rightarrow |\text{Cov}(X, Y)| \leq \sigma_X \sigma_Y \Rightarrow |\rho_{X,Y}| \leq 1 \blacksquare$$

Esta es exactamente la desigualdad de **Cauchy-Schwarz** aplicada a variables aleatorias (pensando a Cov como un producto interno y a σ como una norma).

Caso extremo $\rho = \pm 1$: si $|\rho| = 1$, el discriminante es exactamente 0, entonces existe un único a_0 con $\text{Var}(Y - a_0 X) = 0$, es decir $Y - a_0 X$ es constante c.s. — **Y es una función lineal exacta de X** ($Y = a_0 X + b$). Correlación ± 1 es el caso de dependencia lineal perfecta; el signo de ρ coincide con el signo de a_0 .

Ejemplo 4.1 — Verificación numérica de $|\rho| \leq 1$ y de Cov entre Bernoulli.

```
import numpy as np
np.random.seed(0)
n = 2_000_000
X = np.random.binomial(1, 0.3, n)
# Y depende de X (correlación positiva)
Y = np.where(X==1, np.random.binomial(1, 0.8, n), np.random.binomial(1, 0.2, n))
rho = np.corrcoef(X, Y)[0,1]
print("rho:", rho)      # -> valor en (-1,1), en este caso positivo (~0.6)
print("|rho|<=1:", abs(rho) <= 1)  # True
```

4.4 PROPIEDADES DE LA COVARIANZA (PRODUCTO INTERNO)

- **Simétrica:** $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.
- **Bilineal:** $\text{Cov}(aX + Y, Z) = a \cdot \text{Cov}(X, Z) + \text{Cov}(Y, Z)$.
- **$\text{Cov}(X, X) = \text{Var}(X) \geq 0$** , y $\text{Cov}(X, X) = 0 \Leftrightarrow X$ es constante.

Esto justifica pensar $\sigma_X = \sqrt{\text{Var}(X)}$ como una “norma” (longitud) y ρ como el coseno del ángulo entre X e Y — cuando $\rho = 0$ se dice que X e Y son **ortogonales**.

5. Varianza de una suma: $\text{Var}(X+Y)$

5.1 FÓRMULA GENERAL

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \cdot \text{Cov}(X, Y)$$

Demostración: $\text{Var}(X+Y) = E[(X+Y-E(X)-E(Y))^2] = E[((X-E(X))+(Y-E(Y)))^2]$. Desarrollando el cuadrado del binomio:

$$= E[(X-E(X))^2] + E[(Y-E(Y))^2] + 2E[(X-E(X))(Y-E(Y))] = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) \blacksquare$$

5.2 CASO PARTICULAR: INDEPENDIENTES (O SOLO INCORRELACIONADAS)

Si $\text{Cov}(X, Y) = 0$ (en particular si X e Y son independientes), el término cruzado se anula:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) \text{ (si } \text{Cov}(X, Y) = 0\text{)}$$

Esto se llama, por analogía geométrica, **Teorema de Pitágoras** para varianzas: $\sigma^2_{X+Y} = \sigma^2_X + \sigma^2_Y$ cuando X e Y son “ortogonales” ($\text{Cov} = 0$).

⚠ EL ERROR MÁS FRECUENTE DE TODO EL TEMA — tolerancia cero. Usar $\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y)$ sin haber verificado independencia (o al menos $\text{Cov} = 0$). Si X e Y están correlacionadas positivamente, la varianza real de la suma es **mayor** que $\text{Var}(X) + \text{Var}(Y)$ (el término $2\text{Cov}(X, Y)$ suma); si están correlacionadas negativamente, es **menor**. Omitir este término no es un error “de detalle”: puede cambiar completamente el resultado numérico de un ejercicio. **Regla práctica:** ante $\text{Var}(X+Y)$ o $\text{Var}(\sum X_i)$, lo primero es preguntarse “¿son independientes?” — si el enunciado no lo dice explícitamente (o no se puede justificar), **no** se puede eliminar el término de covarianza.

Ejemplo 5.1 — Verificación numérica del término cruzado.

```
import numpy as np
np.random.seed(0)
n = 2_000_000
X = np.random.normal(0, 1, n)
Y = 0.7*X + np.random.normal(0, 1, n) # Y correlacionada con X
var_suma_real = (X+Y).var()
var_sin_cov = X.var() + Y.var()
cov_xy = np.cov(X,Y)[0,1]
print("Var(X+Y) real:      ", var_suma_real)
print("Var(X)+Var(Y):      ", var_sin_cov)
print("+ 2*Cov(X,Y):       ", var_sin_cov + 2*cov_xy) # debe igualar la primera
línea
```

Salida esperada: la primera y tercera línea coinciden (≈ 3.48), mientras que $\text{Var}(X)+\text{Var}(Y)$ solo (≈ 2.0) subestima fuertemente la varianza real, precisamente porque X e Y están correlacionadas.

5.3 GENERALIZACIÓN A N VARIABLES

$$\text{Var}(X_1 + \dots + X_n) = \sum_i \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j)$$

Si las X_i son i.i.d. (o simplemente independientes de a pares), todos los términos de covarianza se anulan y queda $\text{Var}(\sum X_i) = \sum \text{Var}(X_i) = n\sigma^2$ — este es exactamente el resultado que se usa en la Sección 6 para demostrar la LGN.

6. Variables i.i.d. y la Ley de los Grandes Números

6.1 NOTACIÓN I.I.D. Y ESPERANZA/VARIANZA DEL PROMEDIO

Sean $X_1, \dots, X_n$ **independientes e idénticamente distribuidas** (i.i.d.), cada una con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2$. Sea $S_n = X_1 + \dots + X_n$ y $\bar{X}_n = S_n/n$ el promedio muestral.

Variable	Esperanza	Varianza	Desvío
S_n	$n\mu$	$n\sigma^2$	$\sqrt{n} \cdot \sigma$
$\bar{X}_n$	μ	σ^2/n	$\sigma/\sqrt{n}$

Cálculo de $E(S_n)$: por linealidad (Sección 1.3), vale siempre, sin necesitar independencia: $E(S_n) = \sum E(X_i) = n\mu$. *Cálculo de $Var(S_n)$* : **aquí sí se usa la independencia** (Sección 5.3): $Var(S_n) = \sum Var(X_i) = n\sigma^2$ (todos los términos de covarianza son 0 por independencia). Como $\bar{X}_n = S_n/n$: $E(\bar{X}_n) = E(S_n)/n = \mu$, y $Var(\bar{X}_n) = Var(S_n)/n^2 = \sigma^2/n$ (constante sale al cuadrado, Sección 2.3).

Dos hechos “sorprendentes” y clave para todo lo que sigue: el desvío de la **suma** crece como $\sqrt{n}$ (no linealmente en n), y el desvío del **promedio** tiende a 0. Este segundo hecho es, en esencia, la LGN.

6.2 ENUNCIADO DE LA LGN DÉBIL

Ley de los Grandes Números (débil). Sean $X_1, X_2, \dots$ i.i.d. con $E(X_i) = \mu$ y $Var(X_i) = \sigma^2 < \infty$.

Entonces, para todo $\varepsilon > 0$: $P(|\bar{X}_n - \mu| \geq \varepsilon) \rightarrow 0$ cuando $n \rightarrow \infty$ Notación: $\bar{X}_n \xrightarrow{P} \mu$ (“ $\bar{X}_n$ converge en probabilidad a μ ”).

6.3 DEMOSTRACIÓN VÍA CHEBYSHEV

Aplicando la desigualdad de Chebyshev (Sección 3) a $\bar{X}_n$, que tiene esperanza μ y varianza σ^2/n :

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq Var(\bar{X}_n)/\varepsilon^2 = \sigma^2/(n\varepsilon^2)$$

El lado derecho tiende a 0 cuando $n \rightarrow \infty$ (para σ^2 y ε fijos), lo cual prueba la LGN débil. ■

Esta demostración es la razón por la que Chebyshev se estudia justo antes de la LGN: es literalmente el único ingrediente que hace falta.

6.4 LGN FUERTE (MENCIÓN)

Ley de los Grandes Números (fuerte). Bajo las mismas hipótesis (i.i.d., media finita — la fuerte no necesita varianza finita, solo $E(|X_1|) < \infty$): $\bar{X}_n \rightarrow \mu$ **casi seguramente (c.s.)** cuando $n \rightarrow \infty$, es decir $P(\{\omega : \bar{X}_n(\omega) \rightarrow \mu\}) = 1$.

La convergencia casi segura es **más fuerte** que la convergencia en probabilidad: dice que, con probabilidad 1, la trayectoria completa del promedio converge a μ (no solo que la probabilidad de estar lejos de μ tiende a 0 en cada n por separado). Toda convergencia c.s. implica conver-

gencia en probabilidad, pero no al revés. En este curso, la LFGN (Ley Fuerte) se usa constantemente junto con estas propiedades algebraicas (ver Práctico 8, Ejercicio 2, en el archivo de ejercicios resueltos):

Si $X_n \xrightarrow{\text{c.s.}} a$ e $Y_n \xrightarrow{\text{c.s.}} b$, y $g: \mathbb{R} \rightarrow \mathbb{R}$ es continua, entonces $X_n + Y_n \xrightarrow{\text{c.s.}} a+b$, $X_n Y_n \xrightarrow{\text{c.s.}} ab$, y $g(X_n) \xrightarrow{\text{c.s.}} g(a)$.

Estas propiedades permiten, por ejemplo, obtener el límite c.s. de $\bar{X}_n^2$ a partir del límite c.s. de $\bar{X}_n$ (tomando $g(x)=x^2$, continua), sin tener que rehacer toda la demostración desde cero — técnica central del Práctico 9 (método de los momentos, ver archivo de ejercicios).

6.5 VERIFICACIÓN NUMÉRICA: CONVERGENCIA DEL PROMEDIO MUESTRAL

Ejemplo 6.1 — Tabla de convergencia (dato equilibrado, $\mu=3.5$).

```
import numpy as np
np.random.seed(42)
mu_teorico = 3.5
for n in [10, 100, 1000, 10000]:
    x = np.random.randint(1, 7, size=n)
    print(f"n={n:6d}    $\bar{X}_n$ ={x.mean():.4f}    $|\bar{X}_n - \mu|$ ={abs(x.mean()-mu_teorico):.4f}")
```

n	$\bar{X}_n$ (una corrida)	$ \bar{X}_n - \mu $
10	3.8000	0.3000
100	3.5400	0.0400
1000	3.4860	0.0140
10000	3.4908	0.0092
100000	3.5038	0.0038

El error $|\bar{X}_n - \mu|$ decrece de forma consistente con n creciente (con fluctuaciones, porque es una sola trayectoria aleatoria, pero la tendencia es clara y consistente con el orden $\sigma/\sqrt{n}$ predicho en la Sección 6.1). Esta tabla es la verificación empírica más directa de la LGN.

Dato histórico del curso (Juicio del Pyx, Casa de la Moneda de Londres, s. XII-XIX): durante siglos se toleró que el peso de un lote de n monedas se desviara hasta nR del peso nominal (R = tolerancia por moneda), cuando lo correcto — por la regla del $\sqrt{n}$ de la LGN — es que la desviación típica de un lote crece como $\sqrt{n} \cdot \sigma$, no como n . Ese error de cálculo permitió a maestros de la casa de la moneda (posiblemente incluyendo a Isaac Newton, que ocupó el cargo) acuñar sistemáticamente monedas levemente livianas sin ser detectados.

7. Introducción a estimadores

7.1 QUÉ ES UN ESTIMADOR PUNTUAL

Dada una muestra $X_1, \dots, X_n$ i.i.d. de una distribución que depende de un parámetro desconocido θ , un **estimador puntual** de θ es una función $T_n = T_n(X_1, \dots, X_n)$ de los datos (no depende de θ , que es desconocido) que se usa para aproximar θ .

Un estimador es, en sí mismo, una variable aleatoria (porque es función de variables aleatorias) — antes de observar los datos, T_n tiene su propia distribución, esperanza y varianza.

7.2 SESGO E INSESGADEZ

El **sesgo** de T_n como estimador de θ es $E(T_n) - \theta$. Se dice que T_n es **insesgado** si su sesgo es 0 para todo n , es decir $E(T_n) = \theta$.

Ejemplo 7.1 — La media muestral es insesgada para μ . Si $X_1, \dots, X_n$ son i.i.d. con $E(X_i) = \mu$, entonces por linealidad (Sección 1.3, sin necesitar independencia): $E(\bar{X}_n) = E((X_1 + \dots + X_n)/n) = (1/n) \sum E(X_i) = (1/n)(n\mu) = \mu$. El sesgo es $E(\bar{X}_n) - \mu = 0$ para todo n : **$\bar{X}_n$ es insesgado.**

Ejemplo 7.2 — La varianza muestral “ingenua” (dividir por n) NO es insesgada; dividir por $n-1$ sí. Sea $\sigma_n^2 = (1/n) \sum (X_i - \bar{X}_n)^2$ (divide por n) y $s_n^2 = (1/(n-1)) \sum (X_i - \bar{X}_n)^2$ (divide por $n-1$). Se puede demostrar (desarrollo estándar, usando $\sum (X_i - \bar{X}_n)^2 = \sum X_i^2 - n\bar{X}_n^2$) que: $E(\sigma_n^2) = ((n-1)/n) \cdot \sigma^2 < \sigma^2$ (sesgado, subestima sistemáticamente la varianza real), mientras que $E(s_n^2) = \sigma^2$ exactamente (insesgado). Esta es la razón estadística por la cual, al calcular

una “varianza muestral”, se divide por $n-1$ y no por n (corrección de Bessel). **Verificación numérica** ($\mu=5$, $\sigma^2=4$, $n=5$, 2000 repeticiones):

```
import numpy as np
np.random.seed(0)
mu, sigma, n = 5, 2, 5
biased, unbiased = [], []
for _ in range(2000):
    x = np.random.normal(mu, sigma, n)
    xbar = x.mean()
    biased.append(np.sum((x-xbar)**2)/n)
    unbiased.append(np.sum((x-xbar)**2)/(n-1))
print("Var real:", sigma**2)           # 4
print("Media de /n :", np.mean(biased)) # ~3.18 (subestima)
print("Media de /n-1 :", np.mean(unbiased)) # ~3.97 (correcto, ~4)
```

7.3 CONSISTENCIA — RELACIÓN DIRECTA CON LA LGN

Un estimador T_n es **consistente** si $T_n \xrightarrow{\text{c.s.}} \theta$ (o, en versión débil, $T_n \xrightarrow{P} \theta$) cuando $n \rightarrow \infty$.

La consistencia **es** la LGN aplicada al estimador. De hecho, la demostración de que $\bar{X}_n$ es un estimador consistente de μ es, palabra por palabra, el enunciado de la LGN (débil, Sección 6.2, o fuerte, Sección 6.4) — no hace falta ninguna herramienta nueva. Esta es la razón profunda por la que el tema de estimación (2.2, segunda mitad) viene inmediatamente después de la LGN en el programa: **casi todo estimador basado en promedios es consistente exactamente porque la LGN lo garantiza.**

Ejemplo 7.3 — $\bar{X}_n$ es insesgado y consistente para μ (el ejemplo canónico).

- **Insesgado** (Ejemplo 7.1): $E(\bar{X}_n) = \mu$ para todo n — propiedad “exacta”, vale incluso con una sola observación ($n=1$).
- **Consistente** (LGN, Sección 6.2/6.4): $\bar{X}_n \rightarrow \mu$ (en probabilidad o c.s.) cuando $n \rightarrow \infty$ — propiedad “asintótica”, habla de qué pasa cuando n crece.

Insesgadez y consistencia son propiedades **distintas e independientes**: un estimador puede ser insesgado pero no consistente (su varianza podría no decrecer con n), o consistente pero sesgado para n finito (como σ_n^2 del Ejemplo 7.2, que es sesgado para todo n finito pero consistente, porque el sesgo $(n-1)/n \cdot \sigma^2 - \sigma^2 = -\sigma^2/n \rightarrow 0$ cuando $n \rightarrow \infty$).

Ejemplo 7.4 — Método de los momentos (adelanto, ver Práctico 9). Si $X \sim \text{Geo}(p)$, $E(X)=1/p$. Despejando $p=1/E(X)$, un estimador natural es reemplazar $E(X)$ por su estimador consistente $\bar{X}_n$: $\hat{p}_n = 1/\bar{X}_n$. Como $\bar{X}_n \rightarrow 1/p$ c.s. (LGN) y $g(x)=1/x$ es continua en $x \neq 0$, la propiedad de continuidad de la convergencia c.s. (Sección 6.4) da directamente $\hat{p}_n = g(\bar{X}_n) \rightarrow g(1/p) = p$ c.s. — es decir, **$\hat{p}_n$ es consistente**, sin necesidad de ninguna demostración adicional más allá de la LGN y la continuidad de g .

8. Trampas típicas de examen — resumen

- 1. $\text{Var}(X+Y) = \text{Var}(X)+\text{Var}(Y)$ sin verificar independencia.** Siempre falta preguntarse “¿son independientes o al menos $\text{Cov}=0$?” antes de eliminar el término $2\text{Cov}(X,Y)$. Ver Sección 5.2.
- 2. Confundir “correlación/covarianza cero” con “independencia”.** Independencia $\Rightarrow \text{Cov}=0$, pero la vuelta es falsa en general (contraejemplo explícito en la Sección 4.2). Solo vale la equivalencia completa en casos particulares, como variables Bernoulli.
- 3. Aplicar Chebyshev con varianza infinita o sin controlar cuál varianza usar.** Si $\text{Var}(X)=\infty$, la cota es inútil ($=\infty$). Y para un promedio $\bar{X}_n$, la varianza correcta a usar es σ^2/n , no σ^2 de una observación individual — mezclar ambas es el error más común en ejercicios de “tamaño de muestra necesario” (Sección 3.4, y Ejercicio 1 del Práctico 8).
- 4. Pensar que $E(X+Y)=E(X)+E(Y)$ requiere independencia.** No la requiere nunca — es simple linealidad (Sección 1.3). Lo que sí requiere independencia es $E(XY)=E(X)E(Y)$.
- 5. Confundir insesgadez con consistencia.** Son propiedades distintas: insesgadez es exacta para cada n , consistencia es asintótica ($n \rightarrow \infty$). Un estimador puede tener una sin la otra (Sección 7.3).
- 6. Usar $\text{Var}(X)=E(X^2)-E(X)^2$ sin haber calculado $E(X^2)$ correctamente** (por ejemplo, olvidando que si X toma valores $\{0,1\}$, entonces $X^2=X$ y por lo tanto $E(X^2)=E(X)$ — atajo válido solo para Bernoulli/indicadores, no para variables generales).

Tabla de referencia rápida

Concepto	Fórmula	Requiere independencia?
$E(aX+b)$	$aE(X)+b$	No
$E(X+Y)$	$E(X)+E(Y)$	No, nunca
$E(g(X))$	$\sum g(x)p(x)$ o $\int g(x)p(x)dx$	No
$\text{Var}(X)$	$E(X^2)-E(X)^2$	No
$\text{Var}(aX+b)$	$a^2\text{Var}(X)$	No
$\text{Var}(X+Y)$	$\text{Var}(X)+\text{Var}(Y)+2\text{Cov}(X,Y)$	No (fórmula general)
$\text{Var}(X+Y) = \text{Var}(X)+\text{Var}(Y)$	—	Sí (o al menos $\text{Cov}=0$)
$\text{Cov}(X,Y)$	$E(XY)-E(X)E(Y)$	No (definición)
Independencia $\Rightarrow \text{Cov}=0$	—	Sí (hipótesis)
$\text{Cov}=0 \Rightarrow$ independencia	—	Falso en general
$ \rho_{X,Y} \leq 1$	Cauchy-Schwarz / discriminante	No
$P(X-\mu \geq \varepsilon) \leq \sigma^2/\varepsilon^2$	Chebyshev	No (vale para toda distribución con $\sigma^2 < \infty$)
$\bar{X}_n \rightarrow \mu$	LGN (débil: en prob.; fuerte: c.s.)	Sí (i.i.d.)

Resumen ultra-rápido (2 minutos)

- **$E(X)$** : centro de masa de la distribución. **Lineal siempre**: $E(aX+b)=aE(X)+b$, $E(X+Y)=E(X)+E(Y)$ — nunca necesita independencia.
- **Teorema del estadístico inconsciente**: $E(g(X))$ se calcula pesando $g(x)$ con la distribución de X , sin hallar la distribución de $g(X)$.
- **$\text{Var}(X) = E(X^2)-E(X)^2 \geq 0$** , mide dispersión. $\text{Var}(X+c)=\text{Var}(X)$, $\text{Var}(cX)=c^2\text{Var}(X)$.

- **Chebyshev:** $P(|X-\mu|\geq\epsilon) \leq \sigma^2/\epsilon^2$, para cualquier distribución con varianza finita. Se demuestra vía Markov. Cota conservadora (sobreestima la probabilidad real).
- **Cov(X,Y)=E(XY)-E(X)E(Y).** Independencia $\Rightarrow$ Cov=0, pero **no al revés** (contraejemplo en 4.2). $\rho=\text{Cov}/(\sigma_X\sigma_Y) \in [-1,1]$ (Cauchy-Schwarz / discriminante). $\rho=\pm 1 \Leftrightarrow$ dependencia lineal exacta.
- **Var(X+Y) = Var(X)+Var(Y)+2Cov(X,Y);** se simplifica a $\text{Var}(X)+\text{Var}(Y)$ **solo** si $\text{Cov}(X,Y)=0$ (en particular, si son independientes) — error de tolerancia cero olvidar el término cruzado.
- **LGN débil:** $\bar{X}_n \xrightarrow{P} \mu$, se demuestra en 2 líneas con Chebyshev aplicado a $\bar{X}_n$ ($\text{Var}(\bar{X}_n)=\sigma^2/n \rightarrow 0$). **LGN fuerte:** $\bar{X}_n \xrightarrow{\text{c.s.}} \mu$ (convergencia más fuerte).
- **Estimador:** función de la muestra que aproxima un parámetro. **Insesgado:** $E(T_n)=\theta$ para todo n (propiedad exacta). **Consistente:** $T_n \rightarrow \theta$ cuando $n \rightarrow \infty$ (propiedad asintótica — para promedios, es literalmente la LGN). $\bar{X}_n$ es el ejemplo canónico: insesgado y consistente para μ .
- Toda esta cadena de resultados (Chebyshev $\rightarrow$ LGN $\rightarrow$ consistencia de estimadores) es el fundamento teórico de por qué “juntar más datos” mejora las estimaciones — y es la base de todo lo que sigue en el curso (intervalos de confianza, tests de hipótesis).