

CONTENTS

Estimación Puntual (Momentos y Máxima Verosimilitud) y Teorema Central del Límite

Guía de estudio con tolerancia cero — Temas 2.3 y 2.4, Probabilidad y Estadística (FING UdelaR)

0. Por qué existen estos temas

1. Método de los momentos

2. Función de verosimilitud y log-verosimilitud

3. Estimador de Máxima Verosimilitud (EMV)

4. Momentos vs. EMV: cuando dan resultados distintos

5. Propiedades deseables de los estimadores

6. Teorema Central del Límite (TCL)

7. Corrección por continuidad

8. Cota de Berry-Esseen (mención breve)

9. Trampas típicas de examen

Tabla de referencia — fórmulas clave

Resumen ultra-rápido (2 minutos)

Estimación Puntual (Momentos y Máxima Verosimilitud) y Teorema Central del Límite

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMAS 2.3 Y 2.4, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existen estos temas

Hasta el Bloque 1 del curso, el modelo probabilístico era siempre **conocido de antemano**: “sea $X \sim \text{Exp}(3)$ ”, “sea $X \sim \text{Bin}(10, 0.4)$ ”. En la práctica real casi nunca se conoce el parámetro — se sabe (o se supone, por el contexto físico) *qué familia* de distribución sigue el fenómeno (exponencial para tiempos de espera, Poisson para conteos raros, Normal para mediciones con muchos errores acumulados), pero el parámetro concreto (la tasa λ , la media μ , la probabilidad p) hay que **inferirlo a partir de datos**. Ese es el problema de **estimación puntual**: dado un modelo con parámetro desconocido θ y una muestra i.i.d. $X_1, \dots, X_n$, producir un único número $\hat{\theta}$ que sea la “mejor apuesta” para el verdadero valor de θ .

Hay dos caminos estándar para construir ese número, y el examen evalúa ambos porque **no siempre coinciden**: el **método de los momentos** (igualar promedios muestrales con esperanzas teóricas — mecánico y rápido, pero a veces ineficiente) y el **estimador de máxima verosimilitud** (EMV — elegir el parámetro que hace “más creíbles” los datos observados, casi siempre mejor pero que exige optimizar una función, a veces sin usar derivadas).

El **Teorema Central del Límite** (TCL) resuelve un problema completamente distinto pero íntimamente relacionado: una vez que tenemos un estimador que es un promedio (como $\bar{X}_n$), ¿qué tan “cerca” está de su valor esperado para un n dado? El TCL es la herramienta que permite responder preguntas de probabilidad sobre $\bar{X}_n$ (o sobre sumas $S_n = X_1 + \dots + X_n$) **sin conocer la distribución exacta de las X_i** , aproximándolas por una Normal. Es el puente que conecta la estimación puntual (Tema 2.3) con los intervalos de confianza y tests de hipótesis (Temas 2.5-2.7): casi todo intervalo de confianza que van a construir en las próximas semanas es, en el fondo, “TCL aplicado a un estimador”.

Regla de oro que atraviesa todo el tema: **el método de los momentos y el EMV son procedimientos mecánicos distintos que pueden dar estimadores distintos para el mismo parámetro** — no hay una única “respuesta correcta” a menos que el ejercicio pida específicamente uno de los dos métodos. Y el TCL es la aproximación $N(\mu, \sigma^2/n)$ para $\bar{X}_n$,

válida para **n grande** (no hay un n mágico — depende de cuán lejos esté la distribución original de una Normal) y bajo las hipótesis de **muestra i.i.d. con varianza finita**.

1. Método de los momentos

Idea central. Si X tiene k parámetros desconocidos $\theta_1, \dots, \theta_k$, se calculan los k primeros momentos poblacionales $E(X)$, $E(X^2)$, ..., $E(X^k)$ **en función de** los θ_i , se igualan a los momentos muestrales correspondientes

$$\hat{m}_1 = \overline{X}_n = \frac{1}{n} \sum X_i, \quad \hat{m}_2 = \frac{1}{n} \sum X_i^2, \quad \dots$$

y se despeja el sistema de k ecuaciones con k incógnitas para $\theta_1, \dots, \theta_k$. Cuando hay un solo parámetro, alcanza con la primera ecuación ($E(X) = \bar{X}_n$); cuando hay dos, hace falta usar también la varianza (o el segundo momento).

Procedimiento general:

1. Calcular $E(X)$ (y $E(X^2)$ o $\text{Var}(X)$ si hay 2 parámetros) en función de los θ_i .
2. Igualar cada momento poblacional con su análogo muestral.
3. Resolver el sistema algebraico para despejar θ_i en función de $\bar{X}_n$ (y S_n^2 si aplica).

Ejemplo 1.1 — Un parámetro: Exponencial(λ).

Sea $X_1, \dots, X_n$ i.i.d. $\sim \text{Exp}(\lambda)$. Se sabe que $E(X) = 1/\lambda$. Igualando al momento muestral:

$$\frac{1}{\hat{\lambda}} = \overline{X}_n \quad \rightarrow \quad \hat{\lambda}_{\text{mom}} = \frac{1}{\overline{X}_n}$$

Verificación simbólica (sympy): `sp.solve(sp.Eq(1/lam, xbar), lam)` devuelve `[1/xbar]` ✓.

Verificación numérica: muestra simulada de tamaño 2000 con λ real = 2.5 dio $\bar{X}_n = 0.4015 \rightarrow \hat{\lambda} = 1/0.4015 = \mathbf{2.4905}$ (muy cerca de 2.5, como se espera con n grande).

Ejemplo 1.2 — Dos parámetros simultáneos: Uniforme(a, b).

Sea $X_1, \dots, X_n$ i.i.d. $\sim U[a, b]$. Se sabe que $E(X) = (a+b)/2$ y $\text{Var}(X) = (b-a)^2/12$. Sistema:

$$\frac{\hat{a} + \hat{b}}{2} = \overline{X}_n \quad \text{y} \quad \frac{(\hat{b} - \hat{a})^2}{12} = S_n^2$$

Despejando (sympy: `sp.solve([Eq((a+b)/2, xbar), Eq((b-a)**2/12, s2)], [a, b])`) se obtienen dos soluciones simétricas; se descarta la que da $b < a$, quedando: $\hat{a} =$

$$\overline{X}_n - \sqrt{3} S_n \quad \text{y} \quad \hat{b} = \overline{X}_n + \sqrt{3} S_n$$

Verificación numérica: muestra de 5000 datos $U(3, 10)$ simulados dio $\bar{X}_n = 6.98$, $S_n^2 \approx 4.08 \rightarrow \hat{a} \approx 3.01$,

$\hat{b} \approx 9.99$ (valores reales: $a=3$, $b=10$) ✓. Este es exactamente el Ejercicio 1.2 del Práctico 8 (ver resolución del práctico).

Cuando el modelo tiene dos parámetros pero uno solo entra en la esperanza (por ejemplo $N(\theta, \theta)$, un solo parámetro que es a la vez media y varianza), sigue alcanzando con **una** ecuación de momentos si hay un solo θ que despejar — pero hay que tener cuidado de no mezclar el orden de los momentos: si la esperanza no alcanza para despejar θ de forma única o conveniente, se recurre al segundo momento $E(X^2)$ en vez de (o junto con) $E(X)$. Ver Ejercicio 2 del Práctico 8, resuelto con EMV en la sección 3.

Error frecuente de tolerancia cero: mezclar momento muestral **centrado** (varianza, $S_n^2 = (1/n)\sum (X_i - \bar{X}_n)^2$ o su versión con $1/(n-1)$) con momento muestral **no centrado** ($E(X^2)$ estimado por $(1/n)\sum X_i^2$). Son cantidades relacionadas por $\text{Var}(X) = E(X^2) - E(X)^2$, pero **no intercambiables** dentro del sistema de ecuaciones: hay que ser consistente en si se está igualando $E(X^2)$ o $\text{Var}(X)$ a su respectivo estimador muestral.

2. Función de verosimilitud y log-verosimilitud

Definición. Dada una muestra i.i.d. $X_1, \dots, X_n$ de una densidad (o función de probabilidad puntual) $f(x; \theta)$, la **función de verosimilitud** es

$$L(\theta) = \prod_{i=1}^n f(X_i; \theta)$$

Se interpreta como “qué tan compatibles son los datos observados con cada valor posible de θ ” — **no** es una densidad de probabilidad en θ (θ no es aleatorio en este marco, es un parámetro fijo desconocido).

Por qué se usa el logaritmo. Maximizar un producto de n factores es incómodo (la derivada de un producto es una suma de términos con todos los demás factores multiplicando — regla del producto generalizada). Como el logaritmo es una función **estrictamente creciente**, el argmax de $L(\theta)$ coincide exactamente con el argmax de

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(X_i; \theta)$$

la **log-verosimilitud**, que convierte el producto en una suma — mucho más fácil de derivar término a término.

Formalmente: si g es estrictamente creciente, entonces θ^* maximiza $L(\theta)$ si y solo si θ^* maximiza $g(L(\theta))$. Como $\log$ es estrictamente creciente en $(0, \infty)$ y $L(\theta) > 0$ siempre que la densidad sea positiva, $\operatorname{argmax} L(\theta) = \operatorname{argmax} \log L(\theta)$. Por eso trabajar con $\ell(\theta)$ en vez de $L(\theta)$ nunca cambia la respuesta.

3. Estimador de Máxima Verosimilitud (EMV)

Procedimiento estándar (caso derivable):

1. Escribir $L(\theta) = \prod f(X_i; \theta)$, identificando el **soporte** (el ejercicio 6 del Práctico 8 insiste en esto: si el soporte de f depende de θ , ¡ $L(\theta)$ no es derivable en todo punto y hay que analizar por casos!).
2. Tomar logaritmo: $\ell(\theta) = \sum \log f(X_i; \theta)$.
3. Derivar: $\ell'(\theta)$, igualar a 0 y despejar θ .
4. **Verificar que es un máximo** (segunda derivada negativa, o análisis de monotonía / borde si la función no es diferenciable en el óptimo).

Ejemplo 3.1 — EMV de Bernoulli(p).

Muestra $X_1, \dots, X_n$ i.i.d. $\sim \text{Ber}(p)$, con $k = \sum X_i$ éxitos observados. $\ell(p) = k \log p + (n-k) \log(1-p)$. $\ell'(p) = \frac{k}{p} - \frac{n-k}{1-p}$ Igualando a 0 (sympy:

`sp.solve(Eq(k/p - (n-k)/(1-p), 0), p)` da $\hat{p} = k/n = \bar{X}_n$.

Verificación de que es máximo: $\ell'(p) > 0$ para $p < k/n$ y $\ell'(p) < 0$ para $p > k/n$ (ℓ' cambia de signo una sola vez de $+$ a $-$), confirmando máximo.

Verificación numérica: muestra Bernoulli($p=0.35$) de tamaño 1000 dio $\hat{p} = 0.349$ ✓.

Ejemplo 3.2 — EMV de Exponencial(λ).

$\ell(\lambda) = n \log \lambda - \lambda \sum X_i$. $\ell'(\lambda) = \frac{n}{\lambda} - \sum X_i = 0 \implies \hat{\lambda}_{\text{EMV}} = \frac{1}{\bar{X}_n}$ **Verificación**

de máximo: $\ell''(\lambda) = -n/\lambda^2 < 0$ para todo $\lambda > 0$ (verificado con sympy: `sp.diff(n/lam - n*xbar, lam)` da `-n/lambda**2`) $\rightarrow$ cóncava, único máximo.

Nota importante: en este caso $\hat{\lambda}_{\text{momentos}} = \hat{\lambda}_{\text{EMV}} = 1/\bar{X}_n$ — **coinciden** (pasa siempre que el primer momento determina unívocamente al parámetro y la verosimilitud es “bien comportada”), pero **esto no es la regla general** — ver sección 4.

Error frecuente de tolerancia cero (Práctico 8, Ejercicio 6): derivar $\ell(\theta)$ sin antes fijarse en el soporte. Con $p(x; \theta) = e^{-(x-\theta)}$ para $x \geq \theta$, la verosimilitud es $L(\theta) = e^{-\sum x_i} e^{n\theta}$

solo si $\theta \leq \min\{X_i\}$, y vale 0 si no. Como $e^{n\theta}$ es creciente en θ , el máximo NO se encuentra derivando e igualando a 0 (la derivada nunca se anula) sino en el borde del dominio permitido: $\hat{\theta}_{EMV} = \min\{X_i\}$. Ejercicios “trampa” de este tipo son comunes: siempre preguntarse primero “¿ $L(\theta)$ es diferenciable con un máximo interior, o es monótona y el máximo está en un borde impuesto por el soporte?”.

Caso discreto con soporte finito y θ que solo toma un conjunto discreto de valores (ej. Práctico 8, Ejercicio 9: $\theta \in \{0, 1\}$): no hay nada que derivar. Se evalúa $L(\theta)$ para cada valor posible de θ y se elige el que da la verosimilitud más alta. Es el mismo principio (maximizar la “creencia en los datos”), solo que sobre un dominio discreto.

4. Momentos vs. EMV: cuando dan resultados distintos

El caso más citado en los cursos de PyE para mostrar que **momentos y EMV no siempre coinciden** es la $\text{Uniforme}(0, \theta)$:

Ejemplo 4.1 — Uniforme(0, θ): momentos vs. EMV dan estimadores distintos.

Momentos: $E(X) = \theta/2 \Rightarrow \hat{\theta}_{\text{mom}} = 2\bar{X}_n$.

EMV: $L(\theta) = (1/\theta)^n$ si $\theta \geq \max\{X_i\}$, y 0 si no (porque cada X_i debe estar en $[0, \theta]$). Como $(1/\theta)^n$ es **decreciente** en θ , el máximo se alcanza en el valor más chico de θ compatible con los datos, que es $\theta = \max\{X_i\}$. Por lo tanto $\hat{\theta}_{EMV} = X_n^* = \max\{X_1, \dots, X_n\}$ (demostrado formalmente en el Ejercicio 1.c del Práctico 8).

Verificación numérica ($n=50$, θ real=10):

$\hat{\theta}_{\text{momentos}} = 2 \cdot \bar{X}_n = \mathbf{9.355}$

$\hat{\theta}_{EMV} = \max(\text{muestra}) = \mathbf{9.760}$

Ambos son consistentes (convergen a 10 cuando $n \rightarrow \infty$), pero el EMV nunca puede exceder el valor real θ (por construcción, todos los $X_i \leq \theta$), mientras que el estimador de momentos sí puede sobre- o sub-estimar en cualquier dirección. En este ejemplo el EMV además tiene menor error cuadrático medio para n grande (se puede probar que $ECM(\hat{\theta}_{EMV}) = O(1/n^2)$ mientras que $ECM(\hat{\theta}_{\text{mom}}) = O(1/n)$ — el EMV converge *más rápido*).

Cómo reconocer en el examen si conviene sospechar que momentos $\neq$ EMV: cuando el soporte de la densidad depende del parámetro (como en $U[0, \theta]$ o $U[a, b]$, o en la densidad $p(x; \theta) = e^{-\lambda(x-\theta)}$ del Ejercicio 6 del Práctico 8), la verosimilitud casi siempre termina siendo monótona en θ dentro del rango permitido, y el EMV se dispara al mínimo o

máximo muestral — un resultado cualitativamente distinto del estimador de momentos, que es siempre una combinación lineal de $\bar{X}_n$ y/o S_n .

5. Propiedades deseables de los estimadores

Dado un estimador θ_n (función de la muestra) de un parámetro θ , se evalúan tres propiedades — todas ya usan herramientas de los Temas 2.1/2.2 (valor esperado, varianza, Ley de los Grandes Números):

Insesgadez: θ_n es insesgado si $E(\theta_n) = \theta$ para todo n . El **sesgo** se define como $\text{sesgo}(\theta_n) = E(\theta_n) - \theta$. Un estimador puede ser sesgado pero **asintóticamente insesgado** si $\text{sesgo}(\theta_n) \rightarrow 0$ cuando $n \rightarrow \infty$ (como el $\theta_{\text{EMV}} = \max\{X_i\}$ de $U[0, \theta]$: $E(\max\{X_i\}) = n\theta/(n+1) \neq \theta$, pero $\text{sesgo} = -\theta/(n+1) \rightarrow 0$).

Consistencia: θ_n es consistente si $\theta_n \xrightarrow{P} \theta$ (converge en probabilidad al verdadero valor cuando $n \rightarrow \infty$). La **Ley de los Grandes Números (Tema 2.2)** es la herramienta estándar para probar consistencia: si θ_n es (una función continua de) un promedio muestral que converge por LGN a su análogo poblacional, y esa función es continua, el **teorema de la función continua** (o “mapeo continuo”) garantiza que θ_n converge en probabilidad al parámetro. Una condición suficiente simple: si $\text{ECM}(\theta_n) \rightarrow 0$, entonces θ_n es consistente (porque ECM acota la probabilidad de desvíos grandes vía Chebyshev).

Eficiencia (idea general): entre dos estimadores insesgados, se prefiere el de **menor varianza** (menor ECM, ya que para insesgados $\text{ECM} = \text{Var}$). Cuando al menos uno de los estimadores en comparación es sesgado, la comparación correcta es siempre por **$\text{ECM} = \text{Var} + \text{sesgo}^2$** , no solo por varianza — este es el criterio que decide, por ejemplo, entre θ_1 (insesgado, $\text{ECM} = 1/n$) y θ_2 (sesgado, $\text{ECM} = 2/n^2$) en el Ejercicio 6 del Práctico 8: para n grande, $2/n^2 < 1/n$, así que el estimador sesgado gana en ECM.

Ejemplo 5.1 — Aplicando el criterio ECM (Práctico 8, Ej. 6).

$\theta_1 = \bar{X}_n - 1$ (momentos, insesgado): $\text{ECM}(\theta_1) = \text{Var}(\theta_1) = 1/n$.

$\theta_2 = \max\{X_i\}$ (EMV, sesgado): $\text{sesgo} = 1/n$, $\text{Var} = 1/n^2$, $\text{ECM}(\theta_2) = 1/n^2 + 1/n^2 = 2/n^2$.

Para $n \geq 3$, $2/n^2 < 1/n \Leftrightarrow 2n < n^2 \Leftrightarrow n > 2$ — así que **θ_2 (el EMV, aunque sesgado) es preferible para cualquier $n \geq 3$** por tener menor ECM, y su sesgo de todas formas tiende a 0.

Este curso no exige (salvo que el material específico lo indique) la cota de Cramér-Rao para “eficiencia óptima” — alcanza con la noción comparativa: “ θ_A es más eficiente que

θ_B ” significa $ECM(\theta_A) \leq ECM(\theta_B)$ para el n en cuestión (o asintóticamente).

6. Teorema Central del Límite (TCL)

Enunciado. Sea $X_1, X_2, \dots, X_n$ una muestra i.i.d. con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2 < \infty$ (varianza finita — hipótesis esencial). Entonces, cuando $n \rightarrow \infty$, la media muestral estandarizada converge **en distribución** a una Normal estándar:

$$\frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

Equivalentemente, para n suficientemente grande se usa la aproximación

$$\overline{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{para la suma: } S_n = \sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2)$$

Por qué es “central”. El resultado **no depende de qué distribución tengan las X_i** — solo de que tengan media y varianza finitas y sean i.i.d. Una suma de Uniformes, de Exponenciales, de Bernoullis (que da lugar a la aproximación Normal de la Binomial) o de cualquier otra distribución con varianza finita, todas convergen a la misma familia Normal al promediarlas. Es “central” porque ocupa el lugar del resultado límite universal de la teoría de probabilidad — el “teorema de los teoremas límite”.

Ejemplo 6.1 — TCL con suma de Uniformes(0,1), $n=30$.

$X_i \sim U(0,1) \Rightarrow \mu=0.5, \sigma^2=1/12$. $S_n = \sum X_i$ ($n=30$) $\approx N(15, 2.5)$.

Se pide $P(S_{30} \leq 16)$.

Aproximación TCL: $P(S_{30} \leq 16) \approx \Phi((16-15)/\sqrt{2.5}) = \Phi(0.632) = \mathbf{0.7365}$.

Verificación por simulación Monte Carlo (200 000 muestras de 30 uniformes cada una, sumadas): valor simulado = **0.7363**. Diferencia < 0.001 — excelente ajuste incluso con n moderado, porque la Uniforme ya es simétrica y de soporte acotado (converge rápido).

Ejemplo 6.2 — TCL con suma de Exponenciales($\lambda=1$), $n=50$ (distribución muy asimétrica).

$X_i \sim \text{Exp}(1) \Rightarrow \mu=1, \sigma^2=1$. S_n ($n=50$) $\approx N(50, 50)$.

Se pide $P(S_{50} \leq 55)$.

Aproximación TCL: $\Phi((55-50)/\sqrt{50}) = \Phi(0.707) = \mathbf{0.7602}$.

Verificación Monte Carlo (200 000 repeticiones): valor simulado = **0.7675**. La diferencia (≈ 0.007) es mayor que en el Ejemplo 6.1, porque la Exponencial es fuertemente asimétrica (su tercer momento es grande) — la convergencia del TCL es más lenta para distribu-

ciones con más asimetría, algo que se cuantifica precisamente con la cota de Berry-Esseen (sección 8).

Error frecuente de tolerancia cero: aplicar el TCL sin verificar que la varianza poblacional es finita, o con n claramente chico ($n=3$, $n=5$) sin ninguna justificación adicional (por ejemplo, sin que la distribución original ya sea Normal, en cuyo caso $\bar{X}_n$ es exactamente Normal para cualquier n , sin necesidad de TCL). El TCL es un resultado **asintótico** — “ n grande” en la práctica de este curso suele considerarse $n \geq 30$ como regla informal, pero la velocidad real de convergencia depende de la forma de la distribución de origen (ver Berry-Esseen).

7. Corrección por continuidad

Cuándo se aplica. Cuando se usa la aproximación Normal (vía TCL) para una variable **discreta** (típicamente Binomial o Poisson, sumas de Bernoullis o de Poissons), hay un desajuste estructural: la variable discreta solo toma valores enteros, mientras que la Normal es continua. La corrección por continuidad consiste en tratar cada valor entero k como si “ocupara” el intervalo $[k-0.5, k+0.5]$ antes de aplicar la aproximación Normal:

$$\begin{aligned} P(X \leq k) &\approx \Phi\left(\frac{k+0.5-\mu}{\sigma}\right) \quad P(X \geq k) \approx 1 - \Phi\left(\frac{k-0.5-\mu}{\sigma}\right) \\ P(a \leq X \leq b) &\approx \Phi\left(\frac{b+0.5-\mu}{\sigma}\right) - \Phi\left(\frac{a-0.5-\mu}{\sigma}\right) \end{aligned}$$

Ejemplo 7.1 — Binomial($n=30$, $p=0.4$), $P(X \leq 15)$.

$$\mu=12, \sigma^2=7.2, \sigma=2.683.$$

Valor exacto (Binomial): 0.9029.

Aprox. Normal SIN corrección: $\Phi((15-12)/2.683) = \Phi(1.118) = 0.8682 \rightarrow \text{error} = 0.0347$.

Aprox. Normal CON corrección: $\Phi((15.5-12)/2.683) = \Phi(1.304) = 0.9039 \rightarrow \text{error} = 0.0010$.

La corrección reduce el error en un factor ≈ 35 .

Ejemplo 7.2 — Poisson($\lambda=20$), $P(18 \leq X \leq 22)$.

$$\mu=\sigma^2=20, \sigma=4.472.$$

Valor exacto (Poisson): 0.4236.

Aprox. SIN corrección: $\Phi((22-20)/4.472) - \Phi((18-20)/4.472) = 0.3453 \rightarrow \text{error} = 0.0783$.

Aprox. CON corrección: $\Phi((22.5-20)/4.472) - \Phi((17.5-20)/4.472) = 0.4238 \rightarrow \text{error} = 0.0003$.

Reducción de error en un factor ≈ 260 — la corrección es especialmente valiosa cuando se pide la probabilidad de un rango angosto de valores enteros.

Regla práctica para no perderse con los signos: “achicar hacia adentro suma error, agrandar hacia afuera lo corrige”. Para “ $\leq k$ ” (cerrado a la derecha) se usa $k+0.5$ (agrandar el rango hacia la derecha). Para “ $\geq k$ ” se usa $k-0.5$ (agrandar hacia la izquierda). Para “ $< k$ ” estricto, es equivalente a “ $\leq k-1$ ”, así que se usa $(k-1)+0.5 = k-0.5$. Dibujar la recta con los enteros y el intervalo $[k-0.5, k+0.5]$ sombreado evita errores de signo.

La corrección por continuidad NO se aplica cuando la variable original ya es continua (sumas de Uniformes, Exponenciales, Normales, etc.) — solo tiene sentido para discretas aproximadas por una continua.

8. Cota de Berry-Esseen (mención breve)

El material de la cátedra revisado para esta guía ([14_distribucion_normal.pdf](#), [15_normal_bivariada_regresion.pdf](#), Notas PyE, Zylberberg) **no desarrolla en detalle** la cota de Berry-Esseen con demostración ni ejercicios numéricos asociados — no aparece en los prácticos 8 ni 9 revisados. Por eso esta sección da solo el enunciado general, sin pretender ser material de examen “cerrado”: si aparece, es más probable que sea una pregunta conceptual breve que un cálculo numérico completo.

Qué mide. El TCL dice que la distribución de la media estandarizada *converge* a $N(0,1)$, pero no dice qué tan rápido. La **cota de Berry-Esseen** cuantifica la velocidad de esa convergencia: existe una constante C (universal, no depende de la distribución, con $1/\sqrt{2\pi} \leq C \leq 0.4748$ según la versión del teorema) tal que

$$\sup_{x \in \mathbb{R}} \left| P\left(\frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \leq x\right) - \Phi(x) \right| \leq \frac{C \cdot \rho}{\sigma^3 \sqrt{n}}$$

donde $\rho = E(|X_1 - \mu|^3)$ es el **tercer momento absoluto centrado** de la distribución original. La cota confirma la intuición de los Ejemplos 6.1 y 6.2: cuanto más asimétrica (mayor ρ) sea la distribución de origen, más lento es el peor-caso de convergencia del TCL, y el error decae como **$O(1/\sqrt{n})$** — más lento que el error típico de estimación de parámetros (que suele decaer como $O(1/n)$ en varianza).

9. Trampas típicas de examen

Trampa 1 — Aplicar TCL con n chico sin justificar. Si $n \leq 10$ (o similar) y la distribución original no es ya Normal, la aproximación Normal para $\bar{X}_n$ o S_n no está justificada por el TCL — hace falta o bien que la distribución original ya sea Normal (en cuyo caso $\bar{X}_n$ es exactamente Normal, sin aproximación, para cualquier n), o argumentar explícitamente “ n grande” con algún respaldo (regla informal $n \geq 30$, o que el enunciado lo indique).

Trampa 2 — Olvidar la corrección por continuidad al aproximar variables discretas. Cualquier ejercicio que pida $P(X=k)$, $P(X \leq k)$, $P(a \leq X \leq b)$ para una Binomial o Poisson (o suma de estas) aproximada por Normal debe llevar la corrección ± 0.5 — omitirla es el error más común y, como muestran los Ejemplos 7.1 y 7.2, puede multiplicar el error por más de 30.

Trampa 3 — Confundir el estimador de momentos con el EMV cuando dan resultados distintos. Como se ve en la Sección 4 (Uniforme(0, θ)) y en el Ejercicio 6 del Práctico 8, ambos métodos son procedimientos **independientes**: “hallar el estimador de θ ” sin especificar el método es ambiguo, y en el examen hay que fijarse literalmente en la palabra usada en el enunciado (“por el método de los momentos” vs. “de máxima verosimilitud”) — mezclar ambos procedimientos a mitad de la resolución (por ejemplo, derivar $L(\theta)$ pero después “verificar” con la ecuación de momentos) invalida la resolución.

Trampa 4 — No verificar el soporte antes de derivar la log-verosimilitud. Ver Ejemplo 3.1 y el Ejercicio 6 del Práctico 8: si el soporte de $f(x; \theta)$ depende de θ , la primera pregunta siempre debe ser “¿para qué valores de θ es $L(\theta) > 0$?” antes de derivar — de lo contrario se puede terminar “maximizando” sobre una región donde la verosimilitud en realidad es 0.

Tabla de referencia — fórmulas clave

Concepto	Fórmula
Estimador de momentos (1 parámetro)	Resolver $E(X;\theta) = \bar{X}_n$
Estimador de momentos (2 parámetros)	Resolver $\{E(X;\theta_1, \theta_2) = \bar{X}_n, \text{Var}(X;\theta_1, \theta_2) = S_n^2\}$ (o $E(X^2)$ =segundo momento muestral)
Verosimilitud	$L(\theta) = \prod f(X_i; \theta)$
Log-verosimilitud	$\ell(\theta) = \sum \log f(X_i; \theta)$
EMV (caso derivable)	Resolver $\ell'(\theta) = 0$, verificar $\ell''(\theta) < 0$
EMV (soporte dependiente de θ , no derivable)	Analizar monotonía de $L(\theta)$; máximo en el borde del soporte (mín o máx muestral)
Sesgo	$\text{sesgo}(\theta) = E(\hat{\theta}) - \theta$
ECM	$\text{ECM}(\theta) = \text{Var}(\hat{\theta}) + \text{sesgo}(\hat{\theta})^2$
Consistencia (vía LGN)	Si $\hat{\theta}_n = g(\text{promedio muestral})$ con g continua y el promedio converge en P por LGN, $\hat{\theta}_n \rightarrow^P \theta$
TCL	$(\bar{X}_n - \mu)/(\sigma/\sqrt{n}) \rightarrow^d N(0, 1); S_n^2 \approx N(n\mu, n\sigma^2)$
Corrección continuidad, $P(X \leq k)$	$\Phi((k+0.5-\mu)/\sigma)$
Corrección continuidad, $P(X \geq k)$	$1 - \Phi((k-0.5-\mu)/\sigma)$
Berry-Esseen	$\sup P(\bar{Z}_n \leq x) - \Phi(x) \leq Cp/(\sigma^3\sqrt{n}), \rho = E X - \mu ^3$

Resumen ultra-rápido (2 minutos)

- **Método de momentos:** igualar $E(X)$ (y $\text{Var}(X)$ si hace falta un segundo parámetro) con su versión muestral, despejar θ . Mecánico, siempre funciona, no siempre es el mejor estimador.
- **EMV:** maximizar $\ell(\theta) = \sum \log f(X_i; \theta)$. Si es derivable con máximo interior: $\ell'(\theta) = 0$. Si el soporte depende de θ : analizar monotonía, el máximo suele quedar en mín o máx muestral.
- **Momentos y EMV pueden diferir** (ej. Uniforme(0, θ): momentos da $2\bar{X}_n$, EMV da $\max\{X_i\}$) — nunca asumir que coinciden sin calcular ambos.

- **Propiedades de estimadores:** insesgado ($E(\hat{\theta})=\theta$), consistente ($\hat{\theta} \xrightarrow{P} \theta$, vía LGN), comparación por **ECM = Var + sesgo²** cuando al menos uno es sesgado.
- **TCL:** $(\bar{X}_n - \mu)/(\sigma/\sqrt{n}) \rightarrow N(0,1)$ para n grande, bajo i.i.d. y varianza finita. No depende de la distribución original (“central”). Sirve para aproximar $P(S_n \in \text{rango})$ o $P(\bar{X}_n \in \text{rango})$.
- **Corrección por continuidad:** obligatoria al aproximar una discreta (Binomial/Poisson) con la Normal — sumar/restar 0.5 según el sentido de la desigualdad. Reduce el error drásticamente (factor 30-250 en los ejemplos verificados).
- **Berry-Esseen:** cota que mide la velocidad de convergencia del TCL, en función del tercer momento absoluto — mayor asimetría de la distribución original $\Rightarrow$ convergencia más lenta. No hay desarrollo numérico específico en el material de la cátedra revisado.
- **Trampas de examen:** TCL con n chico sin justificar; olvidar la corrección de continuidad; confundir momentos con EMV; no revisar el soporte de $f(x;\theta)$ antes de derivar.