

CONTENTS

Intervalos de Confianza y Test de Hipótesis	
Guía de estudio con tolerancia cero — Temas 2.5 y 2.6, Probabilidad y Estadística (FING UdelaR)	
0. Por qué existen estos temas	
1. Qué es un intervalo de confianza: la interpretación correcta	
2. IC para la media, varianza conocida (pivote Normal)	
3. IC para la media, varianza desconocida (pivote t-Student)	
4. IC para una proporción (aproximación normal de la Binomial)	
5. IC para la varianza (pivote Chi-cuadrado)	
6. Ancho del IC: trade-off entre confianza, precisión y tamaño de muestra	
7. Test de hipótesis: estructura general	
8. Errores tipo I y tipo II	
9. Potencia del test	
10. Equivalencia entre test bilateral e intervalo de confianza	
11. Trampas típicas de examen	
Resumen ultra-rápido (2 minutos)	

Intervalos de Confianza y Test de Hipótesis

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMAS 2.5 Y 2.6, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existen estos temas

Hasta este punto del curso (Teorema Central del Límite, estimación puntual) uno sabe **estimar** un parámetro desconocido con un único número: el estimador $\hat{\theta}$ (por ejemplo $\bar{X}_n$ para μ). El problema es que un único número no dice nada sobre **cuánto podemos confiar** en esa estimación. Si $\hat{\theta}=50$, ¿el verdadero parámetro podría ser 40? ¿50? Un estimador puntual no distingue estos casos.

Los **intervalos de confianza (IC)** resuelven esto: en vez de dar un número, dan un **rango** construido de forma que, si repitiéramos el experimento muchas veces, un porcentaje conocido de esos rangos contendría al verdadero parámetro. El **test de hipótesis (TdH)** resuelve un problema distinto pero íntimamente relacionado: no queremos *estimar* el parámetro, queremos **decidir** entre dos afirmaciones concretas sobre él (por ejemplo, “la moneda es justa” vs. “la moneda está cargada”), usando la evidencia de la muestra.

Ambas herramientas comparten la misma maquinaria matemática (el mismo pivote, la misma distribución muestral, las mismas tablas T/Normal/Chi), y de hecho — como se ve en la Sección 10 — son **dos caras de la misma moneda**: todo test bilateral se puede reformular como una pregunta sobre un IC, y viceversa. Por eso se estudian juntos.

Regla de oro que se repite en TODO el tema: **todo IC y todo estadístico de test se construye “pivoteando”** — se parte de una cantidad que involucra al parámetro desconocido y que tiene una distribución *conocida* (Normal, t-Student o Chi-cuadrado), y se despeja el parámetro de la desigualdad que define esa distribución. La distribución del pivote depende de qué se conoce y qué no: **si σ es conocida → Normal; si σ es desconocida → t-Student; para varianza → Chi-cuadrado.**

1. Qué es un intervalo de confianza: la interpretación correcta

Definición. Un intervalo de confianza al nivel $1-\alpha$ para un parámetro θ es un intervalo aleatorio $[L(X_1, \dots, X_n), U(X_1, \dots, X_n)]$ (sus extremos dependen de la muestra, por lo tanto son variables aleatorias) tal que

$$P_{\theta}(\bigcap_{L \leq \theta \leq U}) = 1 - \alpha \quad \text{para todo valor posible de } \theta.$$

Interpretación frecuentista correcta: si repitiéramos el experimento (tomar una muestra de tamaño n y construir el intervalo con la misma fórmula) un número muy grande de veces, aproximadamente el $(1 - \alpha) \cdot 100\%$ de los intervalos construidos **contendrían** al verdadero valor de θ (que es fijo, no aleatorio — el frasco no cambia, lo que cambia de repetición en repetición es la muestra).

⚠ Trampa conceptual clásica de examen — tolerancia cero:

Es **INCORRECTO** decir: “hay un 95% de probabilidad de que μ esté en el intervalo $[48.04; 51.96]$ ” (una vez que ya calculamos ese intervalo específico con los datos observados).

¿Por qué es incorrecto? Porque una vez que la muestra fue observada y el intervalo $[48.04; 51.96]$ quedó fijado con números concretos, ya no hay nada aleatorio: o μ está en ese rango de números o no lo está — no hay “probabilidad” involucrada, del mismo modo que no tiene sentido decir “hay 50% de probabilidad de que ya haya salido cara” después de mirar una moneda que ya fue lanzada y tapada. Lo aleatorio en un IC son **los extremos del intervalo** (que dependen de la muestra, antes de observarla), no el parámetro θ , que es una constante fija (desconocida, pero no aleatoria) en el enfoque frecuentista de este curso.

La forma correcta de decirlo: “**el procedimiento que usamos para construir este intervalo tiene una tasa de éxito (cobertura) del 95%**”, o equivalentemente “si repitiéramos el muestreo muchas veces, el 95% de los intervalos así construidos contendrían a μ ”. El 95% es una propiedad del *método*, no una probabilidad sobre *este* intervalo particular ya calculado.

Verificación por simulación (la forma más honesta de entender esto): se puede simular 10 000 veces “tomar una muestra de tamaño n de una $N(\mu, \sigma^2)$ con μ conocido de antemano, construir el IC al 95% con la fórmula del pivote, y contar en qué fracción de las 10 000 repeticiones el intervalo contuvo al μ verdadero”. Si la fórmula es correcta, esa fracción (la “cobertura empírica”) debe acercarse a 0.95. Todos los ejemplos numéricos de esta guía fueron verificados así con Monte Carlo en Python (scipy.stats + 20 000 repeticiones), con coberturas empíricas entre 0.949 y 0.951 — consistentes con el 95% nominal.

2. IC para la media, varianza conocida (pivote Normal)

Situación: $X_1, \dots, X_n$ MAS (muestra aleatoria simple) de $X \sim N(\mu, \sigma^2)$ con σ^2 **conocida** (o n grande y σ^2 conocida, usando TCL para poblaciones no necesariamente normales).

Pivote: $\bar{X}_n \sim N(\mu, \sigma^2/n)$ exactamente (si X es normal) o aproximadamente (por TCL, si n es grande). Estandarizando:

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0,1).$$

Despeje: partiendo de $P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$ (donde $z_{\alpha/2}$ es el valor tal que el área a la derecha es $\alpha/2$), se despeja μ de la desigualdad:

$$IC_{1-\alpha}(\mu) = \left[\bar{X}_n - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

Ejemplo 2.1 — completo con verificación numérica.

$n=25$ mediciones de un proceso con $\sigma=10$ (conocida) dan $\bar{x} = 82$.
Construir el IC al 95% para μ .

$z_{0.025}=1.96$ (tabla Normal). Margen de error: $1.96 \times 10/\sqrt{25} = 3.92$.
 $IC_{95\%}(\mu) = [82-3.92, 82+3.92] = [78.08, 85.92]$.

Verificación (`scipy.stats.norm.ppf(0.975) = 1.959963984540054`): coincide con la tabla a 3 decimales. **Verificación Monte Carlo:** simulando 20 000 muestras de $N(80, 10^2)$ con $n=25$ y aplicando esta fórmula, el intervalo contuvo al verdadero $\mu=80$ en el 94.94% de los casos — consistente con el 95% nominal.

Error frecuente de tolerancia cero: usar σ en vez de $\sigma/\sqrt{n}$ en el margen de error (olvidar dividir por $\sqrt{n}$), o confundir z_{α} (cola simple) con $z_{\alpha/2}$ (dos colas) — para un IC de nivel $1-\alpha$ **siempre se usa $z_{\alpha/2}$ **, porque el error se reparte en las dos colas de la distribución.

3. IC para la media, varianza desconocida (pivote t-Student)

Situación: $X_1, \dots, X_n$ MAS de $X \sim N(\mu, \sigma^2)$ con σ^2 **desconocida** (el caso realista: casi nunca se conoce σ de antemano).

Por qué cambia la distribución del pivote: si reemplazamos σ por su estimador S_n (desvío muestral, con $S_n^2 = \frac{1}{n-1} \sum (X_i - \bar{X}_n)^2$) en el pivote anterior, el cociente

$$T = \frac{\bar{X}_n - \mu}{S_n / \sqrt{n}}$$

ya no es Normal estándar: al dividir por S_n (que también es aleatorio, y depende de la misma muestra que $\bar{X}_n$) se introduce variabilidad adicional. Se puede demostrar que T sigue exactamente una distribución **t-Student con $n-1$ grados de libertad**, que tiene colas más pesadas que la Normal (para compensar la incertidumbre extra de no conocer σ). A medida que $n \rightarrow \infty$, $S_n \rightarrow \sigma$ y la t-Student converge a la Normal — por eso para n grande ($n \gtrsim 30$) usar t o z da resultados casi idénticos, pero para n chico la diferencia es importante.

IC resultante:

$$IC_{1-\alpha}(\mu) = \left[\bar{X}_n - t_{\alpha/2, n-1} \frac{S_n}{\sqrt{n}}, \bar{X}_n + t_{\alpha/2, n-1} \frac{S_n}{\sqrt{n}} \right]$$

Ejemplo 3.1 — completo con verificación numérica.

Muestra de $n=10$ mediciones: 23.1, 22.4, 24.0, 23.7, 22.9, 23.5, 24.2, 23.0, 23.8, 22.6 (unidades arbitrarias), σ desconocida. Construir el IC al 95% para μ .

$\bar{x} = 23.32$, $s = 0.6088$ (desvío muestral, $n-1=9$ grados de libertad).

Tabla T con 9 g.l., $\alpha/2=0.025$: $t_{0.025, 9} = 2.262$.

Margen de error: $2 \times 0.6088 / \sqrt{10} = 0.3855$.

$$IC_{95\%}(\mu) = [23.32 - 0.3855, 23.32 + 0.3855] = [22.93, 23.71]$$

Verificación (`scipy.stats.t.ppf(0.975, df=9) = 2.262157162798205`): coincide con la tabla T.

Verificación Monte Carlo: simulando 20 000 muestras de $N(23.5, 0.6^2)$ con $n=10$, la cobertura empírica del IC-t fue 95.12% — consistente con el 95% nominal.

Comparación directa (mismo dato, dos supuestos distintos): si en el Ejemplo 2.1 ($n=25$, $\bar{x}=82$) la $\sigma=10$ en realidad fuera *desconocida* y se hubiera estimado $s=10$ de la muestra, el IC con t-Student usaría $t_{0.025, 24}=2.064$ en vez de $z_{0.025}=1.960$ — un margen de error **5.3% más ancho** (4.128 en vez de 3.92), reflejando la incertidumbre extra de no conocer σ . Cuanto más chico es n , mayor es esta diferencia relativa (con $n=5$, $t_{0.025, 4}=2.776$ vs. $z_{0.025}=1.960$ — 42% más ancho).

4. IC para una proporción (aproximación normal de la Binomial)

Situación: $X_1, \dots, X_n$ MAS de $X \sim \text{Ber}(p)$ (n ensayos Bernoulli independientes, ej. encuesta sí/no), n grande.

Pivote: $\hat{p} = \bar{X}_n$ (proporción muestral de éxitos) tiene, por TCL, $\hat{p} \approx N(\left(p, \frac{p(1-p)}{n}\right))$. Como $p(1-p)$ (la varianza) también depende del parámetro desconocido p , se lo reemplaza por su estimador $\hat{p}(1-\hat{p})$ (aproximación adicional, válida para n grande — esto es lo que hace que el IC de proporción sea **siempre aproximado**, nunca exacto como el de la media con σ conocida).

$$IC_{1-\alpha}(p) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

Ejemplo 4.1 — completo con verificación numérica.

Encuesta a $n=200$ personas, 54 dicen “sí” ($\hat{p} = 54/200 = 0.27$). IC al 95% para p .

$$z_{0.025} = 1.96. \text{ Margen de error: } 1.96 \sqrt{0.27 \times 0.73/200} = 0.0615. \\ IC_{95\%}(p) = [0.27 - 0.0615, 0.27 + 0.0615] = [0.2085, 0.3315].$$

Verificación Monte Carlo: simulando 20 000 muestras Binomial(200, 0.27) y aplicando esta fórmula, la cobertura empírica fue 95.13% — consistente con el 95% nominal.

Nota práctica (Ejercicio 5 del Práctico 9, “Precisión vs. Confianza”): cuando el tamaño de muestra es **chico** (ej. $n=8$), no corresponde usar la aproximación normal — hay que leer la región de valores de p compatibles directamente de la tabla binomial exacta (ver también Sección 11 sobre esta trampa). La aproximación normal para proporciones solo es válida cuando $n\hat{p}$ y $n(1-\hat{p})$ son razonablemente grandes (regla práctica: ambos ≥ 5 o ≥ 10).

5. IC para la varianza (pivote Chi-cuadrado)

Situación: $X_1, \dots, X_n$ MAS de $X \sim N(\mu, \sigma^2)$, con μ desconocida (caso típico) y se busca un IC para σ^2 .

Pivote: se puede demostrar que

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

(Chi-cuadrado con $n-1$ grados de libertad). A diferencia de la Normal y la t-Student, la χ^2 **no es simétrica**, por lo que sus dos valores críticos ($\chi^2_{\alpha/2, n-1}$ para la cola derecha y $\chi^2_{1-\alpha/2, n-1}$ para la cola izquierda) son distintos y no basta con “ $\pm$ un margen”.

Despeje: de $P(\chi^2_{1-\alpha/2, n-1} \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{\alpha/2, n-1}) = 1-\alpha$ se despeja σ^2 (¡invirtiendo las desigualdades al pasar σ^2 al numerador!):

$$IC_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)S^2}{\chi^2_{\alpha/2, n-1}}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2, n-1}} \right]$$

Ejemplo 5.1 — completo con verificación numérica.

Muestra de $n=15$ mediciones normales: 47.2, 52.1, 49.8, 50.5, 48.9, 51.2, 53.0, 49.1, 50.8, 47.9, 52.5, 49.3, 50.1, 51.8, 48.6. IC al 95% para σ^2 .

$S^2 = 2.963$ (con $n-1=14$ g.l.). Tabla Chi con 14 g.l.: $\chi^2_{0.025, 14} = 26.119$, $\chi^2_{0.975, 14} = 5.629$.

$IC_{95\%}(\sigma^2) = \left[\frac{14 \times 2.963}{26.119}, \frac{14 \times 2.963}{5.629} \right] = [1.588, 7.369]$.

Verificación (scipy.stats.chi2.ppf): $ppf(0.975, 14) = 26.1189$ y $ppf(0.025, 14) = 5.6287$ — coinciden con la tabla Chi. **Verificación Monte Carlo:** simulando 20 000 muestras de $N(50, 4)$ (es decir $\sigma^2=4$) con $n=15$, la cobertura empírica del IC fue 94.96% — consistente con el 95% nominal.

Error frecuente de tolerancia cero: como la χ^2 es asimétrica, el extremo **inferior** del IC de σ^2 usa $\chi^2_{\alpha/2}$ (el valor crítico *más grande*, de la cola derecha) en el **denominador**, y el extremo **superior** usa $\chi^2_{1-\alpha/2}$ (el valor crítico *más chico*, de la cola izquierda). Invertir estos dos subíndices es el error más común del tema — conviene verificar siempre que el extremo inferior calculado sea efectivamente menor que el superior.

6. Ancho del IC: trade-off entre confianza, precisión y tamaño de muestra

El **ancho** (o longitud) de un IC de la forma $\bar{X}_n \pm z_{\alpha/2} \sigma / \sqrt{n}$ es $2z_{\alpha/2} \sigma / \sqrt{n}$. Tres cantidades están en tensión:

- **Más confianza** ($\uparrow 1-\alpha$) $\rightarrow z_{\alpha/2}$ más grande $\rightarrow$ intervalo **más ancho** (menos preciso), a n fijo.
- **Más tamaño de muestra** ($\uparrow n$) $\rightarrow$ el ancho decrece con $1/\sqrt{n}$ (no linealmente: **cuadruplicar n solo reduce el ancho a la mitad**).
- Para una precisión (ancho) deseada, se puede despejar el **n mínimo necesario**.

Ejemplo 6.1 — tabla comparativa numérica ($\sigma=10$, IC para la media).

n	90% ($z=1.645$)	95% ($z=1.960$)	99% ($z=2.576$)
25	6.579	7.840	10.303
100	3.290	3.920	5.152
400	1.645	1.960	2.576

Lectura de la tabla (verificada con `scipy.stats.norm.ppf`): fijando $n=100$, subir de 90% a 99% de confianza casi duplica el ancho (de 3.29 a 5.15). Fijando la confianza en 95%, cuadruplicar n de 25 a 100 reduce el ancho exactamente a la mitad ($7.84 \rightarrow 3.92$), y volver a cuadruplicar ($100 \rightarrow 400$) lo vuelve a reducir a la mitad ($3.92 \rightarrow 1.96$) — consistente con la dependencia $1/\sqrt{n}$.

Ejemplo 6.2 — tamaño de muestra mínimo para un ancho objetivo.

¿Cuántas observaciones hacen falta para que el IC al 95% de la media (con $\sigma=10$) tenga ancho ≤ 2 ?

$$2z_{\alpha/2} \sigma / \sqrt{n} \leq 2 \iff \sqrt{n} \geq z_{\alpha/2} \sigma = 1.96 \times 10 = 19.6 \iff n \geq 384.16 \iff n \geq 385.$$

Verificación: con $n=385$, ancho $= 2 \times 1.96 \times 10 / \sqrt{385} = 1.998 \leq 2$ ✓; con $n=384$, ancho $= 2.001 > 2$ (no alcanza) ✓ — el redondeo hacia arriba es imprescindible.

7. Test de hipótesis: estructura general

Definición. Dada una MAS $X_1, \dots, X_n$ de X con distribución dependiente de un parámetro (u distribución) desconocido, un **test de hipótesis** es un procedimiento para tomar una decisión entre dos afirmaciones incompatibles sobre ese parámetro:

- **Hipótesis nula H_0 :** la afirmación “conservadora” o de “no cambio” — la que se mantiene salvo evidencia fuerte en contra.
- **Hipótesis alternativa H_1 (o H_A):** lo que se quiere evidenciar.

Región crítica (RC) o región de rechazo: subconjunto del espacio muestral tal que, si la muestra observada cae en la RC, la decisión es **rechazar H_0** ; si no, la decisión es **no rechazar H_0** (nunca “aceptar H_0 ” — ver Sección 11).

Procedimiento general (4 pasos):

1. Plantear H_0 y H_1 .
2. Elegir α (nivel de significación) y construir una RC basada en un **estadístico de prueba** T con distribución conocida bajo H_0 , tal que $P_{H_0}(T \in RC) = \alpha$.
3. Calcular T con los datos observados.
4. Decidir: si T cae en la RC, rechazar H_0 ; si no, no rechazar H_0 .

Regiones críticas más usadas (todas se construyen igual que un IC — mismo pivote, mismas tablas):

Situación	H_0 / H_1	Región crítica (RC)
Media, σ^2 conocida	$\mu \leq \mu_0$ / $\mu > \mu_0$	$\bar{X}_n \geq \mu_0 + \frac{\sigma}{\sqrt{n}} z_{\alpha}$
Media, σ^2 conocida	$\mu = \mu_0$ / $\mu \neq \mu_0$	$ \bar{X}_n - \mu_0 \geq \frac{\sigma}{\sqrt{n}} z_{\alpha/2}$
Media, σ^2 desconocida	$\mu \leq \mu_0$ / $\mu > \mu_0$	$\bar{X}_n \geq \mu_0 + \frac{S_n}{\sqrt{n}} t_{\alpha, n-1}$
Media, σ^2 desconocida	$\mu = \mu_0$ / $\mu \neq \mu_0$	$ \bar{X}_n - \mu_0 \geq \frac{S_n}{\sqrt{n}} t_{\alpha/2, n-1}$
Varianza	$\sigma^2 \leq \sigma_0^2$ / $\sigma^2 > \sigma_0^2$	$S_n^2 \geq \frac{\sigma_0^2}{n-1} \chi^2_{\alpha, n-1}$ (equiv. $(n-1)S_n^2 \geq \sigma_0^2 \chi^2_{\alpha, n-1}$)
Proporción, n grande	$p \leq p_0$ / $p > p_0$	$\bar{X}_n \geq p_0 + \frac{\sqrt{p_0(1-p_0)}}{\sqrt{n}} z_{\alpha}$

Ejemplo 7.1 — test de media, varianza conocida, completo con verificación numérica.

Una máquina llenaba bolsas con $\mu_0 = 170$ g en promedio; se ajustó el proceso y se quiere ver si ahora llena *más* de 170g. $\sigma = 12$ g (conocida por especificación del fabricante), $n = 36$, $\bar{x} = 174$. Test $H_0: \mu \leq 170$ vs. $H_1: \mu > 170$ al nivel $\alpha = 0.05$.

Región crítica: $\bar{X}_n \geq 170 + \frac{12}{\sqrt{36}} z_{0.05} = 170 + 2 \times 1.645 = 173.29$.

Como $\bar{x} = 174 \geq 173.29$, se **rechaza H_0** : hay evidencia de que el llenado medio superó los 170g.

Estadístico estandarizado: $Z = \frac{174 - 170}{12/\sqrt{36}} = 2.0$. p-valor $= P(Z \geq 2.0) = 1 - \Phi(2) = 0.0228$.

Como $0.0228 < 0.05 = \alpha$, se confirma el rechazo (ver Sección 11, equivalencia p-valor/decisión).

Verificación (scipy.stats.norm): $z_{0.05}=1.6449$ y $1-\Phi(2.0)=0.02275$, ambos coinciden con el cálculo manual.

Ejemplo 7.2 — test de media, varianza desconocida (t-Student), completo.

Se sospecha que un nuevo aditivo eleva el rendimiento medio por encima de 50 (unidades de producto). $n=16$, $\bar{x}=52.3$, $s=4.8$ (varianza desconocida). Test $H_0:\mu\leq 50$ vs. $H_1:\mu>50$, $\alpha=0.05$.

$t_{0.05,15}=1.753$. RC: $\bar{X}_n \geq 50 + \frac{4.8}{\sqrt{16}} \times 1.753 = 52.10$.

Como $\bar{x}=52.3 \geq 52.10$, se **rechaza H_0** (por muy poco margen).

$T_{\text{obs}} = \frac{52.3-50}{4.8/\sqrt{16}} = 1.917$. p-valor $= P(T_{15} \geq 1.917) = 0.0373 < 0.05$ ✓ consistente con el rechazo.

Verificación (scipy.stats.t): $t.\text{ppf}(0.95,15)=1.75305$ y $1-t.\text{cdf}(1.9167,15)=0.03727$, coinciden con el cálculo manual.

Error frecuente de tolerancia cero: usar z_{α} (Normal) en vez de $t_{\alpha,n-1}$ cuando σ es desconocida y n es chico (Sección 11 lo detalla). En el Ejemplo 7.2, usar $z_{0.05}=1.645$ en vez de $t_{0.05,15}=1.753$ daría una RC de $\bar{X}_n \geq 51.97$ en vez de 52.10 — una diferencia pequeña pero que puede cambiar la decisión en casos límite.

8. Errores tipo I y tipo II

Como la realidad es H_0 o H_1 (nunca ambas) pero no la conocemos, y la decisión también es binaria (rechazar / no rechazar), hay 4 combinaciones posibles — 2 correctas y 2 erróneas:

Decisión \ Realidad	H_0 verdadera	H_1 verdadera
Rechazar H_0	Error tipo I (prob. α)	Decisión correcta
No rechazar H_0	Decisión correcta	Error tipo II (prob. β)

- **Error tipo I:** rechazar H_0 cuando en realidad es verdadera. Su probabilidad es exactamente el **nivel de significación** α (por construcción: la RC se diseña para que $P_{H_0}(\text{RC}) = \alpha$).

- **Error tipo II:** no rechazar H_0 cuando en realidad H_1 es verdadera. Su probabilidad se llama β , y **se calcula después** de fijar la RC (no se elige directamente).

Trade-off (a n fijo): reducir α (RC más “exigente”, más lejos de μ_0) automáticamente agranda β , porque una RC más chica/exigente rechaza H_0 con menos frecuencia — tanto cuando H_0 es cierta (bien, eso es lo que se buscaba) como cuando H_1 es cierta (mal, eso aumenta β). La única forma de reducir **ambos** simultáneamente es aumentar n .

Ejemplo 8.1 — cuantificando el trade-off (mismo escenario del Ejemplo 7.1).

$\mu_0=170$, $\sigma=12$, $n=36$, H_1 verdadera con $\mu_A=175$. Calcular β para tres valores de α .

α	z_α	umbral $c=170+\frac{12}{6}z_\alpha$	$\beta=\Phi\left(\frac{c-175}{12/6}\right)$	Potencia $1-\beta$
0.10	1.282	172.56	0.106	0.894
0.05	1.645	173.29	0.196	0.804
0.01	2.326	174.65	0.402	0.598

Verificación numérica y por simulación (scipy + Monte Carlo, fila $\alpha=0.05$):

con $c=173.29$, simulando 200 000 muestras de $N(170, 12^2)$ con $n=36$ y contando cuántas veces $\bar{X}_n \geq c$, se obtuvo una tasa de rechazo (falso positivo) de 5.05% — consistente con $\alpha=0.05$. Simulando 200 000 muestras de $N(175, 12^2)$ (bajo H_1) con el mismo umbral, la tasa de rechazo (potencia) fue 80.43% — consistente con el valor teórico $1-\beta=0.8038$. La tabla confirma visualmente el trade-off: al bajar α de 0.10 a 0.01, β sube de 0.106 a 0.402 (más de 3.5 veces).

9. Potencia del test

Definición: $K(\theta) = 1-\beta(\theta) = P_{H_1}(\text{rechazar } H_0)$, la probabilidad de rechazar H_0 correctamente cuando el verdadero parámetro toma un valor específico θ dentro de H_1 . Como H_1 suele ser compuesta (un rango de valores, no uno solo), la potencia es en general una **función** del valor verdadero del parámetro — la “función de potencia”.

Ejemplo 9.1 — cálculo directo de la potencia (continuación del Ejemplo 7.1).

Con $\alpha=0.05$ fijo (umbral $c=173.29$, ver tabla del Ejemplo 8.1), calcular la potencia si el verdadero rendimiento medio pasó a ser $\mu_A=175$.

$$K(175) = P(\bar{X}_n \geq 173.29 \mid \mu=175) = P\left(Z \geq \frac{173.29-175}{\sqrt{12/6}}\right) = P(Z \geq -0.855) = 1 - \Phi(-0.855) = 0.8038.$$

Es decir: si en verdad la máquina ahora llena en promedio 175g, este test la detecta correctamente (rechaza H_0) el 80.4% de las veces.

Verificación Monte Carlo: igual que en el Ejemplo 8.1, la simulación de 200 000 repeticiones dio 80.43% de rechazos bajo $\mu=175$ — coincide con el cálculo teórico a menos de 0.1 punto porcentual.

Cómo se lee gráficamente la potencia (bosquejo típico de examen): se dibujan dos campanas superpuestas — la f.d.p. de $\bar{X}_n$ bajo H_0 (centrada en μ_0) y bajo H_A (centrada en μ_A). El área de la campana de H_0 a la derecha del umbral c es α (coloreada, ej. violeta). El área de la campana de H_A a la derecha del **mismo** umbral c es la potencia $1-\beta$ (coloreada, ej. amarilla). Cuanto más lejos está μ_A de μ_0 (o cuanto mayor es n , que “angosta” ambas campanas), menos se superponen las campanas y mayor es la potencia — esto es exactamente lo que se pide bosquejar en el Ejercicio 1.4b del Práctico 10 (potencia contra $\theta=0.55$ vs. $\theta=0.6$: la campana de $\theta=0.6$ está más lejos de $\theta_0=0.55$, se superpone menos con H_0 , y por eso tiene mayor potencia — 0.89 vs. 0.35 con $n=250$).

10. Equivalencia entre test bilateral e intervalo de confianza

Resultado clave: para un test bilateral $H_0:\theta=\theta_0$ vs. $H_1:\theta \neq \theta_0$ al nivel α , y el IC de nivel $1-\alpha$ construido con el mismo pivote:

$$\text{Rechazar } H_0 \text{ al nivel } \alpha \iff \theta_0 \notin \text{IC}_{1-\alpha}(\theta).$$

Por qué es cierto (idea de la demostración): la RC del test bilateral es $[\hat{\theta} - \text{margen}, \hat{\theta} + \text{margen}]$, es decir $\theta_0 \leq \hat{\theta} - \text{margen}$ o $\theta_0 \geq \hat{\theta} + \text{margen}$ — exactamente la condición de que θ_0 quede **afuera** del intervalo $[\hat{\theta} - \text{margen}, \hat{\theta} + \text{margen}]$, que es por construcción el IC de nivel $1-\alpha$.

Ejemplo 10.1 — verificando ambos caminos dan la misma conclusión (mismos datos del Ejemplo 7.1, pero test bilateral).

$\mu_0=170$, $\sigma=12$, $n=36$, $\bar{x}=174$, $\alpha=0.05$. Test $H_0:\mu=170$ vs. $H_1:\mu\neq 170$.

Camino 1 (test directo): $z_{\alpha/2}=1.96$. Estadístico $|Z|=\left|\frac{174-170}{12/6}\right|=2.0 \geq 1.96 \rightarrow$ **se rechaza H_0** .

Camino 2 (vía IC): $IC_{95\%}(\mu) = 174 \pm 1.96 \times \frac{12}{\sqrt{6}} = 174 \pm 3.92 = [170.08, 177.92]$.

¿Está $\mu_0=170$ en este intervalo? $170 < 170.08 \rightarrow$ **no está $\rightarrow$ se rechaza H_0** .

Ambos caminos coinciden $\checkmark$, exactamente como predice la equivalencia (y no es casualidad: el estadístico $|Z| \geq z_{\alpha/2}$ es algebraicamente la misma desigualdad que “ μ_0 cae fuera de $\bar{x} \pm z_{\alpha/2} \sigma / \sqrt{n}$ ”).

Esta equivalencia es exactamente lo que pide el Ejercicio 12 del Práctico 10 (“TdH vs IdC”): tomar ejercicios de IC ya resueltos (Ejercicios 11 y 12 del Práctico 9) y replantearlos como test de hipótesis — la cuenta numérica es la misma, solo cambia la pregunta que se responde con ella (ver Práctico 10, Ejercicio 12 en la resolución adjunta).

11. Trampas típicas de examen

Trampa 1 — interpretación del IC (la más grave, ver Sección 1). “Hay 95% de probabilidad de que μ esté en $[a,b]$ ” (una vez calculados a,b con números concretos) es **incorrecto**. La forma correcta: el *procedimiento* tiene 95% de cobertura.

Trampa 2 — confundir nivel de significancia con p-valor. α es un umbral que el investigador **elige de antemano**, fijo, antes de ver los datos. El p-valor es una cantidad que se **calcula después**, a partir de la muestra observada, y depende de los datos. La regla exacta que los conecta (Práctico “Test de Hipótesis”, Proposición 9): para una RC de la forma $T \geq c$, se tiene $\text{rechazar } H_0 \iff \alpha \geq \text{p-valor}$. Es decir, el p-valor es “el α más chico con el cual todavía se rechazaría H_0 con estos datos” — **no** es “la probabilidad de que H_0 sea verdadera” (esa interpretación bayesiana es un error frecuente y distinto del enfoque frecuentista de este curso).

Trampa 3 — usar Normal en vez de t-Student con n chico y σ desconocida. Ver Sección 3 y Ejemplo 7.2. La regla es simple: ¿la varianza σ^2 aparece dada en el enunciado como un número conocido? Si sí $\rightarrow$ pivote Normal (z). Si hay que estimarla de los datos (calculando S_n^2) $\rightarrow$ pivote t-Student (t), sin importar si n es grande o chico (aunque para n grande la diferencia numérica entre t y z se vuelve chica, la distribución *exacta* correcta sigue siendo t-Student).

Trampa 4 — invertir los subíndices de la Chi-cuadrado en el IC/test de varianza. Ver Sección 5. La χ^2 es asimétrica: el extremo **inferior** del IC usa $\chi^2_{\alpha/2}$ en el denominador (valor grande) y el extremo **superior** usa $\chi^2_{1-\alpha/2}$ (valor chico) — al revés de lo que la intuición (heredada de la Normal simétrica) sugeriría.

Trampa 5 — decir “acepto H_0 ” en vez de “no rechazo H_0 ”. No hay simetría entre H_0 y H_1 : se puede controlar α tan chico como se quiera, pero β queda determinado (no se elige). Por eso “no rechazar H_0 ” significa únicamente “no hay evidencia suficiente para rechazarla”, nunca “queda demostrado que H_0 es cierta”. El ejemplo del fármaco (78% de recuperación observado, umbral de rechazo en 82.1%) ilustra esto: 78% > 75% (el valor de H_0), y sin embargo no se rechaza H_0 — no porque H_0 esté “confirmada”, sino porque 78% no es lo bastante distinto de 75% para descartar el azar muestral.

Trampa 6 — con muestras chicas de una Binomial/discreta, no usar la aproximación Normal. Cuando n es chico (ej. $n=5$ u 8 lanzamientos de moneda), no corresponde aproximar por TCL: hay que trabajar directamente con la tabla de la distribución exacta (Binomial), como en el Ejercicio 11 del Práctico 10 y el Ejercicio 7 del Práctico 9. Además, con distribuciones discretas la región crítica **no siempre puede ajustarse a un α exacto** (solo a “el mayor $\alpha \leq \alpha$ alcanzable con el conjunto discreto de valores posibles del estadístico”) — otra diferencia importante con el caso continuo.

Resumen ultra-rápido (2 minutos)

- **IC $1-\alpha$:** rango aleatorio tal que, repitiendo el muestreo, el $(1-\alpha) \times 100\%$ de los intervalos contienen al parámetro fijo. **Nunca** “95% de probabilidad de que μ esté en este intervalo ya calculado”.
- **Media, σ^2 conocida:** $\bar{X}_n \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ (pivote Normal).

- **Media, σ^2 desconocida:** $\bar{X}_n \pm t_{\alpha/2, n-1} \frac{S_n}{\sqrt{n}}$ (pivote t-Student, $n-1$ g.l.).
- **Proporción (n grande):** $\hat{p} \pm z_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}$ (aproximación Normal de la Binomial).
- **Varianza:** $\left[\frac{(n-1)S_n^2}{\chi^2_{\alpha/2, n-1}}, \frac{(n-1)S_n^2}{\chi^2_{1-\alpha/2, n-1}} \right]$ (pivote Chi-cuadrado, ¡subíndices cruzados!).
- **Ancho del IC** $\propto z_{\alpha/2} / \sqrt{n}$: más confianza $\rightarrow$ más ancho; más n $\rightarrow$ menos ancho (con $1/\sqrt{n}$, no lineal).
- **Test de hipótesis:** H_0 (conservadora) vs. H_1 ; región crítica RC construida con el mismo pivote que el IC correspondiente, de nivel $\alpha = P(H_0 | \text{RC})$.
- **Error tipo I** (α , rechazar H_0 verdadera) vs. **error tipo II** (β , no rechazar H_0 falsa): a n fijo, bajar α sube β — solo subir n reduce ambos.
- **Potencia** $= 1 - \beta$: probabilidad de rechazar correctamente cuando H_1 es cierta con un valor específico del parámetro; función creciente de la distancia entre μ_0 y μ_A , y de n .
- **Test bilateral $\Leftrightarrow$ IC:** rechazar $H_0: \theta = \theta_0$ al nivel α $\iff \theta_0$ no está en el $IC_{1-\alpha}(\theta)$.
- **p-valor:** el menor α con el que aún se rechazaría H_0 con los datos observados; rechazo $\iff \alpha \geq \text{p-valor}$. No es " $P(H_0 \text{ verdadera})$ ".
- **Trampas de examen:** (1) mala interpretación del IC, (2) confundir α con p-valor, (3) Normal en vez de t-Student cuando σ es estimada, (4) subíndices cruzados de χ^2 , (5) "acepto H_0 " en vez de "no rechazo", (6) usar TCL con n chico en vez de la distribución exacta.