

CONTENTS

P-valor, Distribución Empírica y Bondad de Ajuste

Guía de estudio con tolerancia cero — Tema 2.7, Probabilidad y Estadística (FING UdelaR)

0. Por qué existe este tema

1. El p-valor

1.1 Motivación y definición

1.2 La trampa de examen: qué NO es el p-valor

2. Función de distribución empírica

2.1 Definición y propiedades

3. Test de Kolmogorov-Smirnov

3.1 Planteo

3.2 Cálculo práctico del estadístico D_n

3.3 Regla de decisión

4. Test de Lilliefors

4.1 En qué se diferencia de Kolmogorov-Smirnov

5. Trampas típicas de examen (resumen)

Resumen ultra-rápido (2 minutos)

P-valor, Distribución Empírica y Bondad de Ajuste

GUÍA DE ESTUDIO CON TOLERANCIA CERO — TEMA 2.7, PROBABILIDAD Y ESTADÍSTICA (FING UDELAR)

0. Por qué existe este tema

Hasta el tema anterior (2.6, Test de Hipótesis) aprendiste a construir una **región crítica** de nivel α fijo: elegís α de antemano, calculás el valor crítico c , y comparás tu estadístico observado contra c para decidir “rechazo” o “no rechazo”. El problema práctico es que esa región crítica depende de α — si alguien te pregunta “¿y si hubiera trabajado al 1% en vez de al 5%?” tenés que rehacer toda la cuenta del valor crítico.

El **p-valor** resuelve esto de una vez y para siempre: es un único número que, una vez calculado, te permite tomar la decisión para **cualquier** nivel α sin volver a tocar la tabla. Es, con diferencia, el concepto de esta materia que más se malinterpreta fuera del ámbito académico (y el que más trampas de examen tiene), así que la Sección 1 está dedicada casi por completo a blindarte contra esas trampas.

La segunda mitad del tema resuelve un problema distinto: hasta ahora todos los tests de hipótesis asumían que **conocías la familia de distribución** de los datos (Normal, Bernoulli, Exponencial...) y solo dudabas de algún parámetro. Las **pruebas de bondad de ajuste** (Kolmogorov-Smirnov y Lilliefors) sirven para testear la distribución *completa*: ¿es razonable pensar que estos datos vienen de una $\text{Exp}(\lambda=1)$? ¿de una Normal? Para eso primero hace falta una herramienta nueva: la **función de distribución empírica**, que es la forma de “dibujar” la distribución de la muestra sin asumir nada sobre ella.

Regla de oro que atraviesa todo el tema: el p-valor y los tests de bondad de ajuste (K-S, Lilliefors) **no son ideas nuevas de cero** — son la maquinaria de Tests de Hipótesis (2.6) aplicada con otro estadístico (el supremo de una diferencia de distribuciones, en vez de una media muestral) y resumida en un solo número (el p-valor) en vez de una región crítica atada a un α fijo.

1. El p-valor

1.1 MOTIVACIÓN Y DEFINICIÓN

Definición formal. Dada una prueba de hipótesis H_0 vs. H_1 cuya región crítica tiene la forma

$$RC = \{(X_1, \dots, X_n) : T(X_1, \dots, X_n) \geq c\}$$

para algún estadístico T y alguna constante c , si observamos la muestra realizada $(x_1, \dots, x_n)$ y llamamos $t_0 = T(x_1, \dots, x_n)$ al valor observado del estadístico, entonces

$$\text{p-valor} = P_{\{H_0\}}(T \geq t_0)$$

En palabras: **el p-valor es la probabilidad, calculada asumiendo que H_0 es cierta, de observar un valor del estadístico tan extremo o más extremo que el que efectivamente observamos** (extremo en la dirección que favorece a H_1 ; si la región crítica fuera de la forma $T \leq c$, el p-valor se define análogamente como $P_{\{H_0\}}(T \leq t_0)$, y en un test a dos colas se suma la probabilidad de ambas colas).

Regla de decisión (equivalencia con el enfoque clásico).

$$\text{Rechazo } H_0 \text{ si y solo si } \alpha \geq \text{p-valor}.$$

Demostración (la que aparece en el apunte de la cátedra). Dado α , sea c el valor tal que $P_{\{H_0\}}(T \geq c) = \alpha$. Entonces:

$$\alpha \geq \text{p-valor} \Leftrightarrow P_{\{H_0\}}(T \geq c) \geq P_{\{H_0\}}(T \geq t_0) \Leftrightarrow c \leq t_0 \Leftrightarrow \text{rechazo } H_0$$

(la penúltima equivalencia usa que $P_{\{H_0\}}(T \geq x)$ es decreciente en x ; la última es exactamente la definición de la región crítica $T \geq c$). ■

Esta equivalencia es la razón de ser del p-valor: **una vez calculado, sirve para decidir a cualquier nivel α** sin recalculer ningún valor crítico. Si el p-valor es 0.03, rechazás al 5% y al 10%, pero no rechazás al 1%. Si el p-valor es chico, hay poca probabilidad de haber observado algo “tan raro” bajo H_0 — eso es evidencia en contra de H_0 .

Ejemplo 1.1 — Cálculo completo de un p-valor (test sobre la media, varianza conocida).

Sea $X_1, \dots, X_{25}$ una MAS de $X \sim N(\mu, \sigma^2=4)$, de la cual se obtuvo $\bar{x} = 1.3$. Se quiere testear $H_0: \mu=1$ vs. $H_1: \mu>1$. Hallar el p-valor y decidir al 5%.

La región crítica de este test es de la forma $\{\bar{X}_n \geq \mu_0 + (\sigma/\sqrt{n})z_{\alpha}\} = \{\bar{X}_n \geq \text{cte}\}$, o sea $T = \bar{X}_n$

y $t_0 = 1.3$.

Bajo H_0 ($\mu=1$), $\bar{X}_n \sim N(1, 4/25)$ — la varianza es $\sigma^2/n = 4/25$ porque el cálculo se hace suponiendo H_0 cierta.

$p\text{-valor} = P_{\{H_0\}}(\bar{X}_n \geq 1.3) = 1 - \Phi((1.3-1)/(2/5)) = 1 - \Phi(0.75) = 1 - 0.7734 = \mathbf{0.2266 \approx 0.227}$.

Decisión: como $\alpha = 0.05 < 0.227 = p\text{-valor}$, **no rechazamos H_0** al 5% (de hecho tampoco se rechazaría a ningún α usual ≤ 0.20 , porque el p-valor es grande).

Verificación cruzada (vía valor crítico clásico): el valor crítico al 5% sería $1 + (2/5)$ (1.645) = 1.658; como $\bar{x}=1.3 < 1.658$, no cae en la región crítica $\rightarrow$ no rechazo, consistente con la conclusión vía p-valor. $\checkmark$

Ejemplo 1.2 — El mismo dato, dos hipótesis distintas (mismos datos, distinta pregunta).

Con los mismos datos del Ejemplo 1.1 ($n=25$, $\sigma^2=4$, $\bar{x}=1.3$):

(a) $H_0: \mu=1.5$ vs. $H_1: \mu<1.5$ (test a una cola izquierda). Bajo H_0 , $\bar{X}_n \sim N(1.5, 4/25)$.

$p\text{-valor} = P_{\{H_0\}}(\bar{X}_n \leq 1.3) = \Phi((1.3-1.5)/(2/5)) = \Phi(-0.5) = 1 - \Phi(0.5) = 1 - 0.6915 = \mathbf{0.3085}$.

Como $0.05 < 0.3085$, no rechazamos H_0 .

(b) $H_0: \mu=1$ vs. $H_1: \mu \neq 1$ (test a dos colas). Bajo H_0 , $\bar{X}_n \sim N(1, 4/25)$.

$p\text{-valor} = P_{\{H_0\}}(|\bar{X}_n - 1| \geq |1.3 - 1|) = 2 \times P_{\{H_0\}}(\bar{X}_n - 1 \geq 0.3) = 2 \times (1 - \Phi(0.3/(2/5))) = 2 \times (1 - \Phi(0.75)) = 2 \times 0.2266 = \mathbf{0.4533}$.

Como $0.05 < 0.4533$, tampoco rechazamos H_0 .

Moraleja: el mismo dato observado ($\bar{x}=1.3$) produce p-valores completamente distintos según cuál sea H_0/H_1 — el p-valor no es una propiedad de los datos solos, es una propiedad del par (datos, hipótesis planteada). (*Verificado numéricamente con `scipy.stats.norm`: $p_a=0.3085$, $p_b=0.4533$ — coinciden exactamente con el cálculo a mano.*)

1.2 LA TRAMPA DE EXAMEN: QUÉ NO ES EL P-VALOR

⚠ Error de tolerancia cero — el más importante de todo el tema: el p-valor NO es “la probabilidad de que H_0 sea verdadera”, ni “la probabilidad de que H_0 sea falsa”, ni “la probabilidad de haberse equivocado al rechazar H_0 ”. Mirá la definición de nuevo: **p-valor = $P_{\{H_0\}}(T \geq t_0)$** — es una probabilidad calculada *asumiendo H_0 cierta desde el vamos*, sobre el estadístico T , no sobre la hipótesis en sí. H_0 no es una variable aleatoria: es ver-

dadera o falsa (no lo sabemos), y no tiene sentido hablar de “la probabilidad de que sea verdadera” dentro de este marco (frecuentista) de la materia.

Dicho de otra forma: el p-valor responde “¿qué tan compatibles son estos datos con H_0 ?”, no “¿qué tan probable es H_0 ?”. Son preguntas distintas y confundirlas es el error más común (y más penalizado) en el uso del p-valor, tanto en exámenes como en la práctica profesional real.

Consecuencia práctica de la definición: un p-valor grande (ej. 0.85) **no prueba que H_0 sea cierta** — solo dice que los datos observados no dan motivo para dudar de H_0 . Puede haber otra razón para el p-valor grande, como tener pocos datos (poca potencia del test). “No rechazar” nunca es sinónimo de “demostrar”. Ver Sección 5 para el desarrollo completo de esta trampa.

2. Función de distribución empírica

2.1 DEFINICIÓN Y PROPIEDADES

Dada una MAS $X_1, \dots, X_n$ de X con distribución F_X desconocida, la **función de distribución empírica** se define como

$$F_n^*(x) = (1/n) \sum_i \mathbb{1}\{X_i \leq x\} = (\text{cantidad de observaciones} \leq x) / n$$

Es decir, $F_n^*(x)$ es la **proporción de datos de la muestra que son $\leq x$** .

Propiedades:

- Es una **función escalón**: constante entre observaciones consecutivas, con saltos de tamaño $1/n$ en cada punto muestral (si no hay empates, que ocurre con probabilidad 1 en distribuciones continuas).
- Si ordenamos la muestra de menor a mayor $X_1 < X_2 < \dots < X_n$, entonces $F_n^*(x) = i/n$ para todo $x \in [X_i, X_{i+1})$.
- $F_n^*(x) \rightarrow F_X(x)$ para todo x , por la Ley de los Grandes Números ($F_n^*(x)$ es un promedio de indicadoras i.i.d. con esperanza $F_X(x)$). Este resultado, cuando se fortalece a convergencia uniforme ($\sup_x |F_n^*(x) - F_X(x)| \rightarrow 0$ casi seguramente), es el **Teorema de Glivenko-Cantelli**, y es exactamente lo que justifica más adelante el test de Kolmogorov-Smirnov: si la distancia entre F_n^* y una F_0 candidata no tiende a achicarse, es evidencia de que F_0 no es la distribución verdadera.

Ejemplo 2.1 — Tabular y graficar F_n^* para una muestra chica.

Muestra ($n=5$): 0.5, 0.8, 0.6, 1.0, 0.7. Ordenada: $X_1^*=0.5$, $X_2^*=0.6$, $X_3^*=0.7$, $X_4^*=0.8$, $X_5^*=1.0$.

Intervalo de x	$F_5^*(x)$
$x < 0.5$	0
$0.5 \leq x < 0.6$	$1/5 = 0.2$
$0.6 \leq x < 0.7$	$2/5 = 0.4$
$0.7 \leq x < 0.8$	$3/5 = 0.6$
$0.8 \leq x < 1.0$	$4/5 = 0.8$
$x \geq 1.0$	$5/5 = 1.0$

Forma: un gráfico de F_5 es una escalera que arranca en 0, sube de a saltos de 0.2 en cada uno de los 5 valores muestrales (ordenados), y llega a 1 en el valor máximo de la muestra. Es exactamente la muestra usada en el Ejemplo 3.2 de la Sección 3 (test de bondad de ajuste), donde esta tabla es el insumo directo para calcular el estadístico de K-S.

Verificación: el salto total acumulado es $5 \times (1/5) = 1$ ✓ (F_n siempre termina en 1, porque el 100% de la muestra es $\leq$ al máximo observado).

3. Test de Kolmogorov-Smirnov

3.1 PLANTEO

Sea $X_1, \dots, X_n$ una MAS de $X \sim F_X$, con F_X desconocida, y sea F_0 una función de distribución **continua y completamente conocida** (sin parámetros a estimar — ningún μ , σ , λ , etc. que dependan de la propia muestra). Se plantea

$$H_0: F_X = F_0 \text{ (es decir, } X \sim F_0) \quad \text{vs.} \quad H_1: \text{no } H_0$$

Idea del test: si H_0 es cierta, por Glivenko-Cantelli la distribución empírica F_n^* debería estar uniformemente cerca de F_0 . Se mide esa cercanía con el estadístico

$$D_n = \sup_{\{x \in \mathbb{R}\}} |F_n^*(x) - F_0(x)|$$

y se rechaza H_0 si D_n es “demasiado grande” — región crítica $\{D_n \geq c\}$.

La distribución exacta de D_n para n fijo no es conocida en forma cerrada, pero existe un resultado asintótico (basado en el **principio de invarianza de Donsker**) que da la distribución límite de $\sqrt{n} \cdot D_n$. Para n chico (el caso típico de examen) se usan directamente los **valores críticos tabulados** (Tabla de Kolmogorov-Smirnov), sin necesidad de la fórmula asintótica.

3.2 CÁLCULO PRÁCTICO DEL ESTADÍSTICO D_n

Como F_0 es creciente y F_n es *escalón (constante entre datos consecutivos)*, el supremo de la diferencia en cada intervalo $[X_i, X_{i+1}^*)$ solo puede alcanzarse en los extremos del intervalo. Esto da un procedimiento mecánico:

1. **Ordenar** los datos: $X_1 < X_2 < \dots < X_n^*$.
2. Para cada $i=1, \dots, n$, calcular $|i/n - F_0(X_i^*)|$.
3. Para cada $i=1, \dots, n$, calcular $|(i-1)/n - F_0(X_i^*)|$.
4. **D_n = el máximo de todos los valores de los pasos 2 y 3.**

(La columna del paso 2 mide la distancia justo *después* de que F_n *da su salto en* X_i ; la del paso 3 mide la distancia justo *antes* del salto — como F_n^* es escalón, el peor caso de cada tramo está en uno de esos dos bordes.)

3.3 REGLA DE DECISIÓN

Con la **Tabla de Kolmogorov-Smirnov** (valores críticos $D_{\{n,\alpha\}}$ tabulados por tamaño muestral n y nivel α), la regla es:

Rechazar H_0 si $D_n \geq D_{\{n,\alpha\}}$ (valor de tabla para el n y α de la prueba).

Para $n > 35$ (fuera del rango tabulado), se usa la aproximación $D_{\{n,\alpha\}} \approx k_\alpha / \sqrt{n}$, con k_α tabulado ($k_{\{0.05\}}=1.36$, $k_{\{0.01\}}=1.63$, etc.).

Ejemplo 3.1 — Test de Kolmogorov-Smirnov completo, paso a paso (datos: apunte de la cátedra).

Muestra ($n=5$): 0.8, 1, 0.6, 0.5, 0.7. Se quiere testear $H_0: X \sim \text{Exp}(\lambda=1)$ vs. H_1 : no H_0 , al nivel 5%.

$F_0(x) = 1 - e^{-x}$ para $x \geq 0$.

i	X_i^*	$ i/5 - F_o(X_i^*) $	$ (i-1)/5 - F_o(X_i^*) $
1	0.5	0.1935	0.3935
2	0.6	0.0512	0.2512
3	0.7	0.0966	0.1034
4	0.8	0.2493	0.0493
5	1.0	0.3679	0.1679

Máximo de la 3ª columna: 0.3679. Máximo de la 4ª columna: 0.3935.

$D_5 = \max\{0.3679, 0.3935\} = 0.3935$.

De la tabla de K-S, fila $n=5$, columna $\alpha=0.05$: valor crítico = **0.565**.

Como $D_5 = 0.3935 < 0.565$, **no rechazamos H_0** — no hay evidencia suficiente para descartar que los datos vengan de una $\text{Exp}(\lambda=1)$.

Verificación con Python (scipy.stats.kstest): `stats.kstest([0.8,1,0.6,0.5,0.7], 'expon', args=(0,1))` da estadístico $D = 0.3935$ (coincide exactamente con el cálculo a mano) y $p\text{-valor} = 0.327$ (> 0.05 , consistente con “no rechazar”).

Ejemplo 3.2 — Segundo ejemplo completo, con distribución Uniforme (Examen PyE, diciembre 2024, Ej.8).

Muestra ($n=5$): 0.81, 0.90, 0.12, 0.91, 0.63. $H_0: X \sim U(0,1)$ vs. H_1 : no H_0 , $\alpha=0.05$. Aquí $F_o(x) = x$.

$i/5$	X_i^*	$ F_o(X_i^*) - (i-1)/5 $	$ F_o(X_i^*) - i/5 $
0.2	0.12	0.12	0.08
0.4	0.63	0.43	0.23
0.6	0.81	0.41	0.21
0.8	0.90	0.30	0.10
1.0	0.91	0.11	0.19

Máximos por columna: 0.43 y 0.23 $\rightarrow D_5 = 0.43$.

Valor crítico de tabla ($n=5$, $\alpha=0.05$): 0.565. Como $0.43 < 0.565$, **no rechazamos H_0** : es razonable que los datos vengan de una $U(0,1)$.

Verificación con Python: `stats.kstest([0.81,0.90,0.12,0.91,0.63], 'uniform')` da $D = 0.43$ exacto y $p\text{-valor} = 0.236$.

Truco de verificación: en cualquier ejercicio de K-S, el estadístico D_n siempre está entre 0 y 1 (es una diferencia de dos funciones de distribución, ambas entre 0 y 1). Si te da un número fuera de ese rango, hay un error de cuenta. Además, chequeá que usaste **** F_0 evaluada en los datos ordenados****, no en el índice i — es el error de transcripción más común.

4. Test de Lilliefors

4.1 EN QUÉ SE DIFERENCIA DE KOLMOGOROV-SMIRNOV

El test de K-S de la Sección 3 exige que F_0 esté **completamente especificada, sin parámetros libres** — por ejemplo $\text{Exp}(\lambda=1)$ con λ dado de antemano, no estimado de los datos. Pero en la práctica, la pregunta típica es “¿son estos datos Normales?” **sin conocer μ y σ de antemano** — hay que estimarlos de la propia muestra ($\hat{\mu} = \bar{X}_n$, $\hat{\sigma}^2 = S_n^2$).

Ahí aparece un problema sutil: al estimar los parámetros con la misma muestra que se está testeando, la distribución empírica queda “artificialmente” más parecida a la F_0 estimada de lo que estaría si los parámetros vinieran de otra fuente — el propio proceso de ajustar $\hat{\mu}$ y $\hat{\sigma}$ a los datos hace que D_n tienda a dar valores **más chicos** de lo que daría con parámetros verdaderos fijados de antemano. El test de **Lilliefors** (Hubert Lilliefors, 1967, “*On the Kolmogorov-Smirnov Test for Normality with Mean and Variance Unknown*”, JASA) corrige exactamente esto: usa el mismo estadístico D_n , pero con una **tabla de valores críticos distinta** (más exigente / valores más chicos) que tiene en cuenta ese sesgo.

Planteo formal:

$H_0: X \sim N(\mu, \sigma^2)$ para algunos μ, σ^2 (no especificados de antemano) vs. $H_1: \text{no } H_0$

Región crítica: $\{\sup_x |F_n^*(x) - \Phi((x - \bar{X}_n)/S_n)| \geq c\}$, con $S_n^2 = (1/(n-1))\sum (X_i - \bar{X}_n)^2$.

El **cálculo del estadístico es idéntico** al procedimiento de la Sección 3.2, cambiando $F_0(x)$ por $\Phi((x-\bar{X}_n)/S_n)$ (la Normal ajustada con la media y el desvío muestrales). Lo único que cambia es la **tabla** que se usa para decidir: la Tabla de Lilliefors, no la de K-S estándar.

⚠ Error de tolerancia cero: usar la **tabla de Kolmogorov-Smirnov estándar** (Sección 3.3) para decidir un test de normalidad cuando μ y σ^2 fueron **estimados de la misma muestra**. Esto da un test **conservador e incorrecto**: los valores críticos de la tabla de K-S estándar son *más grandes* que los de Lilliefors (compará: $n=10$, $\alpha=0.05 \rightarrow$ K-S da 0.410, Lilliefors da 0.258), porque la tabla de K-S estándar asume que F_0 no depende para nada de los datos. Usarla en un test de normalidad con parámetros estimados hace que sea mucho más difícil rechazar H_0 de lo que debería — el test pierde potencia sin que el enunciado te avise, y en el examen se considera un error grave de método, no solo de cuenta.

Ejemplo 4.1 — Test de Lilliefors completo, mismos datos que el Ejemplo 3.1.

Muestra ($n=5$): 0.8, 1, 0.6, 0.5, 0.7. $H_0: X \sim N(\mu, \sigma^2)$ (parámetros no especificados) vs. H_1 : no H_0 , $\alpha=0.05$.

Estimaciones: $\bar{X}_5 = 0.72$, $S_5 = 0.1924$ (desvío muestral con divisor $n-1$).

F_0 estimada: $\Phi((x-0.72)/0.1924)$.

i	X_i^*	$ i/5 - \Phi((X_i^*-0.72)/0.1924) $	$ (i-1)/5 - \Phi(\cdot) $
1	0.5	0.0736	0.1264
2	0.6	0.1336	0.0664
3	0.7	0.1414	0.0586
4	0.8	0.1387	0.0613
5	1.0	0.0727	0.1273

$D_5 = \max = 0.1414$.

Valor crítico de la tabla de Lilliefors ($n=5$, $\alpha=0.05$): **0.337**.

Como $D_5 = 0.1414 < 0.337$, **no rechazamos H_0** : no hay evidencia para descartar normalidad.

Verificación con Python: cálculo manual con `scipy.stats.norm.cdf` reproduce exactamente $D=0.1414$ (no se pudo contrastar contra `statsmodels.stats.diagnostic.lilliefors`)

porque el paquete no está instalado en este entorno; el cálculo manual siguiendo la definición de la Sección 4.1 es exacto y no depende de statsmodels — statsmodels solo automatizaría la misma cuenta).

Comentario clave (interpretación, no solo cuenta): con estos mismos 5 datos, en el Ejemplo 3.1 tampoco se había rechazado H_0 : $\text{Exp}(\lambda=1)$. Esto no es contradictorio: con $n=5$ el test tiene muy poca potencia, y “no rechazar” nunca equivale a “aceptar” — ver Sección 5. No se puede concluir que los datos sean simultáneamente Exponenciales y Normales; solo que, con tan pocos datos, ninguna de las dos hipótesis pudo descartarse con evidencia suficiente.

Truco de verificación: el estadístico D_n de Lilliefors para una muestra dada siempre es **menor o igual** que el que se obtendría con K-S estándar usando la F_0 “más parecida posible” a los datos — es consecuencia directa de estimar los parámetros de la propia muestra (se está ajustando F_0 para minimizar la distancia). Por eso los valores críticos de la tabla de Lilliefors son más chicos: para compensar esa ventaja artificial.

5. Trampas típicas de examen (resumen)

Trampa 1 — Confundir p-valor con “probabilidad de que H_0 sea verdadera”. El p-valor es $P_{\{H_0\}}(T \geq t_0)$: se calcula *bajo el supuesto* de que H_0 es cierta, sobre el estadístico observado. No es una probabilidad sobre la hipótesis. Ver Sección 1.2.

Trampa 2 — Usar la tabla de K-S estándar en vez de la de Lilliefors cuando los parámetros de la distribución de referencia (típicamente μ y σ de una Normal) fueron estimados de la misma muestra que se testea. Da un test conservador e inválido. Ver Sección 4.1.

Trampa 3 — Confundir “no rechazar H_0 ” con “aceptar que los datos son Normales” (o Exponenciales, o lo que sea H_0). “No rechazar” solo significa “no hay evidencia suficiente en esta muestra para descartar H_0 ” — la ausencia de evidencia en contra **no es evidencia a favor**. Con muestras chicas ($n=5$, como en los Ejemplos 3.1 y 4.1) el test tiene poca potencia: es fácil “no rechazar” casi cualquier distribución razonable, precisamente porque hay poca información para distinguir entre hipótesis. La frase correcta en un exa-

men es “no tenemos evidencia suficiente para rechazar H_0 ”, nunca “se probó/confirmó que H_0 es cierta”.

Complemento breve — Test χ^2 de bondad de ajuste (alternativa para el caso discreto/agrupado). Cuando los datos son categóricos o se agrupan en clases (por ejemplo, testear la Ley de Benford, o una tabla de contingencia — ver Práctico 13, Ejercicios 4 y 5), se usa en cambio el estadístico de razón de verosimilitud $Q_L = 2 \sum_i n_i \ln(n_i/(n \cdot \hat{p}_i))$ (o el χ^2 de Pearson clásico $\sum (n_i - n \cdot p_i)^2 / (n \cdot p_i)$), que bajo H_0 se distribuye aproximadamente $\chi^2(k-1-\dim(\hat{P}))$, con k = cantidad de clases y $\dim(\hat{P})$ = cantidad de parámetros estimados. K-S/Lilliefors, en cambio, se usan cuando los datos son continuos y no se quiere perder información agrupándolos en clases arbitrarias — son estrictamente más apropiados para variables continuas que forzar un χ^2 con clases inventadas.

Resumen ultra-rápido (2 minutos)

- **p-valor** = $P_{\{H_0\}}(T \geq t_0)$: probabilidad, bajo H_0 , de un estadístico tan extremo o más que el observado. **Regla:** rechazo $H_0 \Leftrightarrow \alpha \geq \text{p-valor}$.
- El p-valor **NO** es “la probabilidad de que H_0 sea cierta” — es una probabilidad calculada *asumiendo* H_0 , no una probabilidad *sobre* H_0 .
- **Distribución empírica:** $F_n(x)$ = *proporción de la muestra $\leq x$. Es escalón, con saltos de $1/n$.* $F_n(x) \rightarrow F_X(x)$ (LGN / Glivenko-Cantelli).
- **Kolmogorov-Smirnov:** $H_0: X \sim F_0$ (F_0 *completamente conocida*, sin parámetros a estimar). Estadístico $D_n = \sup |F_n(x) - F_0(x)| = \max$ de $|i/n - F_0(X_i)|$ y $|(i-1)/n - F_0(X_{i-1}^*)|$ sobre los datos ordenados. Rechazo si $D_n \geq$ valor crítico de tabla K-S.
- **Lilliefors:** mismo estadístico D_n , pero F_0 es una Normal con $\hat{\mu} = \bar{X}_n$, $\hat{\sigma} = S_n$ estimados de la propia muestra $\rightarrow$ hace falta la **tabla de Lilliefors** (valores críticos más chicos), no la de K-S estándar.
- Usar la tabla de K-S estándar con parámetros estimados = error de tolerancia cero (test conservador e inválido).
- “No rechazar H_0 ” $\neq$ “ H_0 es cierta”. Ausencia de evidencia $\neq$ evidencia de ausencia — especialmente relevante con muestras chicas.
- Alternativa para datos discretos/agrupados: test χ^2 de bondad de ajuste (razón de verosimilitud o Pearson), con $gl = k-1-(\text{parámetros estimados})$.